1.3 多元向量值函数及其性质

最初，我们考虑了（单值）多元函数，即自变量为向量，而因变量为标量的函数. 然而，我们上一节考虑的线性映射的因变量则是一个向量. 因此，本节我们将系统考虑多元向量值函数，即自变量为向量，因变量也为向量的函数，并探究其微分性质及其与多元函数的关系.

1.3.1 雅各比矩阵

多元向量值函数的定义如下：

定义 1.3.1 (多元向量值函数) 设 X 为实数集 R^n 中的一个子集，如果存在一个对应法则 $\boldsymbol{f}$，使得对于任意 $\boldsymbol{x}=(x_1,x_2,\ldots,x_n)\in X$，都存在唯一 $\boldsymbol{y}=(y_1,y_2,\ldots,y_m)\in\mathbb{R}^m$ 与之对应，则称 $\boldsymbol{f}$ 为定义在 X 上（陪域为 $\mathbb{R}^m$）的 n 元 m 维向量值函数，记作：

$$\boldsymbol{f}:X\to\mathbb{R}^m;\quad \boldsymbol{x}\mapsto\boldsymbol{y}=\boldsymbol{f}(\boldsymbol{x})=\begin{pmatrix} f_1(x_1,x_2,\ldots,x_n)\\ f_2(x_1,x_2,\ldots,x_n)\\ \vdots\\ f_m(x_1,x_2,\ldots,x_n)\end{pmatrix}.$$

由于向量值函数可以视为由 m 个普通多元函数拼合而成，因此每单个多元函数 $y_i=f_i(\boldsymbol{x})$ 均可分别求出所有偏导数和梯度. 事实上，我们可以将每个多元函数的梯度用行向量的形式写出，并纵向拼合成一个矩阵，该矩阵即为多元向量值函数 $\boldsymbol{f}$ 的雅各比矩阵（Jacobian matrix）.

定义 1.3.2 (雅各比矩阵) 对于定义在 $X\subseteq\mathbb{R}^n$ 上的多元向量值函数 $\boldsymbol{f}(\boldsymbol{x})\in\mathbb{R}^m$，若其所有分量的所有偏导数 $(f_i)'_j(\boldsymbol{x}),i=1,2,\ldots,m;j=1,2,\ldots,n$ 在定义域内均存在且为连续函数，则函数 $\boldsymbol{f}$ 的雅各比矩阵定义为由因变量的所有分量关于自变量的所有分量求偏导所构成的矩阵，即：

$$J_{\boldsymbol{f}}(\boldsymbol{x}):=\begin{pmatrix}(f_1)'_1(\boldsymbol{x}) & \cdots & (f_1)'_n(\boldsymbol{x})\\ \vdots & & \vdots\\ (f_m)'_1(\boldsymbol{x}) & \cdots & (f_m)'_n(\boldsymbol{x})\end{pmatrix}=\begin{pmatrix}\nabla f_1(\boldsymbol{x})^\top\\ \vdots\\ \nabla f_m(\boldsymbol{x})^\top\end{pmatrix}.$$

同样，雅各比矩阵也有不止一种表示方式，我们也可以直接借用一元函数中的导数记号，将其记为 $\boldsymbol{f}'(\boldsymbol{x})$. 此外，在机器学习相关研究中，当因变量固定为 $\boldsymbol{y}$ 时，有时会使

Yuan and Song

用偏导数记号 $\dfrac{\partial \boldsymbol{y}}{\partial \boldsymbol{x}}$ 来不严谨地代表雅各比矩阵，为了不易混淆，本书后续内容中如果使用这一偏导数形式的记号，都会进行说明.

以下几个例子演示了雅各比矩阵的求解过程：

例 1.3.3 我们考虑线性映射这一多元向量值函数. 设函数 $\boldsymbol{f}:\mathbb{R}^n\to\mathbb{R}^m$,

$$\boldsymbol{f}(\boldsymbol{x})=A\boldsymbol{x},\quad A\in\mathbb{R}^{m\times n},$$

记因变量为 $\boldsymbol{y}=A\boldsymbol{x}$, 则因变量的每个分量为:

$$y_i=a_{i1}x_1+a_{i2}x_2+\cdots+a_{in}x_n,$$

相应地每个分量的偏导数为

$$\frac{\partial y_i}{\partial x_j}=a_{ij},$$

从而该函数的雅各比矩阵即为

$$J_{\boldsymbol{f}}(\boldsymbol{x})=A.$$

例 1.3.4 (从二维输入到三维输出) 考虑向量值函数

$$\boldsymbol{f}:\mathbb{R}^2\to\mathbb{R}^3,\qquad \boldsymbol{f}(x_1,x_2)=\begin{pmatrix}x_1^2+x_2\\ x_1x_2\\ e^{x_2}\end{pmatrix}.$$

分别计算三个分量的偏导数：

$$\frac{\partial f_1}{\partial x_1}=2x_1,\qquad \frac{\partial f_1}{\partial x_2}=1,$$

$$\frac{\partial f_2}{\partial x_1}=x_2,\qquad \frac{\partial f_2}{\partial x_2}=x_1,$$

$$\frac{\partial f_3}{\partial x_1}=0,\qquad \frac{\partial f_3}{\partial x_2}=e^{x_2}.$$

将每个分量函数的偏导数排列成一行，得到

$$J_{\boldsymbol{f}}(x_1,x_2)=\begin{pmatrix}2x_1 & 1\\ x_2 & x_1\\ 0 & e^{x_2}\end{pmatrix}.$$

Yuan and Song

例如，在 $(x_1, x_2) = (1, 1)$ 处，

$$J_{\boldsymbol{f}}(1,1) = \begin{pmatrix} 2 & 1 \\ 1 & 1 \\ 0 & e \end{pmatrix}.$$

这个函数有三个输出分量、两个输入分量，因此其雅各比矩阵是一个 3×2 矩阵. 雅各比矩阵不必是方阵，并且通常随求导点的位置变化.

例 1.3.5 Softmax 函数用于将一列实数映射为一个抽样时的概率分布，具体的函数形式为 $\boldsymbol{s} : \mathbb{R}^n \to \mathbb{R}^n$,

$$s_i(\boldsymbol{x}) = \frac{e^{x_i}}{e^{x_1} + \cdots + e^{x_n}}.$$

我们下面考虑每个 s_i 关于 x_j 的偏导数. 如果 $j = i$, 则

$$(s_i)'_i(\boldsymbol{x}) = \frac{e^{x_i}}{e^{x_1} + \cdots + e^{x_n}} - \frac{e^{x_i} e^{x_i}}{(e^{x_1} + \cdots + e^{x_n})^2};$$

如果 $j \neq i$, 则

$$(s_i)'_j(\boldsymbol{x}) = -\frac{e^{x_i} e^{x_j}}{(e^{x_1} + \cdots + e^{x_j})^2}.$$

为使得我们的记号更加简便，我们固定因变量 $\boldsymbol{y} = \boldsymbol{s}(\boldsymbol{x})$, 则 Softmax 函数的雅各比矩阵可表示为：

$$J_{\boldsymbol{s}}(\boldsymbol{x}) = \mathrm{Diag}(\boldsymbol{y}) - \boldsymbol{y}\boldsymbol{y}^\top.$$

我们可以观察到，Softmax 函数的雅各比矩阵可以使用因变量进行较为简单的表示，这在前反向传播中具有一定的优势.

1.3.2 梯度作为向量值函数、雅各比矩阵与海瑟矩阵的联系

对于一个多元函数 $f : \mathbb{R}^n \to \mathbb{R}$, 我们可以求得它的 $n \times n$ 维海瑟矩阵；而对于多元向量值函数 $g : \mathbb{R}^n \to \mathbb{R}^n$, 我们同样可以求得它的 $n \times n$ 维的雅各比矩阵. 我们自然要问，两个矩阵之间有着什么样的联系呢？

对于函数 f, 我们会去思考其中是否蕴含一个多元向量值函数，其定义域与陪域均为 $\mathbb{R}^n$, 事实上这样的向量值函数确实存在，而且就是 f 的梯度：我们知道，函数 f 的每个偏导数都为一个 n 元函数，而梯度的定义便是将这 n 个偏导数拼合成为一个向量. 因此可以很自然地将梯度 ∇f 视为一个 n 元的 n 维向量值函数，即：

$$\nabla f : \mathbb{R}^n \to \mathbb{R}^n; \quad \boldsymbol{x} \mapsto \boldsymbol{y} = \nabla f(\boldsymbol{x}) = \big(f'_1(\boldsymbol{x}), \ldots, f'_n(\boldsymbol{x})\big)^\top,$$

注意此时梯度应写为列向量. 进一步，如果我们对这一多元向量值函数求雅各比矩阵，

Yuan and Song

我们可以得到：

$$J_{\nabla f}(\boldsymbol{x}) = \begin{pmatrix} f''_{11}(\boldsymbol{x}) & \cdots & f''_{1n}(\boldsymbol{x}) \\ \vdots & & \vdots \\ f''_{n1}(\boldsymbol{x}) & \cdots & f''_{nn}(\boldsymbol{x}) \end{pmatrix}.$$

我们惊喜地发现，这恰好是函数 f 的海瑟矩阵. 因此我们有如下重要结论：**多元函数 f 的海瑟矩阵，等价于其梯度作为多元向量值函数时的雅各比矩阵.**

例 1.3.6 (梯度的雅各比矩阵就是海瑟矩阵) 考虑标量函数

$$\phi : \mathbb{R}^2 \to \mathbb{R}, \qquad \phi(x_1, x_2) = x_1^2 + x_1 x_2 + x_2^4.$$

它的列梯度为

$$\nabla\phi(x_1, x_2) = \begin{pmatrix} 2x_1 + x_2 \\ x_1 + 4x_2^3 \end{pmatrix}.$$

将梯度视为向量值函数

$$\boldsymbol{q} = \nabla\phi : \mathbb{R}^2 \to \mathbb{R}^2.$$

对 $\boldsymbol{q}$ 的两个分量再次求偏导：

$$\begin{aligned} J_{\boldsymbol{q}}(x_1, x_2) &= \begin{pmatrix} \dfrac{\partial(2x_1 + x_2)}{\partial x_1} & \dfrac{\partial(2x_1 + x_2)}{\partial x_2} \\ \dfrac{\partial(x_1 + 4x_2^3)}{\partial x_1} & \dfrac{\partial(x_1 + 4x_2^3)}{\partial x_2} \end{pmatrix} \\ &= \begin{pmatrix} 2 & 1 \\ 1 & 12x_2^2 \end{pmatrix}. \end{aligned}$$

这恰好是 ϕ 的海瑟矩阵：

$$H_\phi(x_1, x_2) = J_{\nabla\phi}(x_1, x_2) = \begin{pmatrix} 2 & 1 \\ 1 & 12x_2^2 \end{pmatrix}.$$

这里需要区分：

$$\phi'(\boldsymbol{x}) = \begin{pmatrix} 2x_1 + x_2 & x_1 + 4x_2^3 \end{pmatrix}$$

是标量函数的一阶导数，形状为 1×2；而 $J_{\nabla\phi}(\boldsymbol{x})$ 是梯度函数的一阶导数，形状为 2×2，其中包含的是 ϕ 的二阶偏导数. 对标量函数求一次导数得到行梯度；对列梯度作为向量值函数再求雅各比矩阵，得到海瑟矩阵.

我们下面用一个十分常用的实例来进一步展现上述结论的魅力：

例 1.3.7 考虑如下的 n 元函数：

$$f : \mathbb{R}^n \to \mathbb{R}; \quad f(\boldsymbol{x}) = \log(e^{x_1} + e^{x_2} + \cdots + e^{x_n}),$$

Yuan and Song

该函数通常称为“log-sum-exp 函数”，或“指数和对数函数”. 它的函数取值大约比 $\max\{x_1, x_2, \dots, x_n\}$ 稍大一些，而且具有 max 函数不具有的可求导的性质，因此可以视为求最大值函数的平滑版本. 我们下面先求它的偏导数：

对任意 $i = 1, 2, \dots, n$,

$$f_i'(\boldsymbol{x}) = \frac{e^{x_i}}{e^{x_1} + \cdots + e^{x_n}}.$$

我们惊奇地发现，这一函数的梯度 $\nabla f(\boldsymbol{x})$ 正是例1.3.5中的 Softmax 函数. 因此，我们无需进行下一步计算，便可直接断言函数 f 的海瑟矩阵即为 Softmax 函数的雅各比矩阵，即：

$$H_f(\boldsymbol{x}) = J_{\boldsymbol{s}}(\boldsymbol{x}) = \operatorname{Diag}(\nabla f(\boldsymbol{x})) - \nabla f(\boldsymbol{x}) \nabla f(\boldsymbol{x})^\top.$$

从这一例子中我们可以窥探出 Softmax 函数名称的由来，因为以 Softmax 为导数的原函数——log-sum-exp 函数的作用就是求一组数的平滑的、柔性的最大值. 但由于历史原因，其导数反而被称为 Softmax 函数. 事实上，在机器学习领域中，Softmax 函数确实相比 log-sum-exp 函数更加常用. 因为相比于最大值的具体取值，我们更关心取得最大值的那个分量是哪一个，即取出 Softmax 函数输出的概率分布中最大的那个分量，这一操作在机器学习模型决定最终输出时广为使用.

1.3.3 链式法则

我们在第1.1.4节中介绍了全微分的概念，其包含两个版本：其中一个为增量形式的可微性，它是一个比可导性更强一些的性质，主要用于理论分析；另一个为微分形式的表达式，主要用于不严谨的导数推导. 使用严谨的增量微分往往需要较为复杂的数学分析技巧来分析高阶余项的误差，而使用不严谨的微分形式通常能够大幅度简化推导过程，只要我们断言所研究的函数对象性质足够好，高阶余项的误差始终保持为小量即可. 下面我们介绍一个为链式法则推导作准备的引理，并提供使用微分形式的简洁的证明.

引理 1.3.8 (菱形求导法则) 设二元函数 $g(u, v) : \mathbb{R}^2 \to \mathbb{R}$, 而 $u(x), v(x)$ 均为关于 x 的一元函数，考虑复合一元函数 $f(x) := g(u(x), v(x))$, 其导数为：*[** 插图 **]*

$$f'(x) = g_1'\big(u(x), v(x)\big) u'(x) + g_2'\big(u(x), v(x)\big) v'(x).$$

证明. 我们记 $y = g(u(x), v(x))$, 则

$$\mathrm{d}y = \frac{\partial y}{\partial u}\mathrm{d}u + \frac{\partial y}{\partial v}\mathrm{d}v = \frac{\partial y}{\partial u}\frac{\mathrm{d}u}{\mathrm{d}x}\mathrm{d}x + \frac{\partial y}{\partial v}\frac{\mathrm{d}v}{\mathrm{d}x}\mathrm{d}x = \left(\frac{\partial y}{\partial u}\frac{\mathrm{d}u}{\mathrm{d}x} + \frac{\partial y}{\partial v}\frac{\mathrm{d}v}{\mathrm{d}x}\right)\mathrm{d}x$$

根据微分形式，我们可以倒推出函数 f 的导数的具体表达形式. ■

例 1.3.9 (一个输入通过两条路径影响输出) 设

$$u(t)=t^2,\qquad v(t)=e^t,\qquad h(u,v)=u^2+uv.$$

定义复合函数

$$f(t)=h(u(t),v(t)).$$

外层函数的偏导数为

$$\frac{\partial h}{\partial u}=2u+v,\qquad \frac{\partial h}{\partial v}=u.$$

两个内层函数的导数为

$$u'(t)=2t,\qquad v'(t)=e^t.$$

因为 t 同时通过 u 和 v 影响输出，所以两条路径的贡献需要相加：

$$\begin{aligned}f'(t)&=\left.\frac{\partial h}{\partial u}\right|_{(u(t),v(t))}u'(t)+\left.\frac{\partial h}{\partial v}\right|_{(u(t),v(t))}v'(t)\\&=(2t^2+e^t)\,2t+t^2e^t\\&=4t^3+(2t+t^2)e^t.\end{aligned}$$

这也可以写成矩阵乘法：

$$f'(t)=\begin{pmatrix}2t^2+e^t & t^2\end{pmatrix}\begin{pmatrix}2t\\ e^t\end{pmatrix}.$$

其中，外层函数的导数是 1×2 行向量，内层向量值函数的雅各比矩阵是 2×1 列向量.

直接代入还可得到

$$f(t)=t^4+t^2e^t,$$

对其求导，与上面的结果一致. 菱形求导法则中的“各条路径求导后相加”，正好对应矩阵乘法中的求和.

上述引理可以自然推广至除 u,v 外更多中间变量的情形，同时结合多元函数求不同分量偏导数的并行性、向量值函数不同维度求导的并行性，我们可以得出如下的有关多元向量值函数的链式法则：

定理 1.3.10 (链式法则) 考虑两个多元向量值函数

$$\boldsymbol{g}:\mathbb{R}^n\to\mathbb{R}^m,\boldsymbol{y}=\boldsymbol{g}(\boldsymbol{x});\quad \boldsymbol{h}:\mathbb{R}^m\to\mathbb{R}^l,\boldsymbol{z}=\boldsymbol{h}(\boldsymbol{y}),$$

设它们的雅各比矩阵分别为 $\boldsymbol{g}'(\boldsymbol{x}),\boldsymbol{h}'(\boldsymbol{y})$. 定义复合函数

$$\boldsymbol{f}:\mathbb{R}^n\to\mathbb{R}^l,\quad \boldsymbol{z}=\boldsymbol{f}(\boldsymbol{x})=\boldsymbol{h}\big(\boldsymbol{g}(\boldsymbol{x})\big),$$

Yuan and Song

则它的雅各比矩阵为：

$$\boldsymbol{f}'(\boldsymbol{x}) = \boldsymbol{h}'\big(\boldsymbol{g}(\boldsymbol{x})\big)\boldsymbol{g}'(\boldsymbol{x}).$$

证明. 对于向量值函数 $\boldsymbol{z} = \boldsymbol{f}(\boldsymbol{x})$, 考虑 $\boldsymbol{z}$ 的第 i 维对 $\boldsymbol{x}$ 的第 j 个分量求偏导数，则此时我们有：

$$z_i = h_i\big(g_1(x_1,\dots,x_j,\dots,x_n),\quad \dots\quad ,g_m(x_1,\dots,x_j,\dots,x_n)\big),$$

由于除 x_j 外的其余自变量分量均固定，因此此时 $g_1,\dots,g_m$ 即为关于 x_j 的一元函数，我们可以使用上述的菱形求导法则（引理1.3.8），得到：

$$\frac{\partial z_i}{\partial x_j} = \sum_{k=1}^{m}(h_i)'_k\big(g(\boldsymbol{x})\big)\cdot(g_k)'_j(\boldsymbol{x}).$$

将所有 $i = 1,\dots,l; j = 1,\dots,n$ 计算并拼合成 $l\times n$ 维矩阵即可得到最终结果. ■

例 1.3.11 (二维到三维，再从三维到二维) 定义

$$\boldsymbol{g}:\mathbb{R}^2\to\mathbb{R}^3,\qquad \boldsymbol{g}(x_1,x_2) = \begin{pmatrix} x_1+x_2\\ x_1x_2\\ x_1^2\end{pmatrix},$$

以及

$$\boldsymbol{h}:\mathbb{R}^3\to\mathbb{R}^2,\qquad \boldsymbol{h}(y_1,y_2,y_3) = \begin{pmatrix} y_1y_2\\ y_2+y_3^2\end{pmatrix}.$$

令 $\boldsymbol{f} = \boldsymbol{h}\circ\boldsymbol{g}$. 内层函数的雅各比矩阵为

$$J_{\boldsymbol{g}}(x_1,x_2) = \begin{pmatrix} 1 & 1\\ x_2 & x_1\\ 2x_1 & 0\end{pmatrix}\in\mathbb{R}^{3\times2}.$$

外层函数的雅各比矩阵为

$$J_{\boldsymbol{h}}(y_1,y_2,y_3) = \begin{pmatrix} y_2 & y_1 & 0\\ 0 & 1 & 2y_3\end{pmatrix}\in\mathbb{R}^{2\times3}.$$

应将外层雅各比矩阵在内层输出处求值：

$$J_{\boldsymbol{h}}(\boldsymbol{g}(\boldsymbol{x})) = \begin{pmatrix} x_1x_2 & x_1+x_2 & 0\\ 0 & 1 & 2x_1^2\end{pmatrix}.$$

Yuan and Song

根据链式法则，

$$\begin{aligned} J_{\boldsymbol{f}}(\boldsymbol{x}) &= J_{\boldsymbol{h}}(\boldsymbol{g}(\boldsymbol{x}))J_{\boldsymbol{g}}(\boldsymbol{x}) \\ &= \begin{pmatrix} 2x_1x_2 + x_2^2 & x_1^2 + 2x_1x_2 \\ x_2 + 4x_1^3 & x_1 \end{pmatrix}. \end{aligned}$$

例如，

$$J_{\boldsymbol{f}}(1,2) = \begin{pmatrix} 8 & 5 \\ 6 & 1 \end{pmatrix}.$$

直接展开复合函数，得到

$$\boldsymbol{f}(x_1,x_2) = \begin{pmatrix} x_1^2x_2 + x_1x_2^2 \\ x_1x_2 + x_1^4 \end{pmatrix},$$

逐分量求导也得到相同结果. 外层雅各比矩阵要在内层函数的输出处求值；外层矩阵在左、内层矩阵在右. 本例的维数关系是

$$(2\times 3)(3\times 2) = 2\times 2,$$

与复合函数从 $\mathbb{R}^2$ 到 $\mathbb{R}^2$ 的维数一致.

小贴士

上述链式法则针对向量值函数，然而也能退化至普通的多元函数情形，只需令因变量的维度为 1 即可. 需要注意的是，因变量维度为 1 的向量值函数的雅各比矩阵是其对应的多元函数的行梯度. 如果想要转化为列梯度，需要进行转置操作. 为了不易混淆，在涉及链式法则时，我们使用导数记号 $f'(\boldsymbol{x})$ 来表示行梯度，其与雅各比矩阵是相合的；而用算子记号 $\nabla f(\boldsymbol{x})$ 来表示列梯度.

在一元函数中，链式法则求导可以写为紧凑且优雅的形式

$$\frac{\mathrm{d}z}{\mathrm{d}x} = \frac{\mathrm{d}z}{\mathrm{d}y}\frac{\mathrm{d}y}{\mathrm{d}x},$$

或是微分形式

$$\mathrm{d}z = \frac{\mathrm{d}z}{\mathrm{d}y}\frac{\mathrm{d}y}{\mathrm{d}x}\mathrm{d}x.$$

在多元函数中，我们同样有相应的微分形式：

$$\mathrm{d}\boldsymbol{z} = \boldsymbol{h}'(\boldsymbol{y})\boldsymbol{g}'(\boldsymbol{x})\mathrm{d}\boldsymbol{x}.$$

然而，请不要写成导数形式

$$(\times)\quad \frac{\mathrm{d}\boldsymbol{z}}{\mathrm{d}\boldsymbol{x}} = \boldsymbol{h}'(\boldsymbol{y})\boldsymbol{g}'(\boldsymbol{x}),$$

也不要将雅各比矩阵写成 $(\times)\ \dfrac{\mathrm{d}\boldsymbol{y}}{\mathrm{d}\boldsymbol{x}}$. 这是因为，一元函数中微分具有形式不变性，可以直观理解为导数与微分直接相除的结果是一致的. 而在多元函数中，我们不存在向量间相除的定义. 上述的错误记号仅是形式表示，不具有实际意义.

我们下面用几个使用链式法则的实例来结束本节内容：

例 1.3.12 设矩阵 $A\in\mathbb{R}^{m\times n}$, 向量 $\boldsymbol{b}\in\mathbb{R}^m$, 多元函数 $f:\mathbb{R}^n\to\mathbb{R}$,

$$f(\boldsymbol{x})=\frac{1}{2}(A\boldsymbol{x}-\boldsymbol{b})^\top(A\boldsymbol{x}-\boldsymbol{b}),$$

试求其（列）梯度.

解：考虑外层函数 $h(\boldsymbol{y})=\frac{1}{2}\boldsymbol{y}^\top\boldsymbol{y}$ 与内层函数 $\boldsymbol{y}=\boldsymbol{g}(\boldsymbol{x})=A\boldsymbol{x}-\boldsymbol{b}$, 分别参考例1.1.4与例1.3.3, 我们求得 h 的行梯度为：$h'(\boldsymbol{y})=\boldsymbol{y}^\top$; $\boldsymbol{g}$ 的雅各比矩阵为 $\boldsymbol{g}'(\boldsymbol{x})=A$, 因此根据链式法则，我们可以求得函数 f 的行梯度为：

$$f'(\boldsymbol{x})=h'\big(\boldsymbol{g}(\boldsymbol{x})\big)\boldsymbol{g}'(\boldsymbol{x})=(A\boldsymbol{x}-\boldsymbol{b})^\top A.$$

转置为列梯度可得：

$$\nabla f(\boldsymbol{x})=A^\top(A\boldsymbol{x}-\boldsymbol{b}).$$

例 1.3.13 (非线性平方损失的列梯度) 定义残差向量

$$\boldsymbol{r}:\mathbb{R}^2\to\mathbb{R}^2,\qquad \boldsymbol{r}(\boldsymbol{x})=\begin{pmatrix}x_1^2+x_2-1\\ 2x_1-x_2^2\end{pmatrix}.$$

考虑平方损失

$$L(\boldsymbol{x})=\frac{1}{2}\boldsymbol{r}(\boldsymbol{x})^\top\boldsymbol{r}(\boldsymbol{x}).$$

将它分为外层函数 $h(\boldsymbol{y})=\frac{1}{2}\boldsymbol{y}^\top\boldsymbol{y}$ 和内层函数 $\boldsymbol{y}=\boldsymbol{r}(\boldsymbol{x})$. 外层函数的行梯度为

$$h'(\boldsymbol{y})=\boldsymbol{y}^\top.$$

内层函数的雅各比矩阵为

$$J_{\boldsymbol{r}}(\boldsymbol{x})=\begin{pmatrix}2x_1 & 1\\ 2 & -2x_2\end{pmatrix}.$$

因此，链式法则首先给出行梯度：

$$L'(\boldsymbol{x})=\boldsymbol{r}(\boldsymbol{x})^\top J_{\boldsymbol{r}}(\boldsymbol{x}).$$

转置后得到列梯度：

$$\nabla L(\boldsymbol{x})=J_{\boldsymbol{r}}(\boldsymbol{x})^\top\boldsymbol{r}(\boldsymbol{x}).$$

Yuan and Song

记两个残差分量为 r_1, r_2，则

$$\nabla L(\boldsymbol{x}) = \begin{pmatrix} 2x_1 & 2 \\ 1 & -2x_2 \end{pmatrix} \begin{pmatrix} r_1 \\ r_2 \end{pmatrix} = \begin{pmatrix} 2x_1 r_1 + 2r_2 \\ r_1 - 2x_2 r_2 \end{pmatrix}.$$

代入残差表达式：

$$\nabla L(\boldsymbol{x}) = \begin{pmatrix} 2x_1(x_1^2 + x_2 - 1) + 2(2x_1 - x_2^2) \\ (x_1^2 + x_2 - 1) - 2x_2(2x_1 - x_2^2) \end{pmatrix}.$$

例如，在 $\boldsymbol{x} = (1,1)^\top$ 处，

$$\boldsymbol{r}(\boldsymbol{x}) = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \qquad J_{\boldsymbol{r}}(\boldsymbol{x}) = \begin{pmatrix} 2 & 1 \\ 2 & -2 \end{pmatrix},$$

所以

$$\nabla L(1,1) = \begin{pmatrix} 2 & 2 \\ 1 & -2 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 4 \\ -1 \end{pmatrix}.$$

对标量复合函数求列梯度时，内层雅各比矩阵需要转置. 线性最小二乘公式

$$\nabla L(\boldsymbol{x}) = A^\top (A\boldsymbol{x} - \boldsymbol{b})$$

正是这里取 $\boldsymbol{r}(\boldsymbol{x}) = A\boldsymbol{x} - \boldsymbol{b}$ 的特殊情形.

例 1.3.14 设向量 $\boldsymbol{a} \in \mathbb{R}^n$, 常数 $c \in \mathbb{R}$, 多元函数 $f : \mathbb{R}^n \to \mathbb{R}$,

$$f(\boldsymbol{x}) = \ln\left(1 + e^{-c\boldsymbol{a}^\top \boldsymbol{x}}\right),$$

试求其（列）梯度.

解：考虑外层函数 $h(y) = \ln(1 + e^{-y})$ 与内层函数 $y = g(\boldsymbol{x}) = c\boldsymbol{a}^\top \boldsymbol{x}$. 外层函数 $h(y)$ 为一个一元函数，易求得其导数为：

$$h'(y) = \frac{-e^{-y}}{1 + e^{-y}} = \frac{-1}{1 + e^{y}}.$$

内层函数 $g(\boldsymbol{x})$ 为多元函数，通过分别计算偏导数易得到其行梯度为

$$g'(\boldsymbol{x}) = c\boldsymbol{a}^\top.$$

因此根据链式法则，我们可以得到函数 f 的行梯度为：

$$f'(\boldsymbol{x}) = h'\big(g(\boldsymbol{x})\big) g'(\boldsymbol{x}) = \frac{-c\boldsymbol{a}^\top}{1 + e^{y}},$$

转置为列梯度，并代入 y 可得：

$$\nabla f(\boldsymbol{x}) = \frac{-c}{1 + e^{c\boldsymbol{a}^\top \boldsymbol{x}}} \boldsymbol{a}.$$

Yuan and Song