1.4 实线性空间的内积与正定性

我们本节中仅考虑实数域的向量空间，即 $\mathbb{R}^n$, 这是因为实数域具有我们本节中将要介绍的正定性这一重要性质. 本节中我们考虑这样一个问题：先前有关线性空间的讨论大多围绕单个向量，而我们想要进一步探究任意两个向量之间的关系. 将上述想法抽象后，我们的目标是定义一个函数 $p(\boldsymbol{x},\boldsymbol{y})$, 它接受两个 $\mathbb{R}^n$ 空间中的向量 $\boldsymbol{x},\boldsymbol{y}$ 作为自变量，并输出一个 $\mathbb{R}$ 中的标量，而进一步，为了使上述函数的应用范围尽可能广泛，我们希望该函数具有下述的三个性质：

1. **对称性**：对于任意 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{R}^n$, 有 $p(\boldsymbol{x},\boldsymbol{y})=p(\boldsymbol{y},\boldsymbol{x})$.
2. **线性性**：对于任意 $\boldsymbol{x},\boldsymbol{y}_1,\boldsymbol{y}_2\in\mathbb{R}^n$, 任意 $c_1,c_2\in\mathbb{R}$, 有
$$p(\boldsymbol{x},c_1\boldsymbol{y}_1+c_2\boldsymbol{y}_2)=c_1p(\boldsymbol{x},\boldsymbol{y}_1)+c_2p(\boldsymbol{x},\boldsymbol{y}_2).$$
3. **正定性**：对于任意 $\boldsymbol{x}\in\mathbb{R}^n$, 有 $p(\boldsymbol{x},\boldsymbol{x})\geq 0$, 且 $p(\boldsymbol{x},\boldsymbol{x})=0\Leftrightarrow\boldsymbol{x}=\boldsymbol{0}$.

第一条与第二条性质结合可以保证该函数对于左右两个变量以及任意多个线性组合均保持线性，我们一般称这样的函数为**双线性函数**. 第三条性质即正定性是实数域 $\mathbb{R}$ 中的特有性质，它可以确保当线性空间退化为一维时，上述函数能够自然退化为取值恒为非负数的一元函数 $f(x)=x^2$.

本节的后续小节将逐步揭开这一双线性函数的神秘面纱.

1.4.1 矩阵的合同及谱定理

得益于双线性函数的性质，对于任意给定 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{R}^n$, 我们可以使用线性空间中的一个基 $\boldsymbol{e}_1,\ldots,\boldsymbol{e}_n$ 来对它们进行表示，并代入双线性函数 $p(\cdot,\cdot)$ 进行计算. 设 $\boldsymbol{x},\boldsymbol{y}$ 在上述基下的坐标表示分别为 $\boldsymbol{u},\boldsymbol{v}$, 即我们有 $\boldsymbol{x}=(\boldsymbol{e}_1,\ldots,\boldsymbol{e}_n)\boldsymbol{u}$, $\boldsymbol{y}=(\boldsymbol{e}_1,\ldots,\boldsymbol{e}_n)\boldsymbol{v}$, 我们有：

$$p(\boldsymbol{x},\boldsymbol{y})=\sum_{i=1}^{n}\sum_{j=1}^{n}u_iv_jp(\boldsymbol{e}_i,\boldsymbol{e}_j)=\boldsymbol{u}^{\top}\begin{pmatrix}p(\boldsymbol{e}_1,\boldsymbol{e}_1) & \cdots & p(\boldsymbol{e}_1,\boldsymbol{e}_n)\\ \vdots & & \vdots\\ p(\boldsymbol{e}_n,\boldsymbol{e}_1) & \cdots & p(\boldsymbol{e}_n,\boldsymbol{e}_n)\end{pmatrix}\boldsymbol{v}:=\boldsymbol{u}^{\top}M\boldsymbol{v}.$$

因此，和线性映射类似，我们只需将矩阵 M 的性质研究清楚，便可得知有关双线性函数 $p(\cdot,\cdot)$ 的全部信息. 我们称该矩阵为双线性函数 $p(\cdot,\cdot)$ 在基 $\boldsymbol{e}_1,\ldots,\boldsymbol{e}_n$ 下的度量矩阵，我们注意到该矩阵是一个实对称矩阵. 根据上述的结论，如果函数 $p(\cdot,\cdot)$ 满足对称性和线性性，那么选定一个基之后，它一定可以表示为 $\boldsymbol{u}^{\top}M\boldsymbol{v}$ 的形式，我们通常称 $\boldsymbol{u}^{\top}M\boldsymbol{v}$ 这一形式为一个**二次型**（quadratic form）. 然而，这一形式尚且不能保证第三条性质，即

正定性，譬如我们取 M 为零矩阵，则很容易找到非零向量 $\boldsymbol{x}$ 使得 $p(\boldsymbol{x},\boldsymbol{x})=0$.

我们下面依然借鉴线性映射的研究思路，考虑当基进行变换后，相应的 M 矩阵之间有怎样的关系. 对于同一个双线性函数 $p(\cdot,\cdot)$, 假如我们已有一个基 $\boldsymbol{e}_1,\dots,\boldsymbol{e}_n$ 及对应的度量矩阵 M, 下面我们考虑另一个基 $(\boldsymbol{e}'_1,\dots,\boldsymbol{e}'_n)$, 它与原先基的关系为

$$(\boldsymbol{e}'_1,\dots,\boldsymbol{e}'_n)=(\boldsymbol{e}_1,\dots,\boldsymbol{e}_n)P,$$

其中 P 为可逆矩阵. 设 $\boldsymbol{x},\boldsymbol{y}$ 在新的基下的表示为 $\boldsymbol{u}',\boldsymbol{v}'$, 则

$$\boldsymbol{x}=(\boldsymbol{e}_1,\dots,\boldsymbol{e}_n)\boldsymbol{u}=(\boldsymbol{e}'_1,\dots,\boldsymbol{e}'_n)\boldsymbol{u}'=(\boldsymbol{e},\dots,\boldsymbol{e}_n)P\boldsymbol{u}',$$

从而 $\boldsymbol{u}=P\boldsymbol{u}'$, 同理 $\boldsymbol{v}=P\boldsymbol{v}'$. 从而

$$p(\boldsymbol{x},\boldsymbol{y})=\boldsymbol{u}^{\top}M\boldsymbol{v}=(\boldsymbol{u}')^{\top}P^{\top}MP\boldsymbol{v}',$$

由此我们可以得出，$P^{\top}MP$ 即为新的基 $\boldsymbol{e}_1,\dots,\boldsymbol{e}_n$ 下的度量矩阵.

事实上，限定在实对称矩阵范围内，形式 $P^{\top}MP$ 代表了矩阵之间的另一种重要关系——合同关系（congruence），其定义如下：

定义 1.4.1 (合同矩阵) 给定实对称矩阵 $M\in\mathbb{R}^{n\times n}$, 对于另一形状相同的实对称矩阵 $M'\in\mathbb{R}^{n\times n}$, 若存在可逆矩阵 $P\in\mathbb{R}^{n\times n}$ 使得

$$M'=P^{\top}MP,$$

则称矩阵 M' 与矩阵 M 合同.

同样根据矩阵合同的定义，我们不难验证其满足自反性、对称性与传递性.

例 1.4.2 (合同换基保持双线性函数的取值) 在 $\mathbb{R}^2$ 的标准基下，考虑双线性函数

$$p(\boldsymbol{x},\boldsymbol{y})=\boldsymbol{x}^{\top}\boldsymbol{y},\qquad M=I_2.$$

将基换为 $\boldsymbol{e}'_1=2\boldsymbol{e}_1,\ \boldsymbol{e}'_2=3\boldsymbol{e}_2$，过渡矩阵及新的度量矩阵分别为

$$P=\begin{pmatrix}2&0\\0&3\end{pmatrix},\qquad M'=P^{\top}MP=\begin{pmatrix}4&0\\0&9\end{pmatrix}.$$

取 $\boldsymbol{x}=(2,3)^{\top},\ \boldsymbol{y}=(4,-3)^{\top}$，它们在新基下的坐标为

$$\boldsymbol{u}'=P^{-1}\boldsymbol{x}=(1,1)^{\top},\qquad \boldsymbol{v}'=P^{-1}\boldsymbol{y}=(2,-1)^{\top}.$$

在原坐标下，$p(\boldsymbol{x},\boldsymbol{y})=2\cdot4+3\cdot(-3)=-1$；在新坐标下，

$$(\boldsymbol{u}')^{\top}M'\boldsymbol{v}'=4\cdot1\cdot2+9\cdot1\cdot(-1)=-1.$$

因此，换基时坐标和度量矩阵必须一起改变，双线性函数的取值才能保持不变. 此外，

M 的特征值为 $1,1$，而 M' 的特征值为 $4,9$，所以二者合同但不相似. 一般的合同变换并不保持特征值.

对于矩阵合同之间的研究，我们没有像相似关系中的特征值、特征向量等工具. 但是，我们可以通过某一类特殊的矩阵——正交矩阵，将合同关系转化为我们更为熟悉的相似关系. 由于正交矩阵 Q 满足 $Q^{-1}=Q^{\top}$, 我们可以将合同关系 $Q^{\top}MQ$ 转化为相似关系 $Q^{-1}MQ$, 从而使用相似矩阵的工具研究合同的相关性质.

我们知道，对于一般的方形矩阵，其不一定能够相似于对角矩阵. 然而，对于实对称矩阵，我们可以证明其一定能够相似于对角矩阵，且相似关系中使用的可逆矩阵一定可以化为正交矩阵，我们通常将上述性质简称为**实对称矩阵一定可以正交相似于对角矩阵**. 这是一个非常强的性质，在线性代数中我们将其总结为一个重要的定理，即谱定理（spectral theorem），或称主轴定理（principal axis theorem），意为该定理将实对称矩阵相似为对角矩阵上的一串光谱值（特征值），或者将实对称矩阵理解为在某个主坐标轴（特征向量构成的坐标轴）上的缩放变换. 我们下面正式叙述谱定理的定义：

定理 1.4.3 (谱定理) 对于一个 $n\times n$ 的实对称矩阵 M，一定存在一个正交矩阵 Q 与一个实对角矩阵 Λ, 使得

$$M=Q\Lambda Q^{\top}=(\boldsymbol{q}_1,\dots,\boldsymbol{q}_n)\begin{pmatrix}\lambda_1 & & \\ & \ddots & \\ & & \lambda_n\end{pmatrix}\begin{pmatrix}\boldsymbol{q}_1^{\top}\\ \vdots \\ \boldsymbol{q}_n^{\top}\end{pmatrix}=\sum_{i=1}^{n}\lambda_i\boldsymbol{q}_i\boldsymbol{q}_i^{\top},$$

其中 $\lambda_1,\dots,\lambda_n$ 为矩阵 M 的 n 个特征值（可能有重复），$\boldsymbol{q}_1,\dots,\boldsymbol{q}_n$ 分别为特征值 $\lambda_1,\dots,\lambda_n$ 对应的特征向量，且它们两两线性无关.

小贴士

实对称矩阵可以正交相似于对角矩阵，但并不意味着其只能正交相似于对角矩阵. 从特征向量的角度理解，我们可以对特征向量数乘，得到的依然为特征向量；如果某个特征值有多个线性无关的特征向量，则对它们线性组合得到的依然是特征向量. 我们用新的特征向量完全可以构建出非正交的用于相似关系的矩阵.

例 1.4.4 (用正交换元消去二次型的交叉项) 考虑实对称矩阵及相应的二次型

$$M=\begin{pmatrix}5 & 2\\ 2 & 2\end{pmatrix},\qquad q(\boldsymbol{x})=\boldsymbol{x}^{\top}M\boldsymbol{x}=5x_1^2+4x_1x_2+2x_2^2.$$

其特征多项式为

$$|\lambda I - M| = (\lambda - 5)(\lambda - 2) - 4 = (\lambda - 6)(\lambda - 1).$$

对应于 $6, 1$ 的单位特征向量可分别取为

$$\boldsymbol{q}_1 = \frac{1}{\sqrt{5}}(2, 1)^\top, \qquad \boldsymbol{q}_2 = \frac{1}{\sqrt{5}}(-1, 2)^\top.$$

它们满足 $\boldsymbol{q}_i^\top \boldsymbol{q}_i = 1$ 及 $\boldsymbol{q}_1^\top \boldsymbol{q}_2 = 0$. 因此

$$Q = (\boldsymbol{q}_1, \boldsymbol{q}_2) = \frac{1}{\sqrt{5}} \begin{pmatrix} 2 & -1 \\ 1 & 2 \end{pmatrix}, \qquad Q^\top M Q = \begin{pmatrix} 6 & 0 \\ 0 & 1 \end{pmatrix}.$$

令 $\boldsymbol{x} = Q\boldsymbol{z}$，则

$$q(\boldsymbol{x}) = \boldsymbol{z}^\top Q^\top M Q \boldsymbol{z} = 6z_1^2 + z_2^2.$$

例如，$\boldsymbol{x} = (1, 0)^\top$ 对应 $\boldsymbol{z} = (2, -1)^\top/\sqrt{5}$，代入后得到 $6 \cdot 4/5 + 1/5 = 5$，与原式一致. 谱定理在这里给出了一个具体的正交换元，使二次型的交叉项消失.

1.4.2* 谱定理的证明

在本小节中，我们将详细证明谱定理（定理1.4.3），谱定理的证明过程不要求掌握，但读者需要学会使用谱定理.

证明. **第一步：证明实对称矩阵的特征值全为实数.** 我们引入如下的两个操作：

- 矩阵或向量共轭：$\bar{A}$ 或 $\bar{\boldsymbol{v}}$, 即对矩阵或向量中每个元素取共轭复数.
- 矩阵的共轭转置：A^H, 即对矩阵 A 先求共轭再求转置（或先转置再共轭，结果相同）.

设 λ 为矩阵 M 的一个特征值，$\boldsymbol{x}$ 是它的一个特征向量，则 $M\boldsymbol{x} = \lambda\boldsymbol{x}$. 对等式两边取共轭转置，则

$$\boldsymbol{x}^H M^H = (M\boldsymbol{x})^H = (\lambda\boldsymbol{x})^H = \bar{\lambda}\boldsymbol{x}^H.$$

因为 M 为实对称矩阵，所以 $M^H = \bar{M}^\top = \bar{M} = M$, 从而有 $\boldsymbol{x}^H M = \bar{\lambda}\boldsymbol{x}^H$.

现在我们对 $M\boldsymbol{x} = \lambda\boldsymbol{x}$ 左乘 $\boldsymbol{x}^H$, 对 $\boldsymbol{x}^H M = \bar{\lambda}\boldsymbol{x}^H$ 右乘 $\boldsymbol{x}$ 得到：

$$\boldsymbol{x}^H M\boldsymbol{x} = \lambda\boldsymbol{x}^H\boldsymbol{x}; \quad \boldsymbol{x}^H M\boldsymbol{x} = \bar{\lambda}\boldsymbol{x}^H\boldsymbol{x}.$$

由于特征向量为非零向量，$\boldsymbol{x}^H\boldsymbol{x} = \sum_{i=1}^n \bar{x}_i x_i > 0$（一个复数与其共轭的乘积为其模长，具有非负性）. 从而我们可以得出 $\lambda = \bar{\lambda}$, 即 λ 为实数，从而实对称矩阵 M 的任何特征值均为实数.

Kun and Song

第二步：证明实对称矩阵分属不同特征值的特征向量必正交. 所谓两向量 $\boldsymbol{x},\boldsymbol{y}$ 的正交性即为 $\boldsymbol{x}^\top\boldsymbol{y}=0$. （我们在此处仅使用形式定义，正交性含义将会在本节最后提及）

设 $M\boldsymbol{x}=\lambda\boldsymbol{x}, M\boldsymbol{y}=\mu\boldsymbol{y}$, 且 $\lambda\neq\mu$. 对于 $M\boldsymbol{x}=\lambda\boldsymbol{x}$, 取转置得 $\boldsymbol{x}^\top M=\lambda\boldsymbol{x}^\top$, 右乘 $\boldsymbol{y}$ 得到

$$\boldsymbol{x}^\top M\boldsymbol{y}=\lambda\boldsymbol{x}^\top\boldsymbol{y},$$

类似地，我们可以得到 $\boldsymbol{x}^\top M\boldsymbol{y}=\mu\boldsymbol{x}^\top\boldsymbol{y}$, 从而可以得到

$$(\mu-\lambda)\boldsymbol{x}^\top\boldsymbol{y}=0.$$

由于 $\lambda\neq\mu$, 则必有 $\boldsymbol{x}^\top\boldsymbol{y}=0$.

第三步：使用数学归纳法，考虑归纳假设. 对于一维的情形，$M=(m)$ 已是对角矩阵，且取 $Q=(1)$ 即位正交矩阵，满足定理结论. 现假设定理对 $n-1$ 维成立，考虑 n 维情形下的矩阵 M 是否同样满足定理.

第四步：归纳推理. 根据第一步的结论，矩阵 M 一定有一个实特征值 λ_1, 取它的一个单位向量 $\boldsymbol{v}_1$, 即 $\boldsymbol{v}_1^\top\boldsymbol{v}_1=1$, 以 $\boldsymbol{v}_1$ 为基础，我们可以扩充出一个 $\mathbb{R}^n$ 中的单位正交基 $\{\boldsymbol{v}_1,\boldsymbol{v}_2,\ldots,\boldsymbol{v}_n\}$（可以任意选取一个基并进行施密特正交化）. 则我们有 $V_1:=(\boldsymbol{v}_1,\ldots,\boldsymbol{v}_n)$ 为一个正交矩阵.

现考虑 $\boldsymbol{v}_1$ 与其他向量关于 M 的双线性函数 $\boldsymbol{v}_1^\top M\boldsymbol{v}_i$. 当 $i=1$ 时，$\boldsymbol{v}_1^\top M\boldsymbol{v}_1=\lambda_1\boldsymbol{v}_1^\top\boldsymbol{v}_1=\lambda_1$; 当 $i\neq1$ 时，由于 V_1 中向量两两正交，$\boldsymbol{v}_1^\top M\boldsymbol{v}_i=\lambda\boldsymbol{v}_1\boldsymbol{v}_i=0$. 从而

$$V_1^\top MV_1=\begin{pmatrix}\boldsymbol{v}_1^\top\\ \vdots\\ \boldsymbol{v}_n^\top\end{pmatrix}M\begin{pmatrix}\boldsymbol{v}_1,\ldots,\boldsymbol{v}_n\end{pmatrix}=\begin{pmatrix}\boldsymbol{v}_1^\top M\boldsymbol{v}_1 & \cdots & \boldsymbol{v}_1^\top M\boldsymbol{v}_n\\ \vdots & & \vdots\\ \boldsymbol{v}_n^\top M\boldsymbol{v}_1 & \cdots & \boldsymbol{v}_n^\top M\boldsymbol{v}_n\end{pmatrix}=\begin{pmatrix}\lambda_1 & \mathbf{0}^\top\\ \mathbf{0} & \tilde{M}\end{pmatrix},$$

其中 $\mathbf{0}$ 为 $n-1$ 维零向量，$\tilde{M}$ 为 $(n-1)\times(n-1)$ 维矩阵. 由于双线性函数的对称性，我们不难得出 $V_1^\top MV_1$ 为实对称矩阵，从而 $\tilde{M}$ 也为实对称矩阵.

第五步：使用归纳假设. 根据归纳假设，对于矩阵 $\tilde{M}$, 存在正交矩阵 P_{n-1} 和对角矩阵 D_{n-1} 使得

$$\tilde{M}=P_{n-1}D_{n-1}P_{n-1}^\top.$$

Yuan and Cong

我们另取 $V_2 = \begin{pmatrix} 1 & \mathbf{0}^\top \\ \mathbf{0} & P_{n-1} \end{pmatrix}$, 易验证 V_2 也为正交矩阵. 从而

$$\begin{aligned} M &= V_1 \begin{pmatrix} \lambda_1 & \mathbf{0}^\top \\ \mathbf{0} & \tilde{M} \end{pmatrix} V_1^\top = V_1 \begin{pmatrix} 1 & \mathbf{0}^\top \\ \mathbf{0} & P_{n-1} \end{pmatrix} \begin{pmatrix} \lambda_1 & \mathbf{0}^\top \\ \mathbf{0} & D_{n-1} \end{pmatrix} \begin{pmatrix} 1 & \mathbf{0}^\top \\ \mathbf{0} P_{n-1}^\top & \end{pmatrix} V_1^\top \\ &= (V_1 V_2) \begin{pmatrix} \lambda_1 & \mathbf{0}^\top \\ \mathbf{0} & D_{n-1} \end{pmatrix} (V_1 V_2)^\top. \end{aligned}$$

从而有正交矩阵 $Q = V_1 V_2$ 及实对角矩阵 $\Lambda = \begin{pmatrix} \lambda_1 & \mathbf{0}^\top \\ \mathbf{0} & D_{n-1} \end{pmatrix}$ 满足 $M = Q\Lambda Q^\top$. 归纳步成立. 从而定理对于任意 n 阶实对称矩阵均成立. ■

1.4.3 正定矩阵

以谱定理为基础，我们可以将任意一个实对称矩阵正交相似（即正交合同）为对角矩阵. 然而，在合同的概念下，对角矩阵依然包含一部分的冗余信息. 假如我们现在有一个对角矩阵 $\Lambda = \text{Diag}(\lambda_1, \ldots, \lambda_n)$, 我们可以另取一个可逆的对角矩阵 $P = \text{Diag}(p_1, \ldots, p_n), p_i \neq 0, \forall i = 1, \ldots, n$, 得到一个新的合同后的矩阵：

$$P^\top \Lambda P = \text{Diag}(p_1^2 \lambda_1, \ldots, p_n^2 \lambda_n).$$

得益于 $p_1^2 > 0$ 取值的任意性, 它可以将任意正数变为 $+1$, 任意负数变为 -1, 0 保持 0. 通过选取合适的矩阵 P, 我们可以将对角矩阵进一步合同变换为对角元只为

$$\{+1, -1, 0\}$$

其中之一的对角矩阵. 我们称只包含以上三种元素的对角矩阵为所有与之合同的实对称矩阵的**规范形**.

规范形中 $+1, -1, 0$ 元素的个数可以反映出实对称矩阵在合同意义下的所有信息. 进一步，如果对一个实对称矩阵 M 取负得到 $-M$，则其规范形中的 $+1, -1$ 元素也将互换. 因此综合来看，我们感兴趣的实对称矩阵可以分为如下三类：

- **正定矩阵**（positive definite matrix）：规范形中所有元素均为 $+1$.
- **半正定矩阵**（positive semi-definite matrix）：规范形中元素为 $+1$ 或 0, 不存在 -1.
- **不定矩阵**（indefinite matrix）：规范形中元素同时存在 $+1$ 和 -1.

在上述三种类型的实对称矩阵中，我们最感兴趣的是第一种，即**正定矩阵**. 正定矩阵具有许多优良的性质，我们在此简要列举正定矩阵 $M \in \mathbb{R}^{n \times n}$ 的若干基本的及与机器学

YuanJinSong

习密切相关的性质：

1. 所有特征值严格为正，即 $\lambda_1, \ldots, \lambda_n > 0$. 这可由上述关于规范形的讨论直接得出.
2. 存在可逆矩阵 $C \in \mathbb{R}^{n\times n}$ 使得
$$M = CC^\top.$$
这是因为 M 的合同规范形为对角元全为 1 的对角矩阵，即单位阵 I, 从而我们有可逆矩阵 C 及合同变换 $I = C^\top MC$.
3. 行列式 $|M| > 0$. 这是因为其可以正交对角化为对角元全为正数的对角矩阵，而相似矩阵具有相同的行列式值.
4. 正定性：对于任意实数向量 $\boldsymbol{x} \in \mathbb{R}^n$, 有：
$$\boldsymbol{x}^\top M\boldsymbol{x} \geq 0,$$
且不等式取等号当且仅当 $\boldsymbol{x} = \boldsymbol{0}$.
5. 可开方性：由于 $M = Q\Lambda Q^\top$, 且 $\Lambda = \mathrm{Diag}(\lambda_1, \ldots, \lambda_n)$ 中所有元素均为正，因此我们可以定义 $M^{1/2} := Q\Lambda^{1/2}Q^\top$, 其中 $\Lambda := \mathrm{Diag}(\lambda_1^{1/2}, \ldots, \lambda_n^{1/2})$, 我们不难验证，$M^{1/2}M^{1/2} = M$.

我们简要证明一下第四条性质，即正定性. 这也是正定矩阵最重要的一条性质.

证明. 由第二条性质可得，存在可逆矩阵 C 使得 $M = CC^\top$, 从而
$$\boldsymbol{x}^\top M\boldsymbol{x} = \boldsymbol{x}^\top CC^\top\boldsymbol{x} = (C^\top\boldsymbol{x})^\top(C^\top\boldsymbol{x}),$$
记 $\boldsymbol{y} = C^\top\boldsymbol{x}$, 则
$$\boldsymbol{y}^\top\boldsymbol{y} = \sum_{i=1}^{n} y_i^2 \geq 0.$$
且等号取等时当且仅当 $\boldsymbol{y} = \boldsymbol{0}$. 由于 C 为可逆矩阵，$\boldsymbol{x} = (C^\top)^{-1}\boldsymbol{y} = \boldsymbol{0}$. ■

例 1.4.5 (含参数矩阵的正定性与边界情形) 考虑实对称矩阵
$$M_t = \begin{pmatrix} 2 & t \\ t & 3 \end{pmatrix}, \qquad t \in \mathbb{R}.$$
对任意 $\boldsymbol{x} = (x_1, x_2)^\top$，配方得到
$$\boldsymbol{x}^\top M_t\boldsymbol{x} = 2x_1^2 + 2tx_1x_2 + 3x_2^2 = 2\left(x_1 + \frac{t}{2}x_2\right)^2 + \left(3 - \frac{t^2}{2}\right)x_2^2.$$
当 $|t| < \sqrt{6}$ 时，两个平方项的系数均为正，且两项同时为零只可能发生在 $\boldsymbol{x} = \boldsymbol{0}$. 因此 M_t 正定.

当 $|t| = \sqrt{6}$ 时，二次型仍然非负，但非零向量 $(-t/2, 1)^\top$ 使其取零，所以 M_t 半正

Yuan and Song

定而非正定. 当 $|t|>\sqrt{6}$ 时，取 $(1,0)^\top$ 使二次型取正值 2，取 $(-t/2,1)^\top$ 使其取负值 $3-t^2/2$，所以 M_t 不定.

这里使用二次型判断正定性的依据仍是谱定理：在单位特征向量上，二次型的值等于相应特征值. 这个例子也说明，两个对角元都为正并不足以保证矩阵正定.

例 1.4.6 (正定矩阵的平方根不是逐元素开方) 考虑

$$M=\begin{pmatrix}5&4\\4&5\end{pmatrix},\qquad Q=\frac{1}{\sqrt{2}}\begin{pmatrix}1&1\\1&-1\end{pmatrix}.$$

直接计算得 $Q^\top MQ=\mathrm{Diag}(9,1)$，所以 M 正定. 根据正定矩阵可开方的性质，

$$M^{1/2}=Q\,\mathrm{Diag}(3,1)Q^\top=\begin{pmatrix}2&1\\1&2\end{pmatrix}.$$

验证可得

$$\begin{pmatrix}2&1\\1&2\end{pmatrix}\begin{pmatrix}2&1\\1&2\end{pmatrix}=\begin{pmatrix}5&4\\4&5\end{pmatrix}=M.$$

相反，若把 M 的各个元素分别开方，得到 $B=\begin{pmatrix}\sqrt{5}&2\\2&\sqrt{5}\end{pmatrix}$，则

$$B^2=\begin{pmatrix}9&4\sqrt{5}\\4\sqrt{5}&9\end{pmatrix}\neq M.$$

矩阵平方根要求满足矩阵乘法下的 $M^{1/2}M^{1/2}=M$；谱分解中开方的是特征值.

1.4.4 内积与度量

在上一小节中，我们介绍了正定矩阵，并提及了其最重要的一条性质——正定性. 回顾我们本节最初的目标，我们要寻找一个满足正定性的双线性函数. 结合正定矩阵的正定性性质以及矩阵合同的含义，我们得出如下结论：**欲使一个双线性函数满足正定性，只需使其在任何一个基下的度量矩阵为正定矩阵即可.**

因此，从理论上来讲，任给定一个正定矩阵 M, 函数 $p(\boldsymbol{x},\boldsymbol{y}):=\boldsymbol{x}^\top M\boldsymbol{y}$ 均为一个满足正定性的双线性函数，我们称其为实数向量空间的一个广义内积. 进一步，由于通过坐标变换可以将度量矩阵做相应的合同变换，我们一定可以找到一个合适的基，使得该双线性函数对应的度量矩阵为单位阵，那么此时坐标表示后的向量 $\boldsymbol{u},\boldsymbol{v}$ 在该双线性函数下的定义即为 $p'(\boldsymbol{u},\boldsymbol{v})=\boldsymbol{u}^\top\boldsymbol{v}$. 不失一般性，我们可以取上述最简单的 $M=I$ 的形式作为一种标准的形式，将其定义为标准内积，简称内积（inner product）.

Yuan and Song

定义 1.4.7 (内积) 对于 n 维实数向量空间，定义内积为其上的一个双线性函数

$$f(\boldsymbol{x},\boldsymbol{y})=\boldsymbol{x}^{\top}\boldsymbol{y},\quad \boldsymbol{x},\boldsymbol{y}\in\mathbb{R}^n.$$

内积也可记为 $\langle\boldsymbol{x},\boldsymbol{y}\rangle$.

其实，我们在正式引入内积的概念之前，已经在大量使用 $\boldsymbol{x}^{\top}\boldsymbol{y}$ 的形式了. 而本节的推导进一步告诉我们，所谓内积即为实数向量空间中一个满足正定性的双线性函数. 其中双线性性使得内积操作可以与其他多种线性操作兼容，而正定性则为在实数向量空间中引入**度量**提供了基础.

所谓度量，即衡量线性空间中一个向量的“长度”，它是一个以向量为自变量，非负数为因变量的函数，得益于内积的正定性，我们可以引入模（长）（module）的概念作为实数向量空间的度量：

定义 1.4.8 (模) 给定 $\boldsymbol{x}\in\mathbb{R}^n$, 定义其模为

$$\|\boldsymbol{x}\|:=\sqrt{\langle\boldsymbol{x},\boldsymbol{x}\rangle}.$$

有了模长的定义，两向量 $\boldsymbol{x},\boldsymbol{y}$ 间的距离可以直接表示为二者之差的模 $\|\boldsymbol{x}-\boldsymbol{y}\|$.

内积与模之间有一个重要关系，即柯西-施瓦茨不等式（Cauchy-Schwarz Inequality）：

定理 1.4.9 (柯西-施瓦茨不等式) 给定 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{R}^n$, 我们有不等式：

$$|\langle\boldsymbol{x},\boldsymbol{y}\rangle|\le\|\boldsymbol{x}\|\|\boldsymbol{y}\|,$$

不等式取等当且仅当 $\boldsymbol{x},\boldsymbol{y}$ 共线，即存在 $c\in\mathbb{R}$ 使得 $\boldsymbol{x}=c\boldsymbol{y}$ 或 $\boldsymbol{y}=c\boldsymbol{x}$.

柯西-施瓦茨不等式有许多种证明方式，[** 附录 **] 中给出了其中一种证明.

在柯西-施瓦茨不等式的基础上，我们有 $-1\le\dfrac{\langle\boldsymbol{x},\boldsymbol{y}\rangle}{\|\boldsymbol{x}\|\|\boldsymbol{y}\|}\le 1$, 从而我们可以定义两向量的夹角余弦为

$$\cos\theta:=\frac{\langle\boldsymbol{x},\boldsymbol{y}\rangle}{\|\boldsymbol{x}\|\|\boldsymbol{y}\|},$$

其中 $\theta\in[0,\pi]$ 定义为两向量的夹角.

两向量的夹角可以有多种情况，而其中一种情况我们最感兴趣，即夹角为 $\pi/2$ 的情况. 此时从几何角度来看，两向量是相互垂直的；而从代数角度来看，$\cos\theta=0\Leftrightarrow\langle\boldsymbol{x},\boldsymbol{y}\rangle=0$, 我们用正交性（orthogonality）来描述这一性质：

定义 1.4.10 (正交性) 称向量 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{R}^n$ 相互正交，若其满足 $\langle\boldsymbol{x},\boldsymbol{y}\rangle=0$.

例 1.4.11 (利用正交性寻找直线上最近的点) 给定 $\boldsymbol{x}=(2,0,1)^{\top}$，考虑由 $\boldsymbol{u}=(1,1,0)^{\top}$ 张成的直线，其上的点均可写为 $t\boldsymbol{u}$. 我们希望找到与 $\boldsymbol{x}$ 距离最近的一个点. 先要求误差

Yuan and Song

向量与直线方向正交：

$$\langle \boldsymbol{x} - t\boldsymbol{u}, \boldsymbol{u} \rangle = \langle \boldsymbol{x}, \boldsymbol{u} \rangle - t\langle \boldsymbol{u}, \boldsymbol{u} \rangle = 2 - 2t = 0.$$

因此 $t = 1$，对应的点为 $\boldsymbol{p} = (1, 1, 0)^\top$，误差为 $\boldsymbol{r} = \boldsymbol{x} - \boldsymbol{p} = (1, -1, 1)^\top$. 为验证它确实最近，直接计算任意 t 下的距离平方：

$$\|\boldsymbol{x} - t\boldsymbol{u}\|^2 = (2 - t)^2 + t^2 + 1 = 2(t - 1)^2 + 3 \geq 3.$$

等号恰在 $t = 1$ 时成立，最短距离为 $\sqrt{3}$. 这说明，正交性不仅描述夹角，也可以用来确定投影点并解释最短距离.

小贴士

模（长度）、距离、夹角、正交性（垂直）这些概念原本在几何学中均为非常直观的概念. 然而，有了内积的定义，上述的概念均可通过严格的推导得出. 我们一般称配备了标准内积的实数向量空间为欧几里得空间（Euclidean space），简称欧氏空间，它是直观的空间几何的数学抽象与严格化.

我们最后来考虑一下正交矩阵的性质. 在此前，我们仅通过形式 $Q^\top = Q^{-1}$ 来判定一个矩阵为正交矩阵，却未阐释其背后的原理. 事实上，如果我们将正交矩阵 Q 分解为 n 个列向量 $\boldsymbol{q}_1, \ldots, \boldsymbol{q}_n$, 则

$$\boldsymbol{Q}^\top \boldsymbol{Q} = \begin{pmatrix} \boldsymbol{q}_1^\top \\ \vdots \\ \boldsymbol{q}_n^\top \end{pmatrix} (\boldsymbol{q}_1, \ldots, \boldsymbol{q}_n) = \begin{pmatrix} \boldsymbol{q}_1^\top \boldsymbol{q}_1 & \cdots & \boldsymbol{q}_1^\top \boldsymbol{q}_n \\ \vdots & & \vdots \\ \boldsymbol{q}_n^\top \boldsymbol{q}_1 & \cdots & \boldsymbol{q}_n^\top \boldsymbol{q}_n \end{pmatrix} = I_n.$$

从而有

$$\boldsymbol{q}_i^\top \boldsymbol{q}_j = \begin{cases} 1, & i = j; \\ 0, & i \neq j. \end{cases}$$

因此，如果将正交矩阵分解为 n 个列向量，则这 n 个列向量构成了 $\mathbb{R}^n$ 中的一个单位正交基. 将正交矩阵分解为行向量可以得到类似的结果. 单位正交基的几何意义即为所有基向量两两垂直，且模长均为 1.

例 1.4.12 (改变内积会改变长度与正交关系) 取 $M = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$. 由于

$$\boldsymbol{z}^\top M \boldsymbol{z} = (z_1 + z_2)^2 + z_1^2 + z_2^2,$$

它在非零向量上严格为正，所以 M 可以定义广义内积. 为区别于标准内积，本例记

$$\langle \boldsymbol{x}, \boldsymbol{y} \rangle_M := \boldsymbol{x}^\top M \boldsymbol{y}, \qquad \|\boldsymbol{x}\|_M := \sqrt{\boldsymbol{x}^\top M \boldsymbol{x}}.$$

取 $\boldsymbol{x} = (1, 0)^\top$, $\boldsymbol{y} = (1, -2)^\top$，有

$$M\boldsymbol{y} = (0, -3)^\top, \qquad \langle \boldsymbol{x}, \boldsymbol{y} \rangle_M = 0.$$

所以它们在这个广义内积下正交，但标准内积为 $\boldsymbol{x}^\top \boldsymbol{y} = 1$，并不为零. 相应的长度与距离为

$$\|\boldsymbol{x}\|_M = \sqrt{2}, \qquad \|\boldsymbol{y}\|_M = \sqrt{6}, \qquad \|\boldsymbol{x} - \boldsymbol{y}\|_M = 2\sqrt{2}.$$

向量的坐标没有改变，但长度、距离以及正交关系依赖于我们选定的内积.

1.5 矩阵函数

此前，我们考虑的多元函数自变量是以向量的形式表示的，我们本节考虑将自变量推广为矩阵的形式，即矩阵函数：

$$f : \mathbb{R}^{n \times m}; \quad y = f(X), X \in \mathbb{R}^{n \times n}.$$

由于矩阵 X 本质上也是一个有序数组，我们可以将所有元素按照一个特定的顺序（通常为保持每列元素连续，所有列首尾相接）展平为一个向量，我们记为 $\mathrm{vec}(X) \in \mathbb{R}^{mn}$. 从而函数 $f(X)$ 可以转化为关于向量 $\mathrm{vec}(X)$ 的普通多元函数 $\tilde{f}\big(\mathrm{vec}(X)\big)$. 因此，从理论上讲，矩阵函数完全可以通过展平操作转化为关于向量的普通多元函数；但是从实践上讲，展平操作有时会丢失矩阵的某些紧凑性质，使求导过程变得困难，或是使导函数的形式变得非常不直观. 所以，我们仍然有必要独立地研究矩阵函数的性质.

1.5.1 矩阵函数及其导数

为了使记号更加简便，我们定义 E_{ij} 为第 i 行第 j 列元素为 1, 其余元素均为 0 的矩阵. 我们定义矩阵函数的偏导数如下：

定义 1.5.1 (矩阵函数偏导数) 对于定义在 $\mathcal{X} \subseteq \mathbb{R}^{m \times n}$ 上的矩阵函数 $f(X)$, 给定一点 $X^{(0)} \in \mathcal{X}$, 若以下极限存在且有限

$$\ell = \lim_{t \to 0} \frac{f(X^{(0)} + tE_{ij}) - f(X^{(0)})}{t},$$

则称 ℓ 为多元函数 f 在 $X^{(0)}$ 点处关于第 i 行第 j 列分量的(单点)偏导数,记为 $f'_{i,j}(X^{(0)})$. 考虑所有 $X \in \mathcal{X}$, 一系列偏导数构成了一个关于矩阵 X 的矩阵函数，我们称其为偏导

函数，简称偏导数，记为 $f'_{i,j}(X)$.

矩阵函数的偏导数同样有 f' 型记号，$\partial\cdot/\partial\cdot$ 型记号等多种形式，这里不再赘述.

类比关于向量的多元函数梯度的概念，我们理应可以定义矩阵函数梯度的概念. 然而我们遇到了一些困难. 多元函数的梯度为一个同维度的向量，其行梯度、列梯度形式分别有不同的用途；而对于矩阵函数的梯度，我们可能不再能定义出一对行、列梯度的形式. 但我们依旧希望矩阵函数的梯度保留尽可能多的性质. 因此，折衷的方案为：**让矩阵函数的梯度与自变量保持相同的形状**，即 $m\times n$ 维矩阵. 这么做的优势是可以继承列梯度的与自变量直接相加减的性质，从而使得梯度下降等算法依然可行；劣势是其不再直接与链式法则相容，后续行文中我们将介绍含有矩阵函数时，链式法则应当如何处理. 我们下面严格叙述矩阵函数的梯度定义：

定义 1.5.2 (矩阵函数梯度) 对于定义在 $\mathcal{X}\subseteq\mathbb{R}^{m\times n}$ 上的矩阵函数 $f(X)$, 若其所有偏导数 $f'_{i,j}(X), i=1,2,\dots,m; j=1,2,\dots,n$ 在定义域内均存在且为连续函数，则函数 f 的梯度定义为所有分量的偏导数排列成的 $m\times n$ 维矩阵，即：

$$\nabla f(X):=\begin{pmatrix} f'_{1,1}(X) & \cdots & f'_{1,m}(X)\\ \vdots & & \vdots\\ f'_{m,1}(X) & \cdots & f'_{m,n}(X)\end{pmatrix}.$$

同样 grad$f(X)$,$f'(X)$ 也可以用来表示梯度.

本质上讲，将矩阵函数的梯度排列成与自变量相同的形状并不会带来额外的结构与信息，求偏导数并拼合成矩阵依然是最基础的方法. 然而，存在多种可以快速求得矩阵函数梯度的方法，下文的若干实例循序渐进地提供了一些求导的思路.

例 1.5.3 (把分量偏导数放回矩阵中的原位置) 对 $X=(x_{i,j})\in\mathbb{R}^{2\times 3}$，定义

$$f(X)=x_{1,1}x_{2,3}+x_{1,2}^2x_{2,1}+\sin x_{1,3}+e^{x_{2,2}}.$$

分别对六个元素求偏导并按原来的行、列位置排列，得到

$$\nabla f(X)=\begin{pmatrix} x_{2,3} & 2x_{1,2}x_{2,1} & \cos x_{1,3}\\ x_{1,2}^2 & e^{x_{2,2}} & x_{1,1}\end{pmatrix}.$$

例如，在

$$X^{(0)}=\begin{pmatrix} 1 & 2 & 0\\ -1 & 0 & 3\end{pmatrix}$$

处，有 $f(X^{(0)})=0$ 以及

$$\nabla f(X^{(0)})=\begin{pmatrix}3 & -4 & 1\\ 4 & 1 & 1\end{pmatrix}.$$

还可以直接用偏导数的定义检查第 $(1,2)$ 个元素：

$$f(X^{(0)}+tE_{12})-f(X^{(0)})=-(2+t)^2+4=-4t-t^2.$$

除以 t 并令 $t\to 0$，得到 $f'_{1,2}(X^{(0)})=-4$. 梯度与 X 同为 2×3 矩阵，每个位置表示对应元素变化时的一阶影响.

例 1.5.4 设 $A\in\mathbb{R}^{m\times n}$ 为一个常数矩阵，矩阵函数 $f:\mathbb{R}^{m\times n}\to\mathbb{R}$,

$$f(X)=\mathrm{tr}(A^\top X).$$

求解该函数的梯度可以直接将其展开为标量形式，我们不难推导出：

$$f(X)=\sum_{i=1}^{m}\sum_{j=1}^{n}a_{i,j}x_{i,j},$$

聚焦 $x_{i,j}$, 固定其余分量后的偏导数即为

$$\frac{\partial f}{\partial x_{i,j}}=a_{i,j},$$

是一个关于 X 的常数函数. 从而我们直接将其拼合成对应形状的矩阵即可得到：

$$\nabla f(X)=A.$$

例 1.5.5 设 $A\in\mathbb{R}^{m\times m}$, 为一个常数方阵（不一定对称），矩阵函数 $f:\mathbb{R}^{m\times n}\to\mathbb{R}$,

$$f(X)=\mathrm{tr}(X^\top AX).$$

对于该函数，我们依然可以通过展开成标量形式、求偏导数、合并为梯度矩阵的方法去计算. 然而，我们注意到，如果我们将 X 分解为 $(\boldsymbol{x}_1,\dots,\boldsymbol{x}_n)$, 每个 $\boldsymbol{x}_j$ 为一个 m 维向量，则矩阵 $X^\top AX$ 的第 i 个对角元可表示为：

$$\boldsymbol{x}_i^\top A\boldsymbol{x}_i.$$

从而函数 f 可以表示为分别关于 $\boldsymbol{x}_1,\dots,\boldsymbol{x}_n$ 的 n 个独立的函数的和的形式，即

$$f(X)=\boldsymbol{x}_1^\top A\boldsymbol{x}_1+\cdots+\boldsymbol{x}_n^\top A\boldsymbol{x}_n:=\sum_{i=1}^{n}f_i(\boldsymbol{x}_i),$$

我们通常称满足这种形式的函数为一个“可分函数”. 如果我们此时考虑的是关于 $\mathrm{vec}(X)=(\boldsymbol{x}_1^\top,\dots,\boldsymbol{x}_n^\top)^\top$ 的普通多元函数，那么我们不难得出，该函数的梯度就是将关于每块的函数的梯度直接拼合. 矩阵函数的梯度由于只是将偏导数进行了重排，自然也

Yuan and Song

满足上述的性质.

参照例*1.1.13*的推导，我们可以求得

$$\nabla f_i(\boldsymbol{x}_i) = (A + A^\top)\boldsymbol{x}_i.$$

从而我们将其按照矩阵函数的梯度形状将每块进行横向拼合，即得到：

$$\nabla f(X) = (A + A^\top)X.$$

我们将上例的洞察总结为如下定理：

定理 1.5.6 (可分函数的梯度) 设函数 $f : \mathbb{R}^{n_1+\cdots+n_k} \to \mathbb{R}$, 若其可以表示为

$$f(\boldsymbol{x}_1, \ldots, \boldsymbol{x}_k) = f_1(\boldsymbol{x}_1) + \cdots + f_k(\boldsymbol{x}_k),$$

其中 $f_i(\boldsymbol{x}_i) : \mathbb{R}^{n_i} \to \mathbb{R}, i = 1, \ldots, k$ 为 k 个相互独立的函数，则其梯度为

$$\nabla f(\boldsymbol{x}_1, \ldots, \boldsymbol{x}_k) = (\nabla f_1(\boldsymbol{x}_1)^\top, \ldots, \nabla f_k(\boldsymbol{x}_k)^\top)^\top.$$

例 1.5.7* 考虑行列式 $\det(X)$, 它可以视为关于方阵 $X \in \mathbb{R}^{n\times n}$ 的一个矩阵函数，且其本质上是关于矩阵 X 所有元素的一个 n 次多项式，因此是可导的，可以计算梯度.

直接计算关于单个元素的偏导数并不容易，所幸我们有行列式的拉普拉斯展开定理：

$$\det(X) = \sum_{k=1}^{n} x_{i,k} C_{i,k}, \tag{1.2}$$

其中 $C_{i,k}$ 是元素 $x_{i,k}$ 的代数余子式，即 $C_{i,k} = (-1)^{i+k} M_{i,k}$, $M_{i,k}$ 为 $x_{i,k}$ 的余子式，即矩阵 X 去掉第 i 行第 k 列后的子矩阵的行列式.

考虑 $x_{i,k}$, 我们观察到，所有 $C_{i,k}, k = 1, \ldots, n$ 中不含有第 i 行的任何元素，自然也不含有 $x_{i,k}$. 而(1.2)同时也具有可分的结构，因此我们求关于 $x_{i,k}$ 的偏导数时，只需考虑 $x_{i,k}C_{i,k}$ 这一项即可. 很显然，

$$\frac{\partial \det(X)}{\partial x_{i,k}} = C_{i,k}.$$

拼合所有的偏导数，我们可以得到：

$$\nabla \det(X) = \begin{pmatrix} C_{1,1} & \cdots & C_{1,n} \\ \vdots & & \vdots \\ C_{n,1} & \cdots & C_{n,n} \end{pmatrix}.$$

在线性代数中存在与上述矩阵十分相似的形式. 事实上，上述形式即矩阵 X 的伴随矩阵

Yuan and Song

的转置，我们记为 $\mathrm{adj}(X)^\top$. 从而我们有结论：

$$\nabla \det(X) = \mathrm{adj}(X)^\top.$$

进一步，如果 X 为可逆矩阵，我们有线性代数中另一重要结果：

$$X\mathrm{adj}(X) = \mathrm{adj}(X)X = \det(X)I,$$

从而 $\mathrm{adj}(X) = \det(X)X^{-1}$. 因此

$$\nabla \det(X) = \det(X)(X^{-1})^\top.$$

小贴士

多元函数的二阶导数可以表示为海瑟矩阵. 而对于矩阵函数，其二阶导数只能表示为四阶张量，或者是将其展平为向量的多元函数再求海瑟矩阵. 鉴于矩阵函数的二阶导数表示十分不方便，我们在本书中不会详细讨论.

1.5.2 矩阵内积、矩阵函数的微分

在向量空间中，我们有标准内积：

$$\langle \boldsymbol{x}, \boldsymbol{y} \rangle = \boldsymbol{x}^\top \boldsymbol{y}, \quad \boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^n.$$

那么对于矩阵来讲，我们是否也可以定义一个内积呢？事实上，矩阵 X,Y 的内积就等价于将两个矩阵展平为向量 $\mathrm{vec}(X)$,$\mathrm{vec}(X)$ 后的内积，即：

$$\langle X, Y \rangle = \sum_{i=1}^{m}\sum_{j=1}^{n} x_{i,j}y_{i,j}, \quad X, Y \in \mathbb{R}^{m\times n}.$$

事实上，我们可以证明矩阵内积可以写为如下更紧凑的格式：

$$\langle X, Y \rangle = \mathrm{tr}(X^\top Y).$$

例 1.5.8 (非方阵的内积与迹表示) 考虑两个 2×3 矩阵

$$X = \begin{pmatrix} 1 & -1 & 2 \\ 0 & 3 & 1 \end{pmatrix}, \qquad Y = \begin{pmatrix} 2 & 1 & 0 \\ -1 & 0 & 3 \end{pmatrix}.$$

按照逐元素相乘后求和的定义，

$$\langle X, Y \rangle = 1\cdot 2 + (-1)\cdot 1 + 2\cdot 0 + 0\cdot(-1) + 3\cdot 0 + 1\cdot 3 = 4.$$

另一方面，

$$X^\top Y = \begin{pmatrix} 2 & 1 & 0 \\ -5 & -1 & 9 \\ 3 & 2 & 3 \end{pmatrix}, \qquad \mathrm{tr}(X^\top Y) = 2 - 1 + 3 = 4.$$

若按列展平，则

$$\mathrm{vec}(X) = (1, 0, -1, 3, 2, 1)^\top, \qquad \mathrm{vec}(Y) = (2, -1, 1, 0, 0, 3)^\top,$$

这两个向量的内积同样为 4. 因此矩阵内积是一个标量；它并不是矩阵乘法 XY，本例中的 XY 甚至因维度不匹配而没有定义.

对于向量的多元函数，我们有全微分

$$\Delta z = f_1'(\boldsymbol{x})\Delta x_1 + \cdots + f_n'(\boldsymbol{x})\Delta x_n + o(\rho) = \nabla f(\boldsymbol{x})^\top \Delta \boldsymbol{x} + o(\rho),$$

或

$$\mathrm{d}z = \nabla f(\boldsymbol{x})^\top \mathrm{d}\boldsymbol{x},$$

这里的 $\nabla f(\boldsymbol{x})^\top \mathrm{d}\boldsymbol{x}$ 其实正是内积，我们可以自然地将多元函数的微分推广到矩阵函数中，即

$$\Delta z = \langle \nabla f(X), \Delta X \rangle + o(\rho),$$

此处 ρ 的定义应当类推为 $\rho = \sqrt{\sum_{i=1}^m \sum_{j=1}^n x_{i,j}^2}$, 或可写成微分形式

$$\mathrm{d}z = \langle \nabla f(X), \mathrm{d}X \rangle.$$

无论关于向量还是矩阵的微分，其本质上均是一个多元函数的极限，即关于 $\Delta \boldsymbol{x}$ 或是 ΔX 的极限. 这个极限涉及到 n 个乃至 $m \times n$ 个自变量，并不好研究. 因此与之相对的，可微性有另一个稍微弱一些的版本，即将多元函数极限转换为任意方向上的一元函数极限. 我们称这个弱一些的版本为 Gâteaux 可微性，而称原先的标准版本为 Fréchet 可微性. Gâteaux 可微性的定义如下（我们以矩阵形式为例，向量形式可以类推得到）：

定义 1.5.9 (Gâteaux 可微性) 设函数 $z = f(X) : \mathbb{R}^{m\times n} \to \mathbb{R}$ 在点 X_0 的一个邻域中有定义，任意给定方向矩阵 $V \in \mathbb{R}^{m\times n}$, 记 $\Delta z(t) := f(X_0 + tV) - f(X_0)$, 其中 $t \in \mathbb{R}$ 为自由变元. 如果 Δz 满足

$$\Delta z(t) = \langle G, tV \rangle + o(t),$$

其中 $G \in \mathbb{R}^{m\times n}$ 为不依赖于 V 及 t 的常数，则我们称函数 $f(X)$ 在点 X_0 处 *Gâteaux* 可微.

注意：Fréchet 可微性可以直接推导出可导性，且微分中的线性主部系数就是所有的

偏导数. Gâteaux 可微性虽然弱于 Fréchet 可微性，但仍然可以推出可导性且线性主部与偏导数完全相同，证明思路与 Fréchet 可微性完全一致. 我们用如下示意图表达三者的关系，其中右侧的条件成立可以推导出左侧的条件成立.

$$\boxed{\text{可导性} \Leftarrow \text{Gâteaux 可微性} \Leftarrow (\text{Fréchet}) \text{可微性}}$$

小贴士

事实上，机器学习中绝大部分的多元函数或是矩阵函数都是性质良好的函数. 可导但不是 Gâteaux 可微，或是 Gâteaux 可微但不是 Fréchet 可微的函数仅存在于少数一些数学分析的复杂例子中.

例 1.5.10 (由矩阵方向上的增量求梯度) 对方阵 $X \in \mathbb{R}^{n\times n}$，定义 $f(X) = \operatorname{tr}(X^3)$. 固定一个方向矩阵 V，展开时保留矩阵乘积的顺序：

$$(X+tV)^3 = X^3 + t(X^2V + XVX + VX^2) + O(t^2).$$

这里对固定的 X, V，省略项中 t 的次数至少为 2. 利用迹的循环性质，三项 X^2V, XVX, VX^2 的迹相等，于是

$$\begin{aligned} f(X+tV) - f(X) &= 3t\operatorname{tr}(X^2V) + o(t) \\ &= \langle 3(X^2)^\top, tV\rangle + o(t). \end{aligned}$$

与可微性的定义比较，得到

$$\nabla f(X) = 3(X^2)^\top.$$

例如，取 $X_0 = \begin{pmatrix} 1 & 1 \\ 0 & 2 \end{pmatrix}$，则

$$X_0^2 = \begin{pmatrix} 1 & 3 \\ 0 & 4 \end{pmatrix}, \qquad \nabla f(X_0) = \begin{pmatrix} 3 & 0 \\ 9 & 12 \end{pmatrix}.$$

在方向 $V = E_{21}$ 上，一阶变化率为 $\langle \nabla f(X_0), E_{21}\rangle = 9$. 直接展开也得到 $f(X_0 + tE_{21}) = 9 + 9t$. 本例中的转置来自内积 $\langle G, V\rangle = \operatorname{tr}(G^\top V)$，不能省略.

可微性的实用之处在于，如果我们通过某种方式事先“猜测”出了某个函数梯度的可能形式，同时又证明了其满足可微的定义式，那么我们就可以直接断言上述猜测的形式就是该函数的梯度. 下述例子提供了一个利用可微性求得梯度的典型应用.

例 1.5.11* 考虑定义在 n 阶正定矩阵集合 $\mathcal{S}_{++}^n$ 上的矩阵函数 f:

$$f(X) = \ln\big(\det(X)\big).$$

Yuan and Song

我们下面使用 *Gâteaux* 可微性来求该函数的梯度. 给定正定矩阵 X, 由于正定矩阵的线性组合仍然为实对称矩阵，因此我们应该任意假设方向矩阵 V 为实对称矩阵，同时考虑 $t \in \mathbb{R}$, 有

$$\begin{aligned} f(X+tV) - f(X) &= \ln\big(\det(X+tV)\big) - \ln\big(\det(X)\big) \\ &= \ln\Big(\det\big(X^{1/2}(I + tX^{-1/2}VX^{-1/2})X^{1/2}\big)\Big) - \ln\big(\det(X)\big) \\ &= \ln\big(\det(X)\det(I + tX^{-1/2}VX^{-1/2})\big) - \ln\big(\det(X)\big) \\ &= \ln\big(\det(I + tX^{-1/2}VX^{-1/2})\big), \end{aligned}$$

其中 $X^{1/2}$ 的分解得益于正定矩阵的可开方性，$X^{-1/2} := (X^{1/2})^{-1}$. 我们下面考虑将 $X^{-1/2}VX^{-1/2}$ 正交对角化，即 $X^{-1/2}VX^{-1/2} = Q\Lambda Q^\top$, 其中 $\Lambda = \mathrm{Diag}(\lambda_1, \ldots, \lambda_n)$, 则

$$\begin{aligned} &\ln\big(\det(I + tX^{-1/2}VX^{-1/2})\big) \\ &= \ln\big(\det(QIQ^\top + tQ\Lambda Q^\top)\big) = \ln\big(\det(I + t\Lambda)\big) \\ &= \ln\prod_{i=1}^{n}(1+t\lambda_i) = \sum_{i=1}^{n}\ln(1+t\lambda_i) = \sum_{i=1}^{n} t\lambda_i + o(t) \\ &= t\cdot\mathrm{tr}(X^{-1/2}VX^{-1}) + o(t) = \langle (X^{-1})^\top, tV\rangle + o(t), \end{aligned}$$

其中第三行第三个等号使用了 ln 函数的泰勒展开式，第四行第一个等号使用了相似矩阵的保持迹的性质 $\mathrm{tr}(QAQ^{-1}) = \mathrm{tr}(Q^{-1}QA) = \mathrm{tr}(A)$. 自此，我们将函数 f 成功写为了 *Gâteaux* 导数的形式，同时由于 $X^\top = X$, 我们有

$$\nabla f(X) = X^{-1}.$$

小贴士

使用可微性来推导梯度的方法是一种“事后诸葛亮”的方法，猜测和推导梯度的可能形式往往需要很强的洞察力. 在下一小节中，我们将介绍一些更加具有可操作性的求导策略.

1.5.3 复合求导法则

我们在引入矩阵函数的梯度时，曾指出其不再直接支持向量值函数的链式法则. 我们自然可以选择将矩阵 X 展平为向量 $\mathrm{vec}(X)$ 再使用链式法则，但是这往往会显著增加求导的难度，因此我们需要使用一些额外的工具来帮助我们快速求解复合下的矩阵函数的梯度.

Yuanlu Song

我们在先前已指出，微分记号 $\mathrm{d}\boldsymbol{x}, \mathrm{d}X$ 等是一种不严谨的用于快速推导梯度的记号. 对于函数 $f : \mathbb{R}^{m\times n} \to \mathbb{R}, X \mapsto z$, 如果我们能通过若干微分运算推导得出

$$\mathrm{d}z = \langle G, \mathrm{d}X\rangle,$$

则我们就可以断言 $\nabla f(X) = G$. 这实质上正是整理 Fréchet 或 Gâteaux 微分表达式的过程，只是我们默认余项一定是无穷小量，无需担心余项可能出现的问题，这在绝大多数问题中都是满足的. 此外，微分运算下也存在多种形式优雅的运算法则，以使得求导更加便利，我们将会在本小节介绍最常用的几条微分法则.

需要注意的是，微分记号 $\mathrm{d}X$ 可能有不同的含义，如果 X 是底层的自变量，那么 $\mathrm{d}X$ 就是一个自由变元，无需进一步运算；如果 X 是一个中间变量，那么我们需要将其所有分量分别考虑为一个多元函数的微分，再分别展开直至得到底层的自变量.

下述第一条定理与链式法则的关系最为密切，当外层为一个一元函数，内层为一个矩阵函数时，微分运算与链式法则完全一致.

定理 1.5.12 设自变量 $X \in \mathbb{R}^{m\times n}$, 中间变量 $y = f(X) \in \mathbb{R}$, 因变量 $z = g(y) \in \mathbb{R}$, 则：

$$\mathrm{d}z = g'(y)\mathrm{d}y = \Big\langle g'\big(f(X)\big)\nabla f(X), \mathrm{d}X\Big\rangle.$$

证明. 考虑偏导数

$$\frac{\partial z}{\partial x_{i,j}} = g'\big(f(X)\big)f'_{i,j}(X),$$

直接拼合成矩阵即可得到最终结果. ■

以下例子使用上述定理来验证例1.5.11中 ln-det 函数导数的正确性.

例 1.5.13 (续例1.5.11) 再次考虑定义在 n 阶正定矩阵集合上的函数 $h(X) := \ln\big(\det(X)\big)$, 其中外层函数 $z = g(y) = \ln y$ 为一元函数，其导数易求得为 $g'(y) = y^{-1}$; 内层 $y = f(X) = \det(X)$ 为行列式对应的矩阵函数，使用例*1.5.7*的结果，我们得到：

$$\nabla f(X) = \det(X)(X^{-1})^\top = \det(X)X^{-1},$$

其中第二个等式是因为 X 为正定矩阵. 从而我们直接使用定理*1.5.12*得：

$$\nabla h(X) = g'(f(X))\nabla f(X) = \frac{1}{\det(X)}\det(X)X^{-1} = X^{-1}.$$

这与我们在例*1.5.11*中的计算结果是完全吻合的.

以下两个性质与内积运算及矩阵的迹运算有关，它们的证明也是比较直接的.

Yuan and Song

性质 1.5.14 设自变量或中间变量为 $X \in \mathbb{R}^{m\times n}$, $A \in \mathbb{R}^{m\times n}$ 为常数矩阵，则

$$\mathrm{d}\big(\langle A, X\rangle\big) = \langle A, \mathrm{d}X\rangle$$

证明. 直接根据矩阵函数的微分形式来展开函数 $f(X) = \langle A, X\rangle$ 即可. ■

性质 1.5.15 设自变量或中间变量为 $X \in \mathbb{R}^{n\times n}$, 则

$$\mathrm{d}\big(\mathrm{tr}(X)\big) = \mathrm{tr}\big(\mathrm{d}X\big).$$

证明. 由于 $\mathrm{tr}(X) = \mathrm{tr}(I_n X) = \langle I_n, X\rangle$, 因此直接使用性质1.5.14有：

$$\mathrm{d}\big(\mathrm{tr}(X)\big) = \mathrm{d}\big(\langle I_n, X\rangle\big) = \langle I_n, \mathrm{d}X\rangle = \mathrm{tr}(I_n \mathrm{d}X) = \mathrm{tr}(\mathrm{d}X).$$

■

以下三个性质则是进一步处理矩阵作为中间变量时的推导方式. 它们如果展平为向量再使用链式法则进行证明的话将会非常复杂，而由于它们都是线性的运算，直接拆分成分量进行推导反而更加容易.

性质 1.5.16 设 $X \in \mathbb{R}^{n\times n}$ 为自变量或中间变量，则

$$\mathrm{d}(X^\top) = (\mathrm{d}X)^\top.$$

证明. 转置仅影响分量的排列顺序，不会影响分量自身的取值，上述等式自然成立. ■

性质 1.5.17 设 $X, Y \in \mathbb{R}^{m\times n}$ 为自变量或中间变量，则

$$\mathrm{d}(X + Y) = \mathrm{d}X + \mathrm{d}Y.$$

证明. 记 $Z = X + Y$, 则 $z_{i,j} = x_{i,j} + y_{i,j}$, 此时我们直接有

$$\mathrm{d}z_{i,j} = \mathrm{d}x_{i,j} + \mathrm{d}y_{i,j},$$

直接拼合成矩阵即得证. ■

性质 1.5.18 设 $X \in \mathbb{R}^{m\times n}, Y \in \mathbb{R}^{n\times p}$ 为自变量或中间变量，则

$$\mathrm{d}(XY) = (\mathrm{d}X)Y + X(\mathrm{d}Y).$$

Yuan and Song

证明. 记 $Z = XY$, 则 $z_{i,j} = \sum_{k=1}^{n} x_{i,k}y_{k,j}$. 使用一元函数的乘积微分法则 $\mathrm{d}(xy) = x\mathrm{d}y + y\mathrm{d}x$, 我们得到:

$$\mathrm{d}z_{i,j} = \sum_{k=1}^{n}(x_{i,k}\mathrm{d}y_{k,j} + y_{k,j}\mathrm{d}x_{i,k}) = \sum_{k=1}^{n} x_{i,k}\mathrm{d}y_{k,j} + \sum_{k=1}^{n} y_{k,j}\mathrm{d}x_{i,k},$$

再拼合成矩阵我们即可得到最后结果. ■

小贴士

1. 对于性质1.5.18，注意矩阵乘积不满足交换律，矩阵乘积的顺序不可变. 进一步，如果矩阵 A, B 为常数矩阵，则 $\mathrm{d}A = 0, \mathrm{d}B = 0$, 从而我们有：

$$\mathrm{d}(AX) = A\mathrm{d}X; \quad \mathrm{d}(XB) = (\mathrm{d}X)B.$$

2. 以上所有性质均可适用于普通的多元函数，只需将其视为列数为 1 的列矩阵即可，此时求出的梯度为列梯度.

使用上述的微分运算法则，我们来再次分别验证例1.5.4, 例1.5.5求得梯度的正确性.

例 1.5.19 (续例1.5.4) 考虑函数 $f(X) = \mathrm{tr}(A^\top X)$, 其中 A 为常数矩阵.

使用微分形式，

$$\mathrm{d}\big(\mathrm{tr}(A^\top X)\big) = \langle A, \mathrm{d}X\rangle,$$

从而我们立即得到 $\nabla f(X) = A$.

例 1.5.20 (续例1.5.5) 考虑函数 $f(X) = \mathrm{tr}(X^\top AX)$, 其中 A 为常数方阵（不一定对称）.

使用微分形式，

$$\begin{aligned}\mathrm{d}\big(\mathrm{tr}(X^\top AX)\big) &= \mathrm{tr}\big(\mathrm{d}(X^\top AX)\big) = \mathrm{tr}\big(X^\top \mathrm{d}(AX) + (\mathrm{d}X^\top)(AX)\big)\\ &= \mathrm{tr}(X^\top A\mathrm{d}X) + \mathrm{tr}\big((\mathrm{d}X)^\top(AX)\big) = \langle A^\top X, \mathrm{d}X\rangle + \langle AX, \mathrm{d}X\rangle\\ &= \big\langle (A^\top + A)X, \mathrm{d}X\big\rangle.\end{aligned}$$

从而我们可以得到 $\nabla f(X) = (A + A^\top)X$.

例 1.5.21 (矩阵两侧都含常数因子的平方损失) 设 $A \in \mathbb{R}^{p\times m}$, $B \in \mathbb{R}^{n\times q}$, $C \in \mathbb{R}^{p\times q}$ 为常数矩阵，自变量为 $X \in \mathbb{R}^{m\times n}$. 记

$$R = AXB - C, \qquad f(X) = \frac{1}{2}\langle R, R\rangle = \frac{1}{2}\sum_{i=1}^{p}\sum_{j=1}^{q} r_{i,j}^2.$$

对每个残差分量求微分，可得 $\mathrm{d}f = \langle R, \mathrm{d}R\rangle$. 由于 A, B, C 固定，乘积微分法则给出

$\mathrm{d}R = A(\mathrm{d}X)B$. 因此

$$\begin{aligned}\mathrm{d}f &= \operatorname{tr}\big(R^\top A(\mathrm{d}X)B\big)\\ &= \operatorname{tr}\big(BR^\top A\,\mathrm{d}X\big)\\ &= \langle A^\top RB^\top, \mathrm{d}X\rangle.\end{aligned}$$

从而

$$\nabla f(X) = A^\top(AXB - C)B^\top \in \mathbb{R}^{m\times n}.$$

例如，取

$$A = \begin{pmatrix}1 & 2\end{pmatrix},\quad B = \begin{pmatrix}1 & 0\\ 1 & 1\end{pmatrix},\quad C = \begin{pmatrix}0 & 1\end{pmatrix},\quad X = I_2,$$

则 $R = \begin{pmatrix}3 & 1\end{pmatrix}$，并且

$$\nabla f(I_2) = \begin{pmatrix}1\\ 2\end{pmatrix}\begin{pmatrix}3 & 1\end{pmatrix}\begin{pmatrix}1 & 1\\ 0 & 1\end{pmatrix} = \begin{pmatrix}3 & 4\\ 6 & 8\end{pmatrix}.$$

左右两个常数因子分别作用于矩阵的行、列；整理微分时保留乘法顺序，就能得到与自变量同形状的梯度.

我们最后来叙述一个在深度学习前反向传播中广泛使用的结论，它是微分形式的性质1.5.18的直接推论.

推论 1.5.22 设自变量或中间变量 $X \in \mathbb{R}^{m\times n}, Y \in \mathbb{R}^{n\times p}$, 中间变量 $Z = XY$, 因变量 $l = f(Z)$, 其中 $\nabla f(\cdot)$ 已知，则我们有分块导数：

$$\frac{\partial l}{\partial X} = \nabla f(Z)Y^\top;\quad \frac{\partial l}{\partial Y} = X^\top \nabla f(Z).$$

证明. 当求关于 X 的偏导数时，Y 视为常数. 则由微分形式：

$$\begin{aligned}\mathrm{d}l &= \langle \nabla f(Z), \mathrm{d}Z\rangle = \langle \nabla f(Z), (\mathrm{d}X)Y\rangle = \operatorname{tr}\big(\nabla f(Z)^\top (\mathrm{d}X)Y\big)\\ &= \operatorname{tr}\big(Y\nabla f(Z)^\top \mathrm{d}X\big) = \langle \nabla f(Z)Y^\top, \mathrm{d}X\rangle.\end{aligned}$$

从而有 $\dfrac{\partial l}{\partial X} = \nabla f(Z)Y^\top$. 关于 Y 的分块导数可以类似地得到. ■

例 1.5.23 (矩阵乘积两端的分块导数) 设 $X, Y \in \mathbb{R}^{2\times 2}$，中间变量 $Z = XY$，并定义标量函数

$$l = f(Z) = \frac{1}{3}\sum_{i=1}^{2}\sum_{j=1}^{2} z_{i,j}^3.$$