

第一章 微积分与线性代数基础

1.1 多元函数及其导数

多元函数 (multivariate function) 是机器学习理论的基本工具, 其定义如下:

定义 1.1.1 (多元函数) 设 X 为实数集 $\mathbb{R}^n$ 中的一个子集, 如果存在一个对应法则 f , 使得对于任意 $\mathbf{x} = (x_1, x_2, \dots, x_n) \in X$, 都存在唯一 $y \in \mathbb{R}$ 与之对应, 则称 f 为定义在 X 上, (陪域为 $\mathbb{R}$) 的 n 元函数, 记作:

$$f: X \rightarrow \mathbb{R}; \quad \mathbf{x} \mapsto y = f(\mathbf{x}) = f(x_1, x_2, \dots, x_n).$$

我们在本节中将讨论多元函数的偏导数、梯度、二阶导数及海瑟矩阵的定义.

1.1.1 偏导数

对于一元函数, 我们可以使用导数来研究其局部的特性. 而对于多元函数, 我们无法直接一次对所有变量进行求导. 取而代之的是, 我们会取定某一个分量 x_i , 而将其余分量视为常数, 对分量 x_i 求导数. 这样求得的导数可以反映函数 f 在 x_i 方向上的局部特性. 我们将该导数称为函数 f 关于 x_i 的偏导数 (partial derivative), 其严格定义如下:

定义 1.1.2 (偏导数) 对于定义在 $X \subseteq \mathbb{R}^n$ 上的多元函数 $f(x_1, \dots, x_n)$, 给定一点 $\mathbf{x}^{(0)} = (x_1^{(0)}, \dots, x_n^{(0)}) \in X$, 若以下极限存在且有限

$$\ell = \lim_{\Delta x \rightarrow 0} \frac{f(x_1^{(0)}, \dots, x_i^{(0)} + \Delta x, \dots, x_n^{(0)}) - f(x_1^{(0)}, \dots, x_i^{(0)}, \dots, x_n^{(0)})}{\Delta x},$$

则称 ℓ 为多元函数 f 在 $\mathbf{x}^{(0)}$ 点处关于第 i 个分量的 (单点) 偏导数, 记为 $f'_i(x_1^{(0)}, \dots, x_n^{(0)})$. 进一步, 对于任意一个给定点 $(x_1^{(0)}, \dots, x_n^{(0)})$, 均存在唯一的 $f'_i(x_1^{(0)}, \dots, x_n^{(0)})$ 与之对应. 因此, 考虑所有 $\mathbf{x} \in X$, f 关于第 i 个分量的偏导数构成了一个 n 元函数, 我们称其为偏导函数, 简称为偏导数, 记为 $f'_i(x_1, \dots, x_n)$.

注意偏导数的定义域可能不为 X , 而是 x 的一个真子集. 关于偏导数定义域的分析需要考虑不可导情形及边缘单侧导数的情形, 不在本书所讨论的范围之内. 本书中我们一般不讨论偏导数的严格定义域, 或默认定义域与原函数的定义域 X 相同.

小贴士

请注意, 偏导数虽然聚焦于某一分量 x_i , 但其仍然为关于整体 n 元变量 $(x_1, \dots, x_n)$ 的多元函数, 而非仅关于 x_i 的一元函数, 这点尤须注意.

偏导数有除 $f'_i(x_1, \dots, x_n)$ 外的多种写法. 如果自变量的符号固定, 譬如 $(x, y) \in \mathbb{R}^2$, 则关于 x, y 的偏导数可分别写作 $f'_x(x, y), f'_y(x, y)$. 如果因变量的符号同样固定, 譬如 $l = f(x, y)$, 则关于 x, y 的偏导数可分别写作 $\frac{\partial l}{\partial x}(x, y), \frac{\partial l}{\partial y}(x, y)$. 在不引起歧义的情况下, 还可以省略自变量标记, 直接简记为 $\frac{\partial l}{\partial x}, \frac{\partial l}{\partial y}$, 在此情况下, 如果要强调在某一点 $(x^{(0)}, y^{(0)})$ 的单点导数, 可以使用角标形式, 即 $\frac{\partial l}{\partial x}\bigg|_{(x^{(0)}, y^{(0)})}, \frac{\partial l}{\partial y}\bigg|_{(x^{(0)}, y^{(0)})}$. 在因变量不固定时, 有时也使用函数对应法则 f 来代指因变量, 即 $\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}$. 在深度学习相关的数学理论中, 使用偏导数记号 $\frac{\partial}{\partial}$ 的形式反而更为常见.

1.1.2 梯度

如果一个多元函数关于所有分量的偏导数均已知, 我们可以很自然地引出梯度 (gradient) 的定义. 与上文相同, 我们同样只考虑偏导数在整个定义域中均存在的简化情形. 此外, 为确保方向导数良定义, 我们进一步假设偏导数为连续函数, 这是梯度存在的充分不必要条件, 但这一条件在机器学习所研究的问题中一般都是满足的.

定义 1.1.3 (梯度) 对于定义在 $X \subseteq \mathbb{R}^n$ 上的多元函数 $f(x_1, \dots, x_n)$, 若其所有偏导数 $f'_i(\mathbf{x}), i = 1, 2, \dots, n$ 在定义域内均存在且为连续函数, 则函数 f 的梯度定义为由所有分量对应的偏导数组成的列向量 (或行向量), 即:

$$\nabla f(\mathbf{x}) := (f'_1(\mathbf{x}), f'_2(\mathbf{x}), \dots, f'_n(\mathbf{x}))^\top.$$

其中符号 “ ∇ ” 称为哈密顿算子, 读作 “Nabla”. 除上述表示方式外, 梯度也可以有其他表示方法, 如 $\text{grad}f(\mathbf{x})$, 也可以直接借用一元函数导数的记号 $f'(\mathbf{x})$.

小贴士

梯度的列向量与行向量形式分别具有不同的用途，列向量形式用于代入梯度下降等算法中，而行向量形式则用于向量值函数求导及链式法则中。后续内容中，为了不引起混淆，我们会分别使用不同的记号来表示行、列梯度。

在深度学习任务中，由于神经网络通常以分层的形式呈现，因此变量也通常采用分块的形式，我们考虑一个简单的两块的情形，即 $\mathbf{x} \in \mathbb{R}^p, \mathbf{y} \in \mathbb{R}^q$ ，函数 $f(\mathbf{x}, \mathbf{y}) : \mathbb{R}^{p+q} \rightarrow \mathbb{R}$ ，我们可以求得如下的分块的偏导数：

$$f'_{\mathbf{x}}(\mathbf{x}, \mathbf{y}) := (f'_{x_1}(\mathbf{x}, \mathbf{y}), \dots, f'_{x_p}(\mathbf{x}, \mathbf{y}))^\top, \quad f'_{\mathbf{y}}(\mathbf{x}, \mathbf{y}) := (f'_{y_1}(\mathbf{x}, \mathbf{y}), \dots, f'_{y_q}(\mathbf{x}, \mathbf{y}))^\top.$$

同样地，如果因变量的符号固定为 l ，分块偏导数可以写为 $\frac{\partial l}{\partial \mathbf{x}}(\mathbf{x}, \mathbf{y}), \frac{\partial l}{\partial \mathbf{y}}(\mathbf{x}, \mathbf{y})$ ，或省略自变量标记直接写为 $\frac{\partial l}{\partial \mathbf{x}}, \frac{\partial l}{\partial \mathbf{y}}$ ，后者是深度学习中最常用的形式。注意分块导数和梯度一样，均为向量的形式，因此分块导数有时也借用梯度的符号，记为 $\nabla_{\mathbf{x}} f(\mathbf{x}, \mathbf{y}), \nabla_{\mathbf{y}} f(\mathbf{x}, \mathbf{y})$ 。

下面我们通过几个例子来演示函数梯度的求解方法：

例 1.1.4 设函数 $f : \mathbb{R}^n \rightarrow \mathbb{R}$,

$$f(x_1, x_2, \dots, x_n) = \frac{1}{2}(x_1^2 + x_2^2 + \dots + x_n^2),$$

其关于每个分量的偏导数为：

$$f'_i(\mathbf{x}) = x_i,$$

因此整个函数的梯度为：

$$\nabla f(\mathbf{x}) = (x_1, \dots, x_n)^\top = \mathbf{x}.$$

例 1.1.5 设函数 $f : \mathbb{R}^n \rightarrow \mathbb{R}$,

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x} + b,$$

其中 $\mathbf{a} \in \mathbb{R}^n, b \in \mathbb{R}$ 。其关于第 i 个分量的偏导数为：

$$f'_i(\mathbf{x}) = a_i.$$

因此梯度为：

$$\nabla f(\mathbf{x}) = (a_1, \dots, a_n)^\top = \mathbf{a}.$$

例 1.1.6 设函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$,

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top A \mathbf{x} + \mathbf{b}^\top \mathbf{x} + c,$$

其中 $A = (a_{ij}) \in \mathbb{R}^{n \times n}$. 其关于第 i 个分量的偏导数为:

$$f'_i(\mathbf{x}) = \frac{1}{2} \sum_{j=1}^n (a_{ij} + a_{ji}) x_j + b_i.$$

因此梯度为:

$$\nabla f(\mathbf{x}) = \frac{1}{2} (A + A^\top) \mathbf{x} + \mathbf{b}.$$

特别地, 当 A 为对称矩阵时,

$$\nabla f(\mathbf{x}) = A \mathbf{x} + \mathbf{b}.$$

例 1.1.7 设函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$,

$$f(x_1, x_2, \dots, x_n) = \ln(x_1^2 + x_2^2 + \dots + x_n^2),$$

其关于每个分量的偏导数为:

$$f'_i(\mathbf{x}) = \frac{2x_i}{x_1^2 + \dots + x_n^2},$$

因此整个函数的梯度为:

$$\nabla f(\mathbf{x}) = \frac{1}{x_1^2 + \dots + x_n^2} (2x_1, \dots, 2x_n)^\top = \frac{2}{\mathbf{x}^\top \mathbf{x}} \mathbf{x}.$$

例 1.1.8 设函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$,

$$f(\mathbf{x}) = \exp(\mathbf{a}^\top \mathbf{x}),$$

其中 $\mathbf{a} \in \mathbb{R}^n$. 其关于第 i 个分量的偏导数为:

$$f'_i(\mathbf{x}) = a_i \exp(\mathbf{a}^\top \mathbf{x}).$$

因此梯度为:

$$\nabla f(\mathbf{x}) = \exp(\mathbf{a}^\top \mathbf{x}) \mathbf{a}.$$

例 1.1.9 设函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$,

$$f(\mathbf{x}) = \ln \left(\sum_{j=1}^n e^{x_j} \right).$$

记

$$S(\mathbf{x}) = \sum_{j=1}^n e^{x_j}.$$

则其关于第 i 个分量的偏导数为：

$$f'_i(\mathbf{x}) = \frac{e^{x_i}}{S(\mathbf{x})} = \frac{e^{x_i}}{\sum_{j=1}^n e^{x_j}}.$$

因此梯度为：

$$\nabla f(\mathbf{x}) = \left(\frac{e^{x_1}}{\sum_{j=1}^n e^{x_j}}, \dots, \frac{e^{x_n}}{\sum_{j=1}^n e^{x_j}} \right)^\top.$$

该梯度正是 *softmax* 函数的输出.

例 1.1.10 设样本 $(\mathbf{x}, y)$ 满足

$$\mathbf{x} \in \mathbb{R}^n, \quad y \in \{0, 1\}.$$

定义模型输出

$$p(\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x}) = \frac{1}{1 + \exp(-\mathbf{w}^\top \mathbf{x})}.$$

二元逻辑回归的交叉熵损失为

$$\ell(\mathbf{w}) = -y \ln p(\mathbf{x}) - (1 - y) \ln(1 - p(\mathbf{x})).$$

由于

$$\sigma'(z) = \sigma(z)(1 - \sigma(z)),$$

并且

$$\frac{\partial(\mathbf{w}^\top \mathbf{x})}{\partial \mathbf{w}} = \mathbf{x},$$

根据链式法则可得

$$\nabla_{\mathbf{w}} \ell(\mathbf{w}) = (p(\mathbf{x}) - y) \mathbf{x}.$$

也就是

$$\nabla_{\mathbf{w}} \ell(\mathbf{w}) = (\sigma(\mathbf{w}^\top \mathbf{x}) - y) \mathbf{x}.$$

例 1.1.11 对于数据集

$$\{(\mathbf{x}_i, y_i)\}_{i=1}^N,$$

定义平均损失

$$L(\mathbf{w}) = -\frac{1}{N} \sum_{i=1}^N [y_i \ln p_i + (1 - y_i) \ln(1 - p_i)],$$

其中

$$p_i = \sigma(\mathbf{w}^\top \mathbf{x}_i).$$

因此

$$\nabla_{\mathbf{w}} L(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N (p_i - y_i) \mathbf{x}_i$$

若将样本组成矩阵

$$X = \begin{pmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_N^\top \end{pmatrix}, \quad \mathbf{p} = \begin{pmatrix} p_1 \\ \vdots \\ p_N \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_N \end{pmatrix},$$

则梯度可以写成紧凑形式:

$$\nabla_{\mathbf{w}} L(\mathbf{w}) = \frac{1}{N} X^\top (\mathbf{p} - \mathbf{y}).$$

1.1.3 二阶导数与海瑟矩阵

对于一元函数,我们可以使用一阶导数来探究函数的增减性和斜率,同时进一步可以使用二阶导数来探究函数的凹凸性和曲率. 对于多元函数,我们也希望类似地讨论其二阶导数.

对于函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, 我们可以求出 n 个偏导数 $f'_1(\mathbf{x}), \dots, f'_n(\mathbf{x})$, 它们均为定义在 $\mathbb{R}^n$ 上的多元函数. 进一步, 我们可以对这 n 个多元函数再分别求偏导数, 并称其为二阶偏导数. 二阶偏导数可记为 $f''_{ij}; i, j = 1, \dots, n$, 当自变量和因变量分别固定为 $\mathbf{x}, y$ 时, 也可记为 $\frac{\partial^2 y}{\partial x_i \partial x_j}(\mathbf{x})$. 函数 f 的二阶偏导数共计有 n^2 个, 我们将这 n^2 个二阶偏导数构成的 $n \times n$ 矩阵称为函数 f 的海瑟矩阵 (Hessian matrix), 其严格定义如下:

定义 1.1.12 (海瑟矩阵) 对于定义在 $X \subseteq \mathbb{R}^n$ 上的多元函数 $f(x_1, \dots, x_n)$, 若其所有二阶偏导数 $f''_{i,j}(\mathbf{x}), i, j = 1, 2, \dots, n$ 在定义域内均存在且为连续函数, 则函数 f 的海瑟矩阵定义为由所有二阶偏导数构成的矩阵, 即:

$$H_f(\mathbf{x}) := \begin{pmatrix} f''_{11}(\mathbf{x}) & \cdots & f''_{1n}(\mathbf{x}) \\ \vdots & & \vdots \\ f''_{n1}(\mathbf{x}) & \cdots & f''_{nn}(\mathbf{x}) \end{pmatrix}.$$

海瑟矩阵也可以有多种记法, 可借用梯度符号的记号记作 $\nabla^2 f(\mathbf{x})$, 也可借用一元函数导数的记号记为 $f''(\mathbf{x})$.

小贴士

根据克莱罗定理（或施瓦茨定理），如果函数的二阶偏导数连续（深度学习中的问题基本均满足这一条件），那么混合偏导数与求导次序无关，即：

$$f''_{ij}(\mathbf{x}) = f''_{ji}(\mathbf{x}).$$

此时海瑟矩阵是一个**实对称矩阵**.

我们同样给出若干实例来演示海瑟矩阵的求法.

例 1.1.13 对于常数矩阵 $A = (a_{ij}) \in \mathbb{R}^{n \times n}$ （不一定为对称矩阵），定义函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$,

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top A \mathbf{x}.$$

我们先求其关于第 i 个分量的一阶偏导数. f 中关于 x_i 所有项为：

$$\frac{1}{2} a_{ii} x_i^2 + \frac{1}{2} \sum_{k=1, k \neq i}^n (a_{ik} + a_{ki}) x_k x_i,$$

因此关于 x_i 的偏导数为

$$f'_i(\mathbf{x}) = a_{ii} x_i + \frac{1}{2} \sum_{k=1, k \neq i}^n (a_{ik} + a_{ki}) x_k = \frac{1}{2} \sum_{k=1}^n (a_{ik} + a_{ki}) x_k.$$

进一步考虑第 i 个偏导数如何求关于 x_j 的二阶偏导数，由于其为线性函数，我们可以很容易得到

$$f''_{ij} = \frac{1}{2} (a_{ij} + a_{ji}).$$

整合所有二阶偏导数，我们可以求得函数 f 的海瑟矩阵为：

$$H_f(\mathbf{x}) = \frac{1}{2} (A + A^\top),$$

特别地，如果 A 本身为实对称矩阵，则 $H_f(\mathbf{x}) = A$.

例 1.1.14 继续考虑例 1.1.7,

$$f(\mathbf{x}) = \ln(x_1^2 + \cdots + x_n^2),$$

每个分量的偏导数为

$$f'_i(\mathbf{x}) = \frac{2x_i}{x_1^2 + \cdots + x_n^2}.$$

对于二阶偏导数，我们分别考虑 $j = i$ 与 $j \neq i$ 的情形：当 $j = i$ 时，

$$f''_{ii}(\mathbf{x}) = \frac{2(x_1^2 + \cdots + x_n^2) - 4x_i^2}{(x_1^2 + \cdots + x_n^2)^2};$$

当 $j \neq i$ 时,

$$f''_{ij}(\mathbf{x}) = \frac{-4x_i x_j}{(x_1^2 + \cdots + x_n^2)^2}.$$

因此我们可以整合得到该函数的海瑟矩阵为

$$H_f(\mathbf{x}) = \frac{2(\mathbf{x}^\top \mathbf{x})I - 4\mathbf{x}\mathbf{x}^\top}{(\mathbf{x}^\top \mathbf{x})^2}.$$

例 1.1.15 设训练数据为

$$\mathbf{X} \in \mathbb{R}^{N \times d}, \quad \mathbf{y} \in \mathbb{R}^N,$$

考虑线性回归的平方损失函数

$$f(\mathbf{w}) = \frac{1}{2N} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2.$$

将其展开为

$$f(\mathbf{w}) = \frac{1}{2N} (\mathbf{w}^\top \mathbf{X}^\top \mathbf{X} \mathbf{w} - 2\mathbf{y}^\top \mathbf{X} \mathbf{w} + \mathbf{y}^\top \mathbf{y}).$$

根据二次型函数的求导公式, 函数梯度为

$$\nabla f(\mathbf{w}) = \frac{1}{N} \mathbf{X}^\top (\mathbf{X} \mathbf{w} - \mathbf{y}).$$

进一步求其二阶偏导数, 得到海瑟矩阵

$$H_f(\mathbf{w}) = \frac{1}{N} \mathbf{X}^\top \mathbf{X}.$$

注意到

$$H_f(\mathbf{w}) \succeq 0,$$

因此线性回归的平方损失函数是凸函数. 当 $\mathbf{X}$ 列满秩时,

$$H_f(\mathbf{w}) \succ 0,$$

此时损失函数严格凸.

例 1.1.16 考虑带有 L_2 正则项的岭回归目标函数

$$f_\lambda(\mathbf{w}) = \frac{1}{2N} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \frac{\lambda}{2} \|\mathbf{w}\|_2^2,$$

其中 $\lambda \geq 0$ 为正则化参数. 根据前一个例子, 第一项的梯度为

$$\frac{1}{N} \mathbf{X}^\top (\mathbf{X} \mathbf{w} - \mathbf{y}),$$

而正则项的梯度为

$$\nabla \left(\frac{\lambda}{2} \|\mathbf{w}\|_2^2 \right) = \lambda \mathbf{w}.$$

因此

$$\nabla f_\lambda(\mathbf{w}) = \frac{1}{N} \mathbf{X}^\top (\mathbf{X} \mathbf{w} - \mathbf{y}) + \lambda \mathbf{w}.$$

进一步得到海瑟矩阵

$$H_{f_\lambda}(\mathbf{w}) = \frac{1}{N} X^\top X + \lambda I.$$

当 $\lambda > 0$ 时,

$$H_{f_\lambda}(\mathbf{w}) \succ 0,$$

因此岭回归目标函数严格凸.

例 1.1.17 设训练数据为

$$\{(\mathbf{x}_i, y_i)\}_{i=1}^N, \quad \mathbf{x}_i \in \mathbb{R}^d, \quad y_i \in \{0, 1\}.$$

逻辑回归模型定义为

$$p_i = \sigma(\mathbf{w}^\top \mathbf{x}_i) = \frac{1}{1 + \exp(-\mathbf{w}^\top \mathbf{x}_i)}.$$

其平均交叉熵损失可以写为

$$L(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N [\ln(1 + \exp(\mathbf{w}^\top \mathbf{x}_i)) - y_i \mathbf{w}^\top \mathbf{x}_i].$$

根据链式法则, 函数梯度为

$$\nabla L(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N (p_i - y_i) \mathbf{x}_i.$$

再次求导可得

$$H_L(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N p_i(1 - p_i) \mathbf{x}_i \mathbf{x}_i^\top.$$

令

$$D = \text{Diag}(p_1(1 - p_1), \dots, p_N(1 - p_N)),$$

并令 X 的第 i 行为 $\mathbf{x}_i^\top$, 则海瑟矩阵可以写为

$$H_L(\mathbf{w}) = \frac{1}{N} X^\top D X.$$

由于 $p_i(1 - p_i) \geq 0$, 因此

$$H_L(\mathbf{w}) \succeq 0,$$

从而逻辑回归的交叉熵损失函数是凸函数.

1.1.4* 可微性

我们下面简要介绍一下可微性 (differentiability) 的概念. 该概念为链式法则, 以及复合函数微分求导法则做铺垫, 不要求掌握. 我们给出二元函数的可微性的定义, 多元函数可以以此类推.

定义 1.1.18 (可微性) 设函数 $z = f(x, y)$ 在点 (x_0, y_0) 的一个邻域中有定义, 我们记 $\Delta z := f(x_0 + \Delta x, y_0 + \Delta y) - f(x_0, y_0)$, 其中 $\Delta x, \Delta y$ 为两个自由变元. 如果 Δz 可表示为

$$\Delta z = A\Delta x + B\Delta y + o(\rho), \quad (1.1)$$

其中 A, B 是两个不依赖于 $\Delta x, \Delta y$ 的常数, $\rho := \sqrt{(\Delta x)^2 + (\Delta y)^2}$, 则我们称函数 $f(x, y)$ 在点 (x_0, y_0) 处可微. 增量形式(1.1)可以等价地写作如下微分形式: **【** 高阶无穷小 **】**

$$dz = A dx + B dy$$

小贴士

使用微分符号 $d(\cdot)$ 的形式为非严谨形式, 通常只用于理论快速推导, 在物理等领域中应用频率更高. 如果需要严谨证明, 请回退至增量形式(1.1).

可微性的定义相比偏导数的定义稍强一些. 事实上, 如果函数 $z = f(x, y)$ 在 (x_0, y_0) 处可微, 那么它一定在 (x_0, y_0) 处可导, 且它的偏导数正是 A 与 B . 这是因为, 当我们固定 $\Delta y = 0$,

$$f'_x(x_0, y_0) = \lim_{\Delta x \rightarrow 0} \frac{\Delta z}{\Delta x} = \lim_{\Delta x \rightarrow 0} \left(A + \frac{o(|\Delta x|)}{\Delta x} \right) = \lim_{\Delta x \rightarrow 0} (A + o(1)) = A.$$

同理得 $f'_y(x_0, y_0) = B$. 从而我们通常直接将函数 f 的微分形式写为:

$$dz = \frac{\partial z}{\partial x} dx + \frac{\partial z}{\partial y} dy.$$

可微性的重要性在于, 其揭示了两个自变量分量对于因变量的影响可以表达为简单的线性加和形式. 相比于偏导数一次只能聚焦于一个分量, 可微性则一次性考虑了自变量的所有分量, 因此可微性通常也可以叫做“全微分”(total differential), 与偏导数形成对照. 一般地, 假如自变量为 $\mathbf{x} \in \mathbb{R}^n$, 且函数 $z = f(\mathbf{x})$ 的梯度已知为 $\nabla f(\mathbf{x})$, 则微分形式可以紧凑地记为如下格式 (注意此时梯度为行向量):

$$dz = \nabla f(\mathbf{x})^\top d\mathbf{x}.$$

小贴士

在一元函数中, 由于微分的形式不变性, 我们可以用 dz/dx 来表示导数. 然而在多元函数中, 由于我们没有向量相除的运算, $(\times) dz/d\mathbf{x}$ 的形式是没有意义的, 不能用来表示梯度.