

1.2 线性映射与矩阵相似

我们在本节考虑线性映射、线性变换以及矩阵的相似. 注意本节中考虑的域为任意一般的域, 不只局限于实数域 $\mathbb{R}$.

1.2.1 线性映射

我们先考虑一般域 F (实数域、复数域或其他域) 上的线性空间中定义的线性映射 (linear mapping), 随后说明线性映射在 n 维实数向量空间中必然具有 $\mathbf{y} = A\mathbf{x}$ 的形式.

定义 1.2.1 (线性映射) 设 U, V 为两个定义在域 F 上的线性空间, 如果一个映射 $T: U \rightarrow V$ 满足线性条件:

$$T(c_1\mathbf{u}_1 + \cdots + c_s\mathbf{u}_s) = c_1T(\mathbf{u}_1) + \cdots + c_sT(\mathbf{u}_s), \quad \forall c_1, \dots, c_s \in F; \forall \mathbf{u}_1, \dots, \mathbf{u}_s \in U,$$

则 T 称为一个线性映射.

我们回忆线性空间中的基的概念. n 维线性空间 U 中存在 n 个线性无关的向量 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n$, 使得对于任意一个 $\mathbf{u} \in U$, 均可以表示为基向量线性组合的形式, 即

$$\mathbf{u} = c_1\mathbf{e}_1 + c_2\mathbf{e}_2 + \cdots + c_n\mathbf{e}_n.$$

根据线性映射的定义, 我们有

$$T(\mathbf{u}) = c_1T(\mathbf{e}_1) + c_2T(\mathbf{e}_2) + \cdots + c_nT(\mathbf{e}_n).$$

因此, 我们只需给出 U 中的 n 个基向量的线性映射的结果, 就可以掌握该线性映射的全部信息. 我们设陪域空间 V 的维度为 m , 记 $\mathbf{v}_1 = T(\mathbf{e}_1), \dots, \mathbf{v}_n = T(\mathbf{e}_n)$ 为 U 中 n 个基向量在 V 中的线性映射的像, 我们有如下的紧凑的记号:

$$T(\mathbf{e}_1, \dots, \mathbf{e}_n) := (T(\mathbf{e}_1), \dots, T(\mathbf{e}_n)) = (\mathbf{v}_1, \dots, \mathbf{v}_n).$$

小贴士

$T(\mathbf{e}_1, \dots, \mathbf{e}_n)$ 仅为紧凑记号, 并非表示对矩阵作线性变换, 计算时需要将其展开.

下面我们考虑将 U, V 具体化为 n 维、 m 维的实数向量空间. 如果我们取 $\mathbf{e}_1, \dots, \mathbf{e}_n$ 为标准正交基, 即 $\mathbf{e}_1 = (1, 0, \dots, 0)^\top, \dots, \mathbf{e}_n = (0, 0, \dots, 1)^\top \in \mathbb{R}^n$, 它们在线性映射 T 下的像为 $\mathbf{v}_1, \dots, \mathbf{v}_n \in \mathbb{R}^m$, 我们可以将其排列为一个矩阵 $A = (\mathbf{v}_1, \dots, \mathbf{v}_n) \in \mathbb{R}^{m \times n}$. 考

考虑 $U = \mathbb{R}^n$ 中的任何一个向量 $\mathbf{x} = (x_1, \dots, x_n)^\top$, 我们有

$$\begin{aligned} T(\mathbf{x}) &= T(x_1\mathbf{e}_1 + x_2\mathbf{e}_2 + \cdots + x_n\mathbf{e}_n) \\ &= x_1T(\mathbf{e}_1) + x_2T(\mathbf{e}_2) + \cdots + x_nT(\mathbf{e}_n) \\ &= x_1\mathbf{v}_1 + x_2\mathbf{v}_2 + \cdots + x_n\mathbf{v}_n \\ &= (\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n)\mathbf{x} = A\mathbf{x}. \end{aligned}$$

从而我们证明了, $\mathbb{R}^n$ 上的任何一个线性映射均可以写为 $\mathbf{y} = A\mathbf{x}$ 的形式, 且 A 为 $\mathbb{R}^n$ 中标准正交基在该线性映射下的像构成的矩阵.

1.2.2 线性变换

线性映射考虑两个不同的线性空间, 而如果我们考虑线性空间 U 到自身的映射, 我们则称其为线性变换 (linear transformation).

我们同样使用基向量的视角来研究线性映射. 由于线性变换是线性空间 U 到自身的映射, 我们可以使用同一套基向量来同时表示映射前与映射后的向量. 对于 U 中的基向量 $\mathbf{e}_1, \dots, \mathbf{e}_n$, 线性变换 T 作用在每个基向量上得到的向量同样可以由基向量表示, 即:

$$T(\mathbf{e}_j) = a_{1j}\mathbf{e}_1 + \cdots + a_{nj}\mathbf{e}_n, \quad j = 1, \dots, n,$$

我们可以得到如下紧凑的格式:

$$T(\mathbf{e}_1, \dots, \mathbf{e}_n) = (\mathbf{e}_1, \dots, \mathbf{e}_n) \begin{pmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{n1} & \cdots & a_{nn} \end{pmatrix} := (\mathbf{e}_1, \dots, \mathbf{e}_n)A.$$

我们称上述的式子为线性变换 T 在基向量 $\mathbf{e}_1, \dots, \mathbf{e}_n$ 下的矩阵表示.

如果 U 为 n 维实数向量空间 $\mathbb{R}^n$, 基向量 $\mathbf{e}_1, \dots, \mathbf{e}_n$ 为标准正交基, 那么对于任意 $\mathbf{x} \in \mathbb{R}^n$, 不难得到此时 $T(\mathbf{x}) = A\mathbf{x}$, 这与我们上文得到的结论是一致的. 然而, 如果基向量 $\mathbf{e}_1, \dots, \mathbf{e}_n$ 不是 $\mathbb{R}^n$ 上的标准正交基, 那么此时得到的新的矩阵 A' 与标准正交基下的矩阵 A 之间有什么关系呢? 我们下面对其进行探究.

设 $\mathbf{e}_1, \dots, \mathbf{e}_n$ 以及 $\mathbf{e}'_1, \dots, \mathbf{e}'_n$ 为 $\mathbb{R}^n$ 上的两个基, 由于它们二者之间可以互相表出, 因此必存在一个可逆矩阵 $P = (\mathbf{p}_1, \dots, \mathbf{p}_n)$ 使得

$$(\mathbf{e}'_1, \dots, \mathbf{e}'_n) = (\mathbf{e}_1, \dots, \mathbf{e}_n)P, \quad (\mathbf{e}_1, \dots, \mathbf{e}_n) = (\mathbf{e}'_1, \dots, \mathbf{e}'_n)P^{-1}.$$

在已知 $T(\mathbf{e}_1, \dots, \mathbf{e}_n) = (\mathbf{e}_1, \dots, \mathbf{e}_n)A$ 的情况下,

$$T(\mathbf{e}'_j) = T((\mathbf{e}_1, \dots, \mathbf{e}_n)\mathbf{p}_j) = \sum_{i=1}^n p_{ij}T(\mathbf{e}_i)$$

$$\begin{aligned}
&= \sum_{i=1}^n p_{ij} (\mathbf{e}_1, \dots, \mathbf{e}_n) \begin{pmatrix} a_{1i} \\ \vdots \\ a_{ni} \end{pmatrix} = (\mathbf{e}_1, \dots, \mathbf{e}_n) \sum_{i=1}^n p_{ij} \begin{pmatrix} a_{1i} \\ \vdots \\ a_{ni} \end{pmatrix} \\
&= (\mathbf{e}_1, \dots, \mathbf{e}_n) \begin{pmatrix} \sum_{i=1}^n a_{1i} p_{ij} \\ \vdots \\ \sum_{i=1}^n a_{ni} p_{ij} \end{pmatrix} = (\mathbf{e}_1, \dots, \mathbf{e}_n) (AP)_{\cdot, j},
\end{aligned}$$

其中 $(AP)_{\cdot, j}$ 表示矩阵 AP 的第 j 列构成的列向量. 从而我们有

$$T(\mathbf{e}'_1, \dots, \mathbf{e}'_n) = (\mathbf{e}_1, \dots, \mathbf{e}_n) AP = (\mathbf{e}'_1, \dots, \mathbf{e}'_n) P^{-1} AP.$$

即我们有 A' 与 A 之间的关系为 $A' = P^{-1} AP$.

小贴士

得到 $(AP)_{\cdot, j}$ 的过程并不直接, 需要一些经验与洞察力. 有关矩阵及张量线性运算的系统理论可以参考爱因斯坦求和约定 (Einstein summation convention).

1.2.3 矩阵相似、特征值与特征向量

上一小节我们得到, 一个线性空间中的一个线性变换在不同基向量下的矩阵表示具有形如 $A' = P^{-1} AP$ 的关系, 事实上这是矩阵理论中十分重要的一个关系, 我们称其为相似关系 (similarity):

定义 1.2.2 (相似矩阵) 给定方形矩阵 $A \in F^{n \times n}$, 对于另一相同形状的矩阵 $A' \in F^{n \times n}$, 若存在可逆矩阵 $P \in F^{n \times n}$ 使得

$$A' = P^{-1} AP,$$

则称矩阵 A' 与矩阵 A 相似.

根据相似矩阵的定义, 我们可以很容易证明其满足自反性 (任意矩阵 A 与其自身相似)、对称性 (若矩阵 A 与 B 相似, 则矩阵 B 与 A 也相似)、传递性 (若矩阵 A 与 B 相似, B 与 C 相似, 则矩阵 A 与 C 相似).

相似矩阵有以下三个重要性质:

1. **秩相等**: 即 $\text{rank}(A') = \text{rank}(P^{-1} AP) = \text{rank}(A)$, 因为可逆矩阵 P 相当于对原先矩阵做初等行列变换, 不会改变原先的秩.
2. **迹相等**: 即 $\text{tr}(A') = \text{tr}(P^{-1} AP) = \text{tr}(APP^{-1}) = \text{tr}(A)$ [**** 定义 tr ****].
3. **行列式相等**: 即 $|A'| = |P^{-1} AP| = |P^{-1}| |A| |P| = |P|^{-1} |A| |P| = |A|$.

在实际计算中, 直接判定 A, B 两个矩阵是否相似并不容易. 一个较为可行的思路是, 对于两个给定的矩阵 A, B , 我们是否可以找到某种意义下最为简单的矩阵 D , 如果矩阵 A, B 均与 D 相似, 那么矩阵 A 与矩阵 B 也相似. 打一比方, 在不借助地图或是导航等工具等情况下, 判断两个人的家是否离得较近并不容易, 然而, 如果两个人的家附近都有同一个很明显的标志性建筑物, 我们便可以断定两人的家离得也不会很远.

在矩阵的世界中, **对角矩阵**可以充当这些明显的标志性建筑物. 如果两个矩阵均相似于同一个对角矩阵, 则这两个矩阵也相似. 而且对角矩阵的另一个重要性质是, 两个对角矩阵相似当且仅当两个对角矩阵的对角元素在不考虑顺序的情况下完全相同 (这一性质的证明需要用到特征多项式的代数性质, 因此在这里省略), 这一性质保证了对角矩阵可以作为某种程度上唯一的标志物, 便可作为一种标准. 因此我们称对角矩阵为所有与其相似的矩阵的**标准形**.

小贴士

并非所有的矩阵都能相似于一个对角矩阵, 譬如矩阵 $\begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$, 无论如何右上角的非对角元均不能消去. 这些矩阵的标准形需要采用对角矩阵以外的其他形式. 而我们更多感兴趣的矩阵还是能够相似于对角矩阵的矩阵, 我们称这些矩阵为“可对角化”的矩阵.

现假设矩阵 $A \in \mathbb{R}^{n \times n}$ 相似于一个对角矩阵 $D = \text{Diag}\{\lambda_1, \dots, \lambda_n\}$, 则存在一个可逆矩阵 $P = (\mathbf{p}_1, \dots, \mathbf{p}_n)$ 使得

$$A(\mathbf{p}_1, \dots, \mathbf{p}_n) = (\mathbf{p}_1, \dots, \mathbf{p}_n) \begin{pmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{pmatrix} = (\lambda_1 \mathbf{p}_1, \dots, \lambda_n \mathbf{p}_n).$$

因此我们可以看到, 如果 A 相似于对角矩阵, 那么有 n 个实数与 n 个 n 维向量满足

$$A\mathbf{p}_i = \lambda_i \mathbf{p}_i, \quad i = 1, \dots, n.$$

这表示, 如果将 A 视为一个线性变换, 那么 A 作用在向量 $\mathbf{p}_1, \dots, \mathbf{p}_n$ 上, 就相当于对它们分别进行 $\lambda_1, \dots, \lambda_n$ 倍的缩放. $\lambda_i, \mathbf{p}_i, i = 1, \dots, n$ 分别称为矩阵 A 的特征值 (eigenvalue) 和特征向量 (eigenvector), 其中前缀 “eigen-” 来自德语, 表示 “固有的、本征的”, 读作 /'aigen/. 特征值与特征向量的严格定义如下:

定义 1.2.3 (特征值与特征向量) 给定方形矩阵 $A \in F^{n \times n}$, 若存在 $\lambda \in F$, 及非零向量

$\mathbf{p} \in F^n$ 满足

$$A\mathbf{p} = \lambda\mathbf{p},$$

则称 λ 为矩阵 A 的一个特征值, 称 $\mathbf{p}$ 为特征值 λ 对应的一个特征向量.

对于实际问题中的一个方形矩阵 $A \in \mathbb{R}^{n \times n}$, 计算其特征值与特征向量有固定的步骤, 具体分为如下两步:

1. **计算特征值**: 如果 λ 为矩阵 A 的特征值, 则一定存在一个非零的特征向量 $\mathbf{p}$ 使得 $(\lambda I - A)\mathbf{p} = 0$, 根据齐次线性方程组的结论, 有行列式 $|\lambda I - A| = 0$. 事实上, $|\lambda I - A|$ 构成了一个关于变量 λ 的 n 次多项式, 我们称其为矩阵 A 的**特征多项式** (characteristic polynomial), 求解该多项式的所有根便可求出矩阵 A 的所有特征值.
2. **计算特征向量**: 对于已经求出的一个特征值 λ , 我们可以求解齐次线性方程组 $(\lambda I - A)\mathbf{p} = 0$ 来求出该特征值对应的所有特征向量.

小贴士

1. 不难证明, 如果向量 $\mathbf{p}$ 为特征值 λ 的一个特征向量, 则对于任意 $c \in F \setminus \{0\}$, $c\mathbf{p}$ 也为特征值 λ 的一个特征向量; 如果一个特征值 λ 有多个线性无关的特征向量 $\mathbf{p}_1, \dots, \mathbf{p}_r$, 则它们的任意非零线性组合 $c_1\mathbf{p}_1 + \dots + c_r\mathbf{p}_r$; $c_1, \dots, c_r \in F$ 也为特征值 λ 的一个特征向量. 因此同一个特征值的所有特征向量, 连同零向量, 构成了一个子空间, 称为**特征子空间** (eigen-subspace).
2. 互相相似的矩阵有相同的特征值, 但通常有着不同的特征向量.
3. 特征多项式 $|\lambda I - A|$ 中的一个根 λ 可能是多重根, 我们称 λ 在特征多项式中的重数为**代数重数** (algebraic multiplicity).
4. 一个特征值 λ 对应的特征子空间的维度为特征值 λ 的**几何重数** (geometric multiplicity).
5. 如果矩阵 A 可以对角化, 那么它的每一个特征值的代数重数与几何重数必须相等.

我们最后用一个实例来结束本节的内容:

例 1.2.4 考虑 $\mathbb{R}^{2 \times 2}$ 上的线性变换 T :

$$\begin{pmatrix} y_1 \\ y_2 \end{pmatrix} = A \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}.$$

矩阵 A 就是线性变换 T 在标准正交基 $(1, 0)^\top, (0, 1)^\top$ 下的矩阵表示.

我们下面先求矩阵 A 的特征值, 其特征多项式为:

$$|\lambda I - A| = \begin{vmatrix} \lambda - 3 & -1 \\ -1 & \lambda - 3 \end{vmatrix} = (\lambda - 3)^2 - 1 = (\lambda - 4)(\lambda - 2).$$

特征多项式的两个根分别为 4 和 2, 它们即为矩阵 A 的特征值.

下面我们分别求两个特征值对应的特征向量. 先求 $\lambda = 4$ 的特征向量, 我们解如下的其次线性方程组:

$$4I - A = \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix} \begin{pmatrix} p_1 \\ p_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix},$$

易解得其解集为 $\{c_1(1, 1)^\top | c_1 \in \mathbb{R}\}$. 除去零向量后就是特征值 4 对应的特征向量. 同理我们解得特征值 2 的特征向量为 $\{c_2(-1, 1)^\top | c_2 \in \mathbb{R} \setminus \{0\}\}$.

我们取两个易于计算的特征向量 $\mathbf{p}_1 = (1, 1)^\top$, $\mathbf{p}_2 = (-1, 1)^\top$ 来构造相似矩阵. 记 $P = (\mathbf{p}_1, \mathbf{p}_2)$, $D = \text{Diag}\{4, 2\}$, 我们有:

$$AP = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix} = PD = \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 4 & 0 \\ 0 & 2 \end{pmatrix},$$

即矩阵 A 与矩阵 D 相似.

我们下面考虑使用上述的特征向量构建另一个基:

$$(\mathbf{e}'_1, \mathbf{e}'_2) = (\mathbf{e}_1, \mathbf{e}_2) \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix} = P,$$

新基与原先的基下坐标表示关系满足

$$\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = (\mathbf{e}_1, \mathbf{e}_2) \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = (\mathbf{e}'_1, \mathbf{e}'_2) \begin{pmatrix} x'_1 \\ x'_2 \end{pmatrix} = P \begin{pmatrix} x'_1 \\ x'_2 \end{pmatrix},$$

则原线性变换在新的基下的坐标表示为

$$\begin{pmatrix} y'_1 \\ y'_2 \end{pmatrix} = P^{-1} \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} = P^{-1} A \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = P^{-1} A P \begin{pmatrix} x'_1 \\ x'_2 \end{pmatrix} = D \begin{pmatrix} x'_1 \\ x'_2 \end{pmatrix}.$$

因此, 从几何角度来看, 矩阵 A 对平面中向量的变换, 就相当于分别沿着特征向量 $(1, 1)^\top, (-1, 1)^\top$ 方向放大特征值 4, 2 倍. 如果将坐标系变换为以 $(1, 1)^\top, (-1, 1)^\top$ 为两个坐标轴, 则矩阵 A 就相当于沿着两个轴的方向做缩放变换. 图 1.1 为其示意图.

占位

图 1.1: 矩阵 A 作为线性变换矩阵示意图

1.3 多元向量值函数及其性质

最初, 我们考虑了 (单值) 多元函数, 即自变量为向量, 而因变量为标量的函数. 然而, 我们上一节考虑的线性映射的因变量则是一个向量. 因此, 本节我们将系统考虑多元向量值函数, 即自变量为向量, 因变量也为向量的函数, 并探究其微分性质及其与多元函数的关系.

1.3.1 雅各比矩阵

多元向量值函数的定义如下:

定义 1.3.1 (多元向量值函数) 设 X 为实数集 $\mathbb{R}^n$ 中的一个子集, 如果存在一个对应法则 f , 使得对于任意 $\mathbf{x} = (x_1, x_2, \dots, x_n) \in X$, 都存在唯一 $\mathbf{y} = (y_1, y_2, \dots, y_m) \in \mathbb{R}^m$ 与之对应, 则称 f 为定义在 X 上 (陪域为 $\mathbb{R}^m$) 的 n 元 m 维向量值函数, 记作:

$$f: X \rightarrow \mathbb{R}^m; \quad \mathbf{x} \mapsto \mathbf{y} = f(\mathbf{x}) = \begin{pmatrix} f_1(x_1, x_2, \dots, x_n) \\ f_2(x_1, x_2, \dots, x_n) \\ \vdots \\ f_m(x_1, x_2, \dots, x_n) \end{pmatrix}.$$

由于向量值函数可以视为由 m 个普通多元函数拼合而成, 因此每个多元函数 $y_i = f_i(\mathbf{x})$ 均可分别求出所有偏导数和梯度. 事实上, 我们可以将每个多元函数的梯度用行向量的形式写出, 并纵向拼合成一个矩阵, 该矩阵即为多元向量值函数 f 的雅各比矩阵 (Jacobian matrix).

定义 1.3.2 (雅各比矩阵) 对于定义在 $X \subseteq \mathbb{R}^n$ 上的多元向量值函数 $f(\mathbf{x}) \in \mathbb{R}^m$, 若其所有分量的所有偏导数 $(f_i)'_j(\mathbf{x}), i = 1, 2, \dots, m; j = 1, 2, \dots, n$ 在定义域内均存在且为连

续函数，则函数 $\mathbf{f}$ 的雅各比矩阵定义为由因变量的所有分量关于自变量的所有分量求偏导所构成的矩阵，即：

$$J_{\mathbf{f}}(\mathbf{x}) := \begin{pmatrix} (f_1)'_1(\mathbf{x}) & \cdots & (f_1)'_n(\mathbf{x}) \\ \vdots & & \vdots \\ (f_m)'_1(\mathbf{x}) & \cdots & (f_m)'_n(\mathbf{x}) \end{pmatrix} = \begin{pmatrix} \nabla f_1(\mathbf{x})^\top \\ \vdots \\ \nabla f_m(\mathbf{x})^\top \end{pmatrix}.$$

同样，雅各比矩阵也有不止一种表示方式，我们也可以直接借用一元函数中的导数记号，将其记为 $\mathbf{f}'(\mathbf{x})$. 此外，在机器学习相关研究中，当因变量固定为 $\mathbf{y}$ 时，有时会使用偏导数记号 $\frac{\partial \mathbf{y}}{\partial \mathbf{x}}$ 来不严谨地代表雅各比矩阵，为了不易混淆，本书后续内容中如果使用这一偏导数形式的记号，都会进行说明。

以下两个例子演示了雅各比矩阵的求解过程：

例 1.3.3 我们考虑线性映射这一多元向量值函数. 设函数 $\mathbf{f} : \mathbb{R}^n \rightarrow \mathbb{R}^m$,

$$\mathbf{f}(\mathbf{x}) = A\mathbf{x}, \quad A \in \mathbb{R}^{m \times n},$$

记因变量为 $\mathbf{y} = A\mathbf{x}$, 则因变量的每个分量为：

$$y_i = a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n,$$

相应地每个分量的偏导数为

$$\frac{\partial y_i}{\partial x_j} = a_{ij},$$

从而该函数的雅各比矩阵即为

$$J_{\mathbf{f}}(\mathbf{x}) = A.$$

例 1.3.4 Softmax 函数用于将一系列实数映射为一个抽样时的概率分布，具体的函数形式为 $\mathbf{s} : \mathbb{R}^n \rightarrow \mathbb{R}^n$,

$$s_i(\mathbf{x}) = \frac{e^{x_i}}{e^{x_1} + \cdots + e^{x_n}}.$$

我们下面考虑每个 s_i 关于 x_j 的偏导数. 如果 $j = i$, 则

$$(s_i)'_i(\mathbf{x}) = \frac{e^{x_i}}{e^{x_1} + \cdots + e^{x_n}} - \frac{e^{x_i} e^{x_i}}{(e^{x_1} + \cdots + e^{x_n})^2};$$

如果 $j \neq i$, 则

$$(s_i)'_j(\mathbf{x}) = -\frac{e^{x_i} e^{x_j}}{(e^{x_1} + \cdots + e^{x_n})^2}.$$

为使得我们的记号更加简便，我们固定因变量 $\mathbf{y} = \mathbf{s}(\mathbf{x})$, 则 Softmax 函数的雅各比矩阵可表示为：

$$J_{\mathbf{s}}(\mathbf{x}) = \text{Diag}(\mathbf{y}) - \mathbf{y}\mathbf{y}^\top.$$

我们可以观察到, Softmax 函数的雅各比矩阵可以使用因变量进行较为简单的表示, 这在前反向传播中具有一定的优势.

1.3.2 梯度作为向量值函数、雅各比矩阵与海瑟矩阵的联系

对于一个多元函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, 我们可以求得它的 $n \times n$ 维海瑟矩阵; 而对于多元向量值函数 $g: \mathbb{R}^n \rightarrow \mathbb{R}^n$, 我们同样可以求得它的 $n \times n$ 维的雅各比矩阵. 我们自然要问, 两个矩阵之间有着什么样的联系呢?

对于函数 f , 我们会去思考其中是否蕴含一个多元向量值函数, 其定义域与陪域均为 $\mathbb{R}^n$, 事实上这样的向量值函数确实存在, 而且就是 f 的梯度: 我们知道, 函数 f 的每个偏导数都为 n 元函数, 而梯度的定义便是将这 n 个偏导数拼合成为一个向量. 因此可以很自然地将梯度 ∇f 视为一个 n 元的 n 维向量值函数, 即:

$$\nabla f: \mathbb{R}^n \rightarrow \mathbb{R}^n; \quad \mathbf{x} \mapsto \mathbf{y} = \nabla f(\mathbf{x}) = (f'_1(\mathbf{x}), \dots, f'_n(\mathbf{x}))^\top,$$

注意此时梯度应写为列向量. 进一步, 如果我们对这一多元向量值函数求雅各比矩阵, 我们可以得到:

$$J_{\nabla f}(\mathbf{x}) = \begin{pmatrix} f''_{11}(\mathbf{x}) & \cdots & f''_{1n}(\mathbf{x}) \\ \vdots & & \vdots \\ f''_{n1}(\mathbf{x}) & \cdots & f''_{nn}(\mathbf{x}) \end{pmatrix}.$$

我们惊喜地发现, 这恰好是函数 f 的海瑟矩阵. 因此我们有如下重要结论: **多元函数 f 的海瑟矩阵, 等价于其梯度作为多元向量值函数时的雅各比矩阵.**

我们下面用一个十分常用的实例来进一步展现上述结论的魅力:

例 1.3.5 考虑如下的 n 元函数:

$$f: \mathbb{R}^n \rightarrow \mathbb{R}; \quad f(\mathbf{x}) = \log(e^{x_1} + e^{x_2} + \cdots + e^{x_n}),$$

该函数通常称为“log-sum-exp 函数”, 或“指数和对数函数”. 它的函数取值大约比 $\max\{x_1, x_2, \dots, x_n\}$ 稍大一些, 而且具有 $\max$ 函数不具有的可求导的性质, 因此可以视为求最大值函数的平滑版本. 我们下面先求它的偏导数:

对任意 $i = 1, 2, \dots, n$,

$$f'_i(\mathbf{x}) = \frac{e^{x_i}}{e^{x_1} + \cdots + e^{x_n}}.$$

我们惊奇地发现, 这一函数的梯度 $\nabla f(\mathbf{x})$ 正是例 1.3.4 中的 Softmax 函数. 因此, 我们无需进行下一步计算, 便可直接断言函数 f 的海瑟矩阵即为 Softmax 函数的雅各比矩阵,

即：

$$H_f(\mathbf{x}) = J_s(\mathbf{x}) = \text{Diag}(\nabla f(\mathbf{x})) - \nabla f(\mathbf{x})\nabla f(\mathbf{x})^\top.$$

从这一例子中我们可以窥探出 Softmax 函数名称的由来，因为以 Softmax 为导数的原函数——log-sum-exp 函数的作用就是求一组数的平滑的、柔性的最大值。但由于历史原因，其导数反而被称为 Softmax 函数。事实上，在机器学习领域中，Softmax 函数确实相比 log-sum-exp 函数更加常用。因为相比于最大值的具体取值，我们更关心取得最大值的那个分量是哪一个，即取出 Softmax 函数输出的概率分布中最大的那个分量，这一操作在机器学习模型决定最终输出时广为使用。

1.3.3 链式法则

我们在第 1.1.4 节中介绍了全微分的概念，其包含两个版本：其中一个为增量形式的可微性，它是一个比可导性更强一些的性质，主要用于理论分析；另一个为微分形式的表达式，主要用于不严谨的导数推导。使用严谨的增量微分往往需要较为复杂的数学分析技巧来分析高阶余项的误差，而使用不严谨的微分形式通常能够大幅度简化推导过程，只要我们断言所研究的函数对象性质足够好，高阶余项的误差始终保持为小量即可。下面我们介绍一个为链式法则推导作准备的引理，并提供使用微分形式的简洁的证明。

引理 1.3.6 (菱形求导法则) 设二元函数 $g(u, v) : \mathbb{R}^2 \rightarrow \mathbb{R}$ ，而 $u(x), v(x)$ 均为关于 x 的一元函数，考虑复合一元函数 $f(x) := g(u(x), v(x))$ ，其导数为：【**插图**】

$$f'(x) = g'_1(u(x), v(x))u'(x) + g'_2(u(x), v(x))v'(x).$$

证明. 我们记 $y = g(u(x), v(x))$ ，则

$$dy = \frac{\partial y}{\partial u} du + \frac{\partial y}{\partial v} dv = \frac{\partial y}{\partial u} \frac{du}{dx} dx + \frac{\partial y}{\partial v} \frac{dv}{dx} dx = \left(\frac{\partial y}{\partial u} \frac{du}{dx} + \frac{\partial y}{\partial v} \frac{dv}{dx} \right) dx$$

根据微分形式，我们可以倒推出函数 f 的导数的具体表达形式。 ■

上述引理可以自然推广至除 u, v 外更多中间变量的情形，同时结合多元函数求不同分量偏导数的并行性、向量值函数不同维度求导的并行性，我们可以得出如下的有关多元向量值函数的链式法则：

定理 1.3.7 (链式法则) 考虑两个多元向量值函数

$$\mathbf{g} : \mathbb{R}^n \rightarrow \mathbb{R}^m, \mathbf{y} = \mathbf{g}(\mathbf{x}); \quad \mathbf{h} : \mathbb{R}^m \rightarrow \mathbb{R}^l, \mathbf{z} = \mathbf{h}(\mathbf{y}),$$

设它们的雅各比矩阵分别为 $\mathbf{g}'(\mathbf{x}), \mathbf{h}'(\mathbf{y})$. 定义复合函数

$$\mathbf{f} : \mathbb{R}^n \rightarrow \mathbb{R}^l, \quad \mathbf{z} = \mathbf{f}(\mathbf{x}) = \mathbf{h}(\mathbf{g}(\mathbf{x})),$$

则它的雅各比矩阵为:

$$\mathbf{f}'(\mathbf{x}) = \mathbf{h}'(\mathbf{g}(\mathbf{x}))\mathbf{g}'(\mathbf{x}).$$

证明. 对于向量值函数 $\mathbf{z} = \mathbf{f}(\mathbf{x})$, 考虑 $\mathbf{z}$ 的第 i 维对 $\mathbf{x}$ 的第 j 个分量求偏导数, 则此时我们有:

$$z_i = h_i(g_1(x_1, \dots, x_j, \dots, x_n), \dots, g_m(x_1, \dots, x_j, \dots, x_n)),$$

由于除 x_j 外的其余自变量分量均固定, 因此此时 $g_1, \dots, g_m$ 即为关于 x_j 的一元函数, 我们可以使用上述的菱形求导法则 (引理 1.3.6), 得到:

$$\frac{\partial z_i}{\partial x_j} = \sum_{k=1}^m (h_i)'_k(g(\mathbf{x})) \cdot (g_k)'_j(\mathbf{x}).$$

将所有 $i = 1, \dots, l; j = 1, \dots, n$ 计算并拼合成 $l \times n$ 维矩阵即可得到最终结果. ■

小贴士

上述链式法则针对向量值函数, 然而也能退化至普通的多元函数情形, 只需令因变量的维度为 1 即可. 需要注意的是, 因变量维度为 1 的向量值函数的雅各比矩阵是其对应的多元函数的**行梯度**. 如果想要转化为列梯度, 需要进行转置操作. 为了不易混淆, 在涉及链式法则时, 我们使用导数记号 $f'(\mathbf{x})$ 来表示行梯度, 其与雅各比矩阵是相合的; 而用算子记号 $\nabla f(\mathbf{x})$ 来表示列梯度.

在一元函数中, 链式法则求导可以写为紧凑且优雅的形式

$$\frac{dz}{dx} = \frac{dz}{dy} \frac{dy}{dx},$$

或是微分形式

$$dz = \frac{dz}{dy} \frac{dy}{dx} dx.$$

在多元函数中, 我们同样有相应的微分形式:

$$dz = \mathbf{h}'(\mathbf{y})\mathbf{g}'(\mathbf{x})d\mathbf{x}.$$

然而, 请不要写成导数形式

$$(\times) \quad \frac{dz}{d\mathbf{x}} = \mathbf{h}'(\mathbf{y})\mathbf{g}'(\mathbf{x}),$$

也不要将雅各比矩阵写成 $(\times) \frac{dy}{dx}$. 这是因为, 一元函数中微分具有形式不变性, 可以直观理解为导数与微分直接相除的结果是一致的. 而在多元函数中, 我们不存在向量间相除的定义. 上述的错误记号仅是形式表示, 不具有实际意义.

我们下面用两个使用链式法则的实例来结束本节内容:

例 1.3.8 设矩阵 $A \in \mathbb{R}^{m \times n}$, 向量 $\mathbf{b} \in \mathbb{R}^m$, 多元函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$,

$$f(\mathbf{x}) = \frac{1}{2}(\mathbf{Ax} - \mathbf{b})^\top (\mathbf{Ax} - \mathbf{b}),$$

试求其 (列) 梯度.

解: 考虑外层函数 $h(\mathbf{y}) = \frac{1}{2}\mathbf{y}^\top \mathbf{y}$ 与内层函数 $\mathbf{y} = \mathbf{g}(\mathbf{x}) = \mathbf{Ax} - \mathbf{b}$, 分别参考例 1.1.4 与例 1.3.3, 我们求得 h 的行梯度为: $h'(\mathbf{y}) = \mathbf{y}^\top$; $\mathbf{g}$ 的雅各比矩阵为 $\mathbf{g}'(\mathbf{x}) = A$, 因此根据链式法则, 我们可以求得函数 f 的行梯度为:

$$f'(\mathbf{x}) = h'(\mathbf{g}(\mathbf{x}))\mathbf{g}'(\mathbf{x}) = (\mathbf{Ax} - \mathbf{b})^\top A.$$

转置为列梯度可得:

$$\nabla f(\mathbf{x}) = A^\top (\mathbf{Ax} - \mathbf{b}).$$

例 1.3.9 设向量 $\mathbf{a} \in \mathbb{R}^n$, 常数 $c \in \mathbb{R}$, 多元函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$,

$$f(\mathbf{x}) = \ln(1 + e^{-c\mathbf{a}^\top \mathbf{x}}),$$

试求其 (列) 梯度.

解: 考虑外层函数 $h(y) = \ln(1 + e^{-y})$ 与内层函数 $y = \mathbf{g}(\mathbf{x}) = c\mathbf{a}^\top \mathbf{x}$. 外层函数 $h(y)$ 为一个一元函数, 易求得其导数为:

$$h'(y) = \frac{-e^{-y}}{1 + e^{-y}} = \frac{-1}{1 + e^y}.$$

内层函数 $\mathbf{g}(\mathbf{x})$ 为多元函数, 通过分别计算偏导数易得到其行梯度为

$$\mathbf{g}'(\mathbf{x}) = c\mathbf{a}^\top.$$

因此根据链式法则, 我们可以得到函数 f 的行梯度为:

$$f'(\mathbf{x}) = h'(\mathbf{g}(\mathbf{x}))\mathbf{g}'(\mathbf{x}) = \frac{-c\mathbf{a}^\top}{1 + e^y},$$

转置为列梯度, 并代入 y 可得:

$$\nabla f(\mathbf{x}) = \frac{-c}{1 + e^{c\mathbf{a}^\top \mathbf{x}}} \mathbf{a}.$$