第二章　概率与统计

2.1　事件及其概率

生活中充满了随机事件，对于随机事件发生的可能性大小进行度量就产生了概率. 从纯数学角度来讲，概率可以通过公理化体系来定义；而从实际意义角度，概率通常认为是在大量且可重复的独立实验中，某事件发生的频率的极限. 在本节我们将要学习事件的定义、概率及其基本的性质.

2.1.1 样本空间与事件

想要研究一个随机对象（譬如骰子），首先我们需要进行试验，得到随机对象的所有可能的确定的结果（即将骰子掷出去）. 每一次化随机为某个确定的结果的试验过程就称为一次**采样**（sample）. 该随机对象的每一个可能的结果就称为一个**样本点**（sample point），所有样本点构成了该随机对象的**样本空间**（sample space），通常记为 Ω. 样本空间中的元素可以是有限的，如掷硬币的 $\{\text{正}, \text{反}\}$，掷骰子的 $\{1, 2, 3, 4, 5, 6\}$, 也可以是无限的，如 $(0, 1]$(单位 m) 的长度值等.

有了样本空间，我们可以定义事件（events），事件即定义为**样本空间中的一个子集**，通常用大写字母 $A, B \ldots$ 来表示. 如“掷骰子数值 ≤ 3”，“掷硬币为正面”均可视为事件.

由于事件本质为上为样本空间的集合，我们可以有事件的包含关系：$A \subset B$ 即表示所有属于 A 的样本点也属于 B, 或者可以理解为事件 A 发生，则事件 B 一定发生. 事件 A 也可以取补集，即样本空间中所有不属于 A 的样本点构成的集合，我们称这一事件为原事件 A 的**对立事件**（complementary events）或**逆事件**，记作 $\bar{A}$. 事件之间可以进行取并集运算 $A \cup B$, 表示两个事件至少有一个发生；也可以进行取交集运算，$A \cap B$, 表示两个事件同时发生，$A \cap B$ 通常简写为 AB.

Yuan and Song

特别地，当 $A\cap B=\varnothing$ 时，我们称事件 A,B 为**互斥事件**或**互不相容事件**（exclusive events）. 事件 A 与其对立事件 $\bar{A}$ 一定是互斥事件. 如果事件 A,B 互斥，此时我们称 $A\cup B$ 为两个事件的和，可以改记为 $A+B$.

事件的运算满足如下的定理，它们本质上都是通过集合理论推导得出的结论：

1. 交换律：$A\cup B=B\cup A,\ AB=BA.$
2. 结合律：$(A\cup B)\cup C=A\cup(B\cup C),\ (AB)C=A(BC).$
3. 分配律：$(A\cup B)C=(AC)\cup(BC),\ (AB)\cup C=(A\cup C)(B\cup C).$
4. 德摩根（De Morgan）律：$\overline{A\cup B}=\bar{A}\bar{B},\ \overline{AB}=\bar{A}\cup\bar{B}.$

例 2.1.1 (把日常语言写成事件) 掷一次骰子，样本空间为 $\Omega=\{1,2,3,4,5,6\}$. 设 $A=$“点数为偶数”，$B=$“点数不超过 *3*”，则

$$A=\{2,4,6\},\quad B=\{1,2,3\},\quad AB=\{2\},\quad A\cup B=\{1,2,3,4,6\}.$$

“两个条件都不满足”对应 $\overline{A\cup B}=\{5\}$；“两个条件没有同时满足”对应 $\overline{AB}=\{1,3,4,5,6\}$. 前者要求既不是偶数也不小于等于 *3*，后者只要求至少有一个条件不满足，二者是不同的事件.

另外，$C=$“点数大于 *4*”与 B 互斥，但 $B\cup C=\{1,2,3,5,6\}\neq\Omega$，所以互斥事件未必互为对立事件.

2.1.2 概率模型

到目前为止，我们仅对一个随机对象给出了所有的样本点，并且划分了事件，但并未对其分配概率. 以下两种概率模型分别从离散与连续的角度给出了对于事件概率的基本合理的定义.

定义 2.1.2 (古典概型) 假设样本空间 Ω 的样本点个数为有限个，且 n 个样本点中每个样本点 $\omega_1,\ldots,\omega_n$ 被采样到的机会都是均等的，那么对于一个事件 $A\subset\Omega$, 假如其包含的样本点个数为 m 个，则定义事件 A 的概率为：

$$P(A)=m/n.$$

我们用一个实例演示古典概型如何使用：

例 2.1.3 考虑先后独立地掷两枚硬币，假设硬币的质地均匀，掷出正反面的机会是均等的，则此时我们可以将样本空间写作：

$$\Omega=\{(正,正),(正,反),(反,正),(反,反)\}.$$

Yan and Song

事件 $A=$“第一次掷出正面”，共包含 *2* 个样本点，因此 $P(A)=1/2$.

事件 $B=$“第二次掷出正面”，共包含 *2* 个样本点，因此 $P(B)=1/2$.

事件 $C=$“两次均掷出正面”，共包含 *1* 个样本点，因此 $P(C)=1/4$.

事件 $D=$“至少一次掷出正面”，共包含 *3* 个样本点，因此 $P(D)=3/4$.

例 2.1.4 (等可能的是样本点，而不一定是点数之和) 独立地掷两枚均匀骰子，求点数之和为 *7* 的概率. 用有序数对 (i,j) 记录两枚骰子的点数，样本空间共有 $6\times 6=36$ 个等可能的样本点. 点数之和为 *7* 的样本点为

$$(1,6),(2,5),(3,4),(4,3),(5,2),(6,1),$$

所以所求概率为 $6/36=1/6$.

虽然点数之和可以取 $2,3,\ldots,12$ 这 *11* 个数，但它们并不等可能. 例如和为 *2* 只有 $(1,1)$ 这一种情形，其概率为 $1/36$. 因此不能把“和为 *7*”的概率写成 $1/11$；使用古典概型时，必须先确认所选的基本结果等可能.

通过上述掷硬币的例子，我们可以引出另一种事件间的相互关系. 从直观上来讲，第一次掷硬币的结果与第二次掷硬币的结果理应没有关系，它们二者之间应当是相互独立的. 从计算结果来看，我们有 $P(C)=P(AB)=P(A)P(B)$. 我们下面引入独立事件（independent events）的定义：

定义 2.1.5 (独立事件) 设 A,B 为同一个样本空间中的两个事件，若其满足

$$P(AB)=P(A)P(B),$$

则称事件 A,B 相互独立.

小贴士

两个事件相互独立的定义较为直接，而多个事件之间相互独立的定义则较为复杂，需要保证从所有事件中任取若干个事件，它们的交集的概率均为这些取定的事件的概率的乘积.

例 2.1.6 (互斥与独立是两回事) 掷一次均匀骰子，设 $A=$“点数为偶数”，$B=$“点数不超过 *3*”，则

$$P(A)=\frac{1}{2},\quad P(B)=\frac{1}{2},\quad P(AB)=\frac{1}{6}\neq\frac{1}{4}=P(A)P(B).$$

因此 A,B 既不互斥，也不独立. 若改取 $C=$“点数不超过 *4*”，则 $AC=\{2,4\}$，有

$$P(AC)=\frac{2}{6}=\frac{1}{2}\times\frac{4}{6}=P(A)P(C),$$

Yuan and Song

所以 A, C 相互独立，即使它们来自同一次掷骰子试验.

再取 $D =$“点数为奇数”, 则 A, D 互斥, 却不独立, 因为 $P(AD) = 0$ 而 $P(A)P(D) = 1/4$. 一般地，两个概率均为正的互斥事件不可能独立.

例 2.1.7 (两两独立还不够) 独立地掷两枚均匀硬币，设 $A =$“第一枚为正面”，$B =$“第二枚为正面”，$C =$“两枚朝向相同”. 这三个事件的概率均为 $1/2$，任意两个同时发生的概率均为 $1/4$，所以它们两两独立.

但 ABC 只包含“两枚均为正面”这一个结果，故

$$P(ABC) = \frac{1}{4} \neq \frac{1}{8} = P(A)P(B)P(C).$$

因此三个事件并不相互独立. 判断多个事件的相互独立性，只检查每一对事件是不够的.

回到最初掷两枚硬币的例子，沿用其中的事件 A, B, D，我们也观察到，

$$\boxed{P(D) = P(A \cup B) = P(A) + P(B) - P(AB),}$$

这一等式可以从集合的视角较为容易地推导出，这也是概率计算中普遍成立的一个等式. 特别地，当 A, B 为互斥事件时，我们有

$$\boxed{P(A \cup B) = P(A + B) = P(A) + P(B),}$$

后者一般称作**加法公式**.

例 2.1.8 (至少一个发生与对立事件) 某设备有两套独立工作的备用模块，每套模块在一次任务中正常工作的概率均为 0.9. 设 A, B 分别表示两套模块正常工作，则“至少一套正常工作”的概率为

$$P(A \cup B) = 0.9 + 0.9 - 0.9 \times 0.9 = 0.99.$$

也可以先求“两套都失效”的概率，得到

$$P(A \cup B) = 1 - P(\bar{A}\bar{B}) = 1 - 0.1^2 = 0.99.$$

前一种方法扣除了重复计算的“两套都正常工作”，后一种方法利用了对立事件. 若有 n 套这样的独立模块，至少一套正常工作的概率就是 $1 - 0.1^n$.

最后，从古典概型的计算中，我们可以总结出概率作为样本空间上所有事件的函数，所满足的三条性质：

1. **非负性**：对于任意事件 A, $P(A) \geq 0$.
2. **规范性**：样本空间上全集 Ω 的概率 $P(\Omega) = 1$.
3. **可列可加性**：若事件 $A_1, A_2, \ldots$ 互斥，则有 $P(A_1 + A_2 + \cdots) = P(A_1) + P(A_2) + \cdots$.

Yuan and Song

实际上，上述三条性质即为概率的公理化定义中的三条基本公理.

由于古典概型只能处理样本空间容量有限的情形，对于无限但是可以度量的情形，我们相对应地引入几何概型：

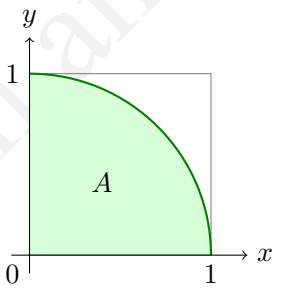
定义 2.1.9 (几何概型) 假设样本空间 Ω 是可测的，其测度（长度、面积、体积等）是 M，满足 $0 < M < \infty$，且采样在 Ω 上相对于这一测度均匀分布，即等测度的可测区域被采样到的概率相同. 那么对于一个事件 A, 假如其对应 Ω 的可测子集测度为 m, 则定义事件 A 的概率为：

$$P(A) = m/M.$$

我们同样用实例来演示几何概型的使用方法：

例 2.1.10 在区间 $[0,1]$ 内独立、均匀地取两个实数 x, y, 考虑事件 $A =$ “$x^2 + y^2 \leq 1$” 的概率.

我们将 x, y 的取值画在一个平面直角坐标系中. 其中样本空间 $\Omega = \{(x,y)|0 \leq x, y \leq 1\}$ 为一个正方形，其面积为 1. 而事件 $A = \{(x,y)|0 \leq x, y \leq 1, x^2 + y^2 \leq 1\}$ 为四分之一圆，其面积为 $\pi/4$. 因此事件 A 的概率即为 $P(A) = \pi/4$.



例 2.1.11 (约会问题中的面积法) 两人约定在一小时内到达某处，各自的到达时刻在这一小时内独立、均匀分布. 先到的人最多等待 *15* 分钟，求两人能够见面的概率.

以分钟为单位记录两人的到达时刻 x, y,样本空间是 $[0,60]^2$,见面条件为 $|x-y| \leq 15$. 不能见面的区域是正方形中满足 $y > x + 15$ 或 $x > y + 15$ 的两个直角三角形，每个三角形的直角边长均为 *45*. 因此

$$P(\text{见面}) = 1 - \frac{2 \times \frac{1}{2} \times 45^2}{60^2} = \frac{7}{16}.$$

这里并不是“等待时间占一小时的 $1/4$，所以见面概率就是 $1/4$”；需要度量的是两个到达时刻共同构成的平面区域.

Yuanang Song

小贴士

对于几何概型，有关“样本空间究竟关于哪种测量方式是均匀的”在某些问题中会有不唯一的回答，也会进一步导致概率计算的差异. 经典反例可参看贝特朗（Bertrand）奇论. 这一问题也进一步推动了概率的定义朝着公理化方向发展，即仅规定概率满足的最基本性质，而将具体概率值的计算从概率定义中剥离出来.

除古典概型和几何概型之外，在实际生活中，我们有时也会通过长期观察事件发生的频率来估计事件的概率，随后使用事件之间的关系来推导更加复杂的事件的概率. 下一小节我们将讨论，在已经给定某些事件的概率后，如何求更复杂的事件的概率，其中最基本的概念即为**条件概率**.

2.1.3 条件概率、全概率公式与贝叶斯公式

对于掷骰子问题，我们想要探究：在已知掷出的点数小于等于 3 的情况下，掷出的点数为 1 的概率进一步是多少？直观告诉我们，掷出点数小于等于 3 共有 3 种情形，而掷出点数为 1 是其中的一种，因此上述概率应当为 $\frac{1}{3}$. 我们记事件“掷出点数小于等于 3”为事件 A,“掷出的点数为 1”为事件 B, 我们一般记“已知掷出的点数小于等于 3 的情况下，掷出的点数为 1”的概率为 $P(B|A)$, 进一步我们发现，

$$P(B|A)=\frac{1}{3}=\frac{\frac{1}{6}}{\frac{3}{6}}=\frac{P(AB)}{P(A)},$$

这实际上是一个普遍成立的等式，也是条件概率（conditional probability）的严格定义方式.

定义 2.1.12 (条件概率) 设 A, B 为同一个样本空间中的两个事件，且 $P(A)>0$, 记

$$P(B|A)=\frac{P(AB)}{P(A)},$$

为已知事件 A 发生的条件下事件 B 发生的概率，即条件概率.

有时候，条件概率可能是更加直观或是更容易求出的值，而我们通常可以利用条件概率反过来求得交事件的概率，即

$$\boxed{P(AB)=P(A)P(B|A),}$$

该公式一般被称作**乘法公式**. 乘法公式可以通过递推的方式推广到多个事件的情形中：

$$\begin{aligned} P(A_1A_2\cdots A_n) &= P(A_1A_2\cdots A_{n-1})P(A_n|A_1A_2\cdots A_{n-1}) \\ &= \cdots \\ &= P(A_1)P(A_2|A_1)P(A_3|A_1A_2)\cdots P(A_n|A_1A_2\cdots A_{n-1}). \end{aligned}$$

例 2.1.13 (不放回抽样与乘法公式) 袋中有 *3* 个红球和 *2* 个蓝球，每次等可能地摸出一个球，连续摸两次且不放回. 设 $A=$“第一次为红球”，$B=$“第二次为红球”. 已知 A 发生后，袋中只剩 *2* 个红球和 *2* 个蓝球，故

$$P(B|A)=\frac{2}{4}=\frac{1}{2},\qquad P(AB)=P(A)P(B|A)=\frac{3}{5}\times\frac{2}{4}=\frac{3}{10}.$$

不能将 $P(AB)$ 写成 $(3/5)^2$，因为第一次摸球改变了第二次面对的球的组成. 若继续摸第三个球，三次均为红球的概率为

$$\frac{3}{5}\times\frac{2}{4}\times\frac{1}{3}=\frac{1}{10}.$$

每一步的条件概率都应根据前面已经发生的结果重新计算.

我们下面考虑如下情形：现在我们刚刚完成高考，我们想估计我们上北京大学的希望有多大. 直接估计这一概率并不容易，但我们可以查阅资料大概了解到，位于不同分数段的同学报考北京大学被录取的比率是多少，从而估计相应的概率；同时我们又可以根据自己高中时的经验，大致给出自己能够考到各个分数段的概率，那么就可以最终给出上北京大学的概率大致为多少了.

我们下面将上述过程抽象为一般的概率问题. 首先，我们需要像分数段一样的一组事件 $A_1,\ldots,A_n$, 它们满足两两互斥，且并集为全集 Ω, 我们称这样的事件为**完备事件组**，或称它们构成了样本空间的一个**分割**. 以下假设各 $P(A_i)>0$，以便使用相应的条件概率. 随后，任给一个事件 B, 利用事件的分配律，我们有：

$$B=B\cap\Omega=B\cap(A_1\cup A_2\cup\cdots\cup A_n)=(BA_1)\cup(BA_2)\cup\cdots\cup(BA_n),$$

且我们注意到 $(BA_1),\ldots,(BA_n)$ 之间也是两两互斥的，这是因为

$$(BA_i)\cap(BA_j)=B\cap(A_i\cap A_j)=B\cap\varnothing=\varnothing,\quad 1\le i,j\le n,\ i\ne j.$$

从而使用加法公式，我们有

$$\boxed{P(B)=\sum_{i=1}^{n}P(A_iB)=\sum_{i=1}^{n}\big(P(A_i)P(B|A_i)\big),}$$

这一公式通常被称为**全概率公式**，它体现了概率论中分而治之的思想. 我们下面举一个具体的实例.

yuan wilson

例 2.1.14 箱子中有 a 个黄球与 b 个蓝球，其中 a,b 为正整数，小明和小红两人先后等可能地摸球. 小明先摸出一个球后不放回，求小红摸出黄球的概率.

在不知道小明摸球结果时，由抽取位置的对称性，我们猜测小红摸出黄球的概率仍为 $a/(a+b)$. 但若已知小明摸出的颜色，小红摸出黄球的条件概率会随之改变，所以两人的摸球结果并不独立. 下面我们尝试使用全概率公式来计算未获知小明摸球结果时的概率.

显然“小明摸出黄球”与“小明摸出蓝球”为一个完备事件组，我们分别记为 A_1, A_2，同时我们也可以直接求得小明摸出一个球后，小红摸出黄球的条件概率，我们记“小红摸出黄球”为事件 B，其概率的计算如下：

$$\begin{aligned} P(B) &= P(B|A_1)P(A_1) + P(B|A_2)P(A_2) = \frac{a-1}{a+b-1}\frac{a}{a+b} + \frac{a}{a+b-1}\frac{b}{a+b} \\ &= \frac{a(a+b-1)}{(a+b)(a+b-1)} = \frac{a}{a+b} \end{aligned},$$

也就是说，小红在小明后摸出黄球的概率，与第一次小明摸出黄球的概率相同，均为 $a/(a+b)$，这就是抽签结果与抽签顺序无关的原理.

例 2.1.15 (全概率公式是按来源加权) 某仓库的零件有 60% 来自甲工厂、40% 来自乙工厂，两厂零件的次品率分别为 1% 和 3%. 从仓库中等可能地取一个零件，求它为次品的概率.

设 A_1, A_2 分别表示“来自甲厂”和“来自乙厂”，B 表示“为次品”. A_1, A_2 构成完备事件组，因此

$$P(B) = 0.6 \times 0.01 + 0.4 \times 0.03 = 0.018.$$

所以总体次品率为 1.8%，而不是两厂次品率的简单平均值 2%. 每种来源的条件概率必须按该来源所占比例加权.

最后，我们再来介绍一下**贝叶斯公式**（Bayesian Equation），它完全使用已有的条件概率与全概率公式的工具，但却体现着截然不同的思想.

定义 2.1.16 (贝叶斯公式) 给定事件 $A_1, \ldots, A_n$ 为一个完备事件组，满足 $P(A_i) > 0$，及另一个事件 B，满足 $P(B) > 0$，已知 $P(B|A_i), \forall i = 1, \ldots, n$，我们有

$$P(A_i|B) = \frac{P(A_iB)}{P(B)} = \frac{P(B|A_i)P(A_i)}{\sum_{j=1}^{n} P(B|A_j)P(A_j)}.$$

从公式本身来看，贝叶斯公式只是将条件概率与全概率公式组合了起来，但其背后却有着深刻的意义. 在许多应用中，A_i 表示某种可能的来源或原因，B 表示观测到的结果，$P(B|A_i)$ 描述已知来源时结果出现的概率. 贝叶斯公式则求已知结果时各个来源的

概率，体现了“由果溯因”的逆向思维，因此也往往称为**逆概率公式**. 不过，条件概率本身并不要求两个事件存在时间先后或因果关系. 我们下面用一个具体实例来加深印象：

例 2.1.17 小明上学经常迟到，如果是普通的晴天，那么小明上学迟到的概率为 40%; 如果下雨，则小明上学迟到的概率高达 80%. 根据以往经验及统计数据，小明居住的城市在当下季节有 50% 的概率会下雨. 而小明今天上学果然迟到了. 那么根据小明已经迟到了这一已知信息，我们需要反推今天确实下雨了这件事的概率.

设“下雨”为事件 A, “小明迟到”为事件 B, 则

$$P(A)=0.5,\quad P(B|A)=0.8,\quad P(B|\bar{A})=0.4,$$

根据贝叶斯公式，我们有

$$P(A|B)=\frac{P(B|A)P(A)}{P(B|A)P(A)+P(B|\bar{A})P(\bar{A})}=\frac{0.8\times 0.5}{0.8\times 0.5+0.4\times 0.5}=\frac{2}{3},$$

因此，在已知小明迟到的前提下，当天确实下雨的概率为 2/3.

从以上例子中我们可以看出，如果没有小明迟到这一信息，我们根据统计规律有当地下雨的概率为 1/2, 而我们已知了小明迟到，这就告诉我们当天小明确实更有可能遇到了下雨天，因此在小明迟到的前提下，下雨的概率上升至了 2/3. 事实上，在贝叶斯理论中，我们把原先完备事件组（如下雨和不下雨）的概率称为**先验概率**，将获知的某个事件（如小明迟到）称为一次**观测**，将该事件发生前提下原先完备事件组的条件概率称为**后验概率**. 在给定概率模型下，后验概率体现了观测信息对原有判断的更新.

例 2.1.18 (识别结果还要结合先验比例) 假设一批邮件中 10% 是垃圾邮件. 一个过滤器会把 90% 的垃圾邮件标记出来，同时误把 5% 的正常邮件也标记出来. 某封邮件被标记后，它确实是垃圾邮件的概率是多少？

设 $A=$“是垃圾邮件”，$B=$“被标记”，则

$$P(A|B)=\frac{0.9\times 0.1}{0.9\times 0.1+0.05\times 0.9}=\frac{2}{3}.$$

也可以用 *1000* 封邮件帮助理解：按上述比例，有 *100* 封垃圾邮件，其中 *90* 封被标记；*900* 封正常邮件中有 *45* 封被误标. 因此被标记的 *135* 封中，垃圾邮件所占比例为 $90/135=2/3$.

注意，90% 描述的是 $P(B|A)$，题目求的是 $P(A|B)$，二者不能直接互换. 若垃圾邮件的先验比例改变，即使过滤器的两项识别概率不变，后验概率也会改变.

2.2　随机变量、分布与数学期望

在上一节中，我们定义了样本空间，它可以是有限的离散的数、可以是无限但可数的离散的数，也可以是在某个区间中连续的数，当然也有可能不是以数字的形式存在的，如比赛胜负的结果等. 然而，对于统计学家来讲，大家更希望将所有的这些形式不同的样本空间都用数字来表达，以便可以使用数学的工具进行更深入的研究. 譬如我们可以将比赛胜利记为 1，失败记为 0, 这样就可以将非数字的样本空间转化为数字的样本空间. 对于更加复杂的样本空间我们也可以相应地设计更加复杂的转化方式，将它们都转换为数字. 对于这些以数字形式存在的随机对象，我们便将其称为**随机变量**（Random variables），通常用大写字母 X, Y, Z 等来表示.

2.2.1 随机变量与分布

根据随机变量的性质，我们可以将其分为两类：一类为**离散随机变量**，它的取值是一些离散的数值，如 $1, 2, 3, \ldots$, 可以是有限个也可以是无限个；另一类为**连续随机变量**, 它的取值为实数轴 $\mathbb{R}$ 上的一段连续区域，如 $[0, 1]$, 其长度可以是有限的，也可以是无限长的，甚至是实数轴本身.

对于一个随机变量 X，我们可以沿用事件的方式，关注随机变量取值范围中的一个子集，并给出它的概率. 然而，子集的数量是庞大的，求出所有子集对应的事件的概率并不容易. 既然我们已经将样本空间转化为了数字，那么就可以很好地利用数字的特征. 数字的一个很好的特点就是可以在其上很方便地定义函数. 我们可以使用**分布**（Distribution）的概念，来描述随机变量具体是以什么样的方式、什么样的概率，在数轴上分布的. 我们需要对离散随机变量与连续随机变量的分布进行分别定义.

离散随机变量的分布定义较为直接，参照古典概型，每个取值均可作为一个基本事件，研究清楚了所有取值对应的概率，我们就可以对该随机变量有一个整体的把握.

定义 2.2.1 (离散随机变量的分布) 给定离散随机变量 X, 设其所有取值构成的集合为 $\mathcal{X}$, 定义以 $\mathcal{X}$ 为定义域的函数

$$f(x) := P(X = x), \quad x \in \mathcal{X},$$

为随机变量 X 的概率质量函数，也称分布列.

例 2.2.2 (随机变量把多个样本点合并为一个取值) 独立地掷两枚均匀硬币，令 X 表示正

面出现的次数. 四个等可能的样本点被映射为

$$(反,反)\mapsto 0,\quad (正,反),(反,正)\mapsto 1,\quad (正,正)\mapsto 2.$$

因此 X 的分布列为

$$f(0)=\frac{1}{4},\qquad f(1)=\frac{1}{2},\qquad f(2)=\frac{1}{4}.$$

这说明样本点等可能，并不意味着随机变量的不同取值也等可能. 求 $P(X\geq 1)$ 时，将相应取值的概率相加即可，得到 $1/2+1/4=3/4$.

对于连续随机变量，因为实数轴上的一个区间包含无数个点，随机变量取一个特定的点的概率基本都是 0. 有意义的是研究随机变量取值落在任意一段的概率，而一个比较好的排列方式就是从左至右以此扫描随机变量的取值范围并赋予相应的概率.

定义 2.2.3 (连续随机变量的分布) 给定连续随机变量 X, 定义以 $\mathbb{R}$ 为定义域的函数

$$F(x):=P(X\leq x),\quad x\in\mathbb{R},$$

为随机变量 X 的累积分布函数，简称分布函数.

小贴士

对于离散随机变量，我们要求所有取值的概率之和为 1, 即 $\sum_{x\in\mathcal{X}} f(x)=1$. 对于连续随机变量，它的累积分布函数是一个单调不减函数，且设其定义域左右端点分别为 a,b, 则有 $F(a)=0, F(b)=1$. 进一步，我们也可以将其延拓为一个定义在 $\mathbb{R}$ 上的函数，只需令 $F(x)=0, x\leq a; F(x)=1, x\geq b$ 即可. 事实上，在概率论中，我们通常认为连续随机变量的取值范围均是 $\mathbb{R}$，而将那些真正的可能取值的部分，即累积分布函数在上涨的区域称为随机变量的支撑（support）.

对于连续随机变量，相较累积分布函数，我们更常用的是**概率密度函数**（Probability Density Function）：

定义 2.2.4 (概率密度函数) 给定连续随机变量 X, 不妨设其取值范围为 $\mathbb{R}$, 已知其分布函数为 $F(x)$, 若存在另一函数 $f(x)$ 满足

$$F(x)=\int_{-\infty}^{x} f(t)\mathrm{d}t,$$

且 $f(x)\geq 0$，则称 $f(x)$ 为 X 的概率密度函数，简称密度函数.

多数情况下（譬如累积分布函数可微时），概率密度函数就是累积分布函数的导数，即 $f(x)=F'(x)$. 同时我们不难得出，随机变量支撑之外的区域内有 $f(x)\equiv 0$. 概率密

度函数的意义与物理中密度的意义相似. 物理中密度表示单位体积内的质量大小，而概率密度的含义就是在实数轴上单位长度内的概率大小. 概率密度函数的一个作用是，使用牛顿-莱布尼茨公式，对于任意 $a, b \in \mathcal{X}$, 我们有

$$P(a \leq X \leq b) = F(b) - F(a) = \int_a^b f(x)\mathrm{d}x,$$

因此我们可以使用积分来求出连续随机变量落入任何区间内的概率.

例 2.2.5 (从密度求分布函数与区间概率) 设随机变量 X 的密度函数为

$$f(x) = \begin{cases} cx, & 0 \leq x \leq 1, \\ 0, & \text{其他}, \end{cases}$$

求常数 c、分布函数 $F(x)$ 及 $P(1/2 < X \leq 1)$. 密度的总积分必须为 *1*，故

$$1 = \int_0^1 cx\mathrm{d}x = \frac{c}{2}, \qquad c = 2.$$

从左向右累积积分，得到

$$F(x) = \begin{cases} 0, & x < 0, \\ x^2, & 0 \leq x \leq 1, \\ 1, & x > 1. \end{cases}$$

所以 $P(1/2 < X \leq 1) = F(1) - F(1/2) = 3/4$. 虽然 $f(1) = 2 > 1$，但它是密度值，并不是事件的概率；任意单点仍有 $P(X = x) = 0$，区间概率则由密度的积分给出.

2.2.2 常用分布

人们的长相千姿百态，而我们在生活经验中总结出了“国字脸”、“瓜子脸”等具有代表性的脸型. 同样，随机变量的分布千姿百态，而统计学家们也总结出了一些常用的随机变量的分布的模式类型. 本小节我们来列举若干常用的分布类型，我们先介绍离散随机变量的分布，再介绍连续随机变量的分布.

我们首先考虑最简单的情形，当随机变量的取值只有两个时，我们只需要一个参数 p, 就可以完全确定随机变量的分布情况.

例 2.2.6 (伯努利分布/0-1 分布) 离散随机变量 X 取值为 $\{0, 1\}$, 给定常数 $p \in [0, 1]$, X 的分布为

$$f(1) = p, \quad f(0) = 1 - p.$$

称该分布为伯努利分布（*Bernoulli Distribution*），或 *0-1* 分布.

Yuan and Song

伯努利分布可以表示一个实验或是一场比赛成功或失败的概率. 而对于相互独立的 n 个实验或是 n 场比赛，每次的成功概率均是 p, 记累计成功的次数为 X, 则如何求 X 的分布呢？假设成功 x 次，这 x 次在 n 次中共计有 C_n^x 种，由于每次实验或比赛相互独立，我们可以直接使用相互独立事件的乘法公式求出每种情况的概率，并将 C_n^x 种情况加在一起求得总共的概率. 这就得到了二项分布.

例 2.2.7 (二项分布) 离散随机变量 X 取值为 $\{0,1,2,\ldots,n\}$, 给定常数 $p\in[0,1]$, X 的分布为

$$f(x)=C_n^x p^x(1-p)^{n-x},\quad x=0,1,2,\ldots,n.$$

称该分布为二项分布（*Binomial Distribution*），记为 $B(n,p)$, 其中 $n=1$ 时便退化为了伯努利分布.

例 2.2.8 (一次是否成功与多次成功的次数) 假设某服务每次请求成功的概率为 0.8，各次结果相互独立. 令 I 在一次请求成功时取 *1*，失败时取 *0*，则 I 服从参数 $p=0.8$ 的伯努利分布.

若连续发送 *5* 次请求，令 X 为成功次数，则 X 服从 $B(5,0.8)$. 恰好成功 *4* 次的概率为

$$P(X=4)=C_5^4(0.8)^4(0.2)=0.4096.$$

其中 $C_5^4=5$ 表示唯一一次失败可能出现在 *5* 个不同位置. 若问“至少成功一次”，用对立事件计算更简便：

$$P(X\geq 1)=1-P(X=0)=1-(0.2)^5=0.99968.$$

对于二项分布，如果 p 为有理数，即存在非负整数 m,M, 使得 $p=m/M$, 则我们可以将二项分布视为在含有 M 个小球，其中有 m 个是白球的箱子中，有放回地抽取 n 次，其中抽到白球的次数是多少. 相对应地，我们自然可以考虑如果不放回，那么抽取 n 次，抽到白球的个数有多少. 我们同样是使用古典概型的基本事件的方法，考虑抽到 x 个白球的事件包含多少个基本事件，这里 x 的取值最小是 $\max\{0,n-M+m\}$, 最大是 $\min\{m,n\}$. 总共的基本事件个数为组合数 C_M^n, 而抽到 x 个白球的基本事件有 $C_m^x\times C_{M-m}^{n-x}$ 个. 因此我们可以定义如下分布：

例 2.2.9 (超几何分布) 离散随机变量 X 取值为 $\mathcal{X}=\{a,a+1,\ldots,b\}$, 其中 $a=\max\{0,n-M+m\}$, $b=\min\{m,n\}$, X 的分布为：

$$f(x)=\frac{C_m^x\times C_{M-m}^{n-x}}{C_M^n},\quad x\in\mathcal{X}.$$

Yuan and Song

称该分布为超几何分布（*Hypergeometric Distribution*），记为 $H(n, M, m)$.

例 2.2.10 (有放回与不放回应选不同分布) *10* 个零件中有 *3* 个次品，等可能地抽取 *4* 个且不放回，令 X 为抽到的次品个数，则 X 服从 $H(4, 10, 3)$. 恰好抽到 *1* 个次品的概率为

$$P(X=1)=\frac{C_3^1C_7^3}{C_{10}^4}=\frac{3\times 35}{210}=\frac{1}{2}.$$

分子分别选择 *1* 个次品和 *3* 个正品，分母选择任意 *4* 个零件.

若改为每次抽后放回并充分混合，*4* 次抽取相互独立，此时 X 服从 $B(4, 0.3)$，相应概率变为

$$P(X=1)=C_4^1(0.3)(0.7)^3=0.4116.$$

是否放回改变了各次抽取之间的关系，因此也改变了所用的分布.

二项分布关注 n 次实验中总计成功的次数，而如果我们只关注第一次实验成功出现在什么时候，就得到了几何分布. 如果第一次实验成功出现在第 x 次，那么它的前 $x-1$ 次实验必定失败，因此相应的概率为 $p(1-p)^{x-1}$. 我们定义几何分布如下：

例 2.2.11 (几何分布) 离散随机变量 X 取值为 $\mathbb{N}_+ := \{1, 2, \dots\}$, 给定常数 $p \in (0, 1]$, X 的分布为：

$$f(x)=p(1-p)^{x-1},\quad x\in\mathbb{N}_+,$$

称该分布为几何分布（*Geometric Distribution*）.

小贴士

几何分布名称的由来为：几何分布的分布列概率相加构成了一个几何级数（即等比数列的无穷推广）. 而超几何分布之所以如此命名，是因为其分布函数的形式与超几何级数相似，而超几何级数的形式十分复杂，我们不进行讨论.

例 2.2.12 (第一次成功要等到什么时候) 每次独立尝试连接某服务器，成功概率均为 0.2，令 X 表示首次连接成功时的尝试次数，则 X 服从几何分布. 首次在第 *3* 次成功，要求前两次失败而第三次成功，所以

$$P(X=3)=(0.8)^2\times 0.2=0.128.$$

“尝试 *3* 次后仍未成功”则要求前三次全部失败，故 $P(X>3)=(0.8)^3=0.512$. 进一步，

$$P(X>5\mid X>3)=\frac{(0.8)^5}{(0.8)^3}=(0.8)^2=P(X>2).$$

在各次尝试独立且成功概率不变的模型中，已经失败 3 次，不会改变接下来两次仍然失败的概率. 这一性质称为无记忆性.

我们下面考虑一个具体场景：消防站一天内可能会接到若干次 119 火警电话，我们想探究一天内接到火警电话次数的随机规律. 我们理论上可以将其建模为二项分布，即将全城每个人视为一次独立实验，而每个人在一天内以一定的概率拨打 119，我们假设一个人不会在一天内拨打两次 119. 然而，这样建模的二项分布，n 极大，可能是几万到几百万不等，而 p 极小，因为险情的发生是小概率事件. 因此这样建模的二项分布随机变量 X, 只有极少一部分接近于 0 的取值概率是比较显著的，其他较大的取值对应的概率基本十分趋近于 0，但是它们的计算依然需要用到组合数，十分消耗计算资源. 因此，我们需要寻求近似的、且计算较为简单的另一个分布. 我们注意到，$\lambda := np$ 可能是一个比较适中的数字，而当 x 较大时，二项分布的分布函数为

$$\begin{aligned} f(x) = C_n^x p^x (1-p)^{n-x} &= \frac{n(n-1)\cdots(n-x+1)}{x!}\left(\frac{\lambda}{n}\right)^x \left(1-\frac{\lambda}{n}\right)^{n-x} \\ &= \frac{\lambda^x}{x!}\cdot\left(1-\frac{1}{n}\right)\left(1-\frac{2}{n}\right)\cdots\left(1-\frac{x-1}{n}\right)\cdot\left(1-\frac{\lambda}{n}\right)^{n-x}. \end{aligned}$$

当 x 远小于 n 时，上式中除了首尾两个因子，中间所有的因子值都十分接近于 1，而对于最后一个因子，我们根据微积分的基本结论：

$$\lim_{n\to\infty}\left(1-\frac{\lambda}{n}\right)^{n-x} = e^{-\lambda},$$

因此我们可以得出一个分布函数形如 $f(x) = \dfrac{\lambda^x}{x!}e^{-\lambda}$, 而我们使用泰勒公式不难验证，上述分布函数满足完备性，即所有取值的概率之和为 1. 因此我们给出如下的分布定义：

例 2.2.13 (泊松分布) 离散随机变量 X 取值为 $\mathbb{N} := \{0, 1, 2, \dots\}$, 给定常数 $\lambda \geq 0$, X 的分布为：

$$f(x) = \frac{\lambda^x}{x!}e^{-\lambda}, \quad x \in \mathbb{N},$$

称该分布为泊松分布（*Poisson Distribution*）.

例 2.2.14 (把平均到达次数代入泊松分布) 假设某窗口每分钟收到的请求数 X 服从参数 $\lambda = 2$ 的泊松分布，则一分钟内恰好收到 3 次请求的概率为

$$P(X=3) = \frac{2^3}{3!}e^{-2} = \frac{4}{3}e^{-2} \approx 0.1804,$$

至少收到一次请求的概率为 $1 - P(X=0) = 1 - e^{-2} \approx 0.8647$.

参数 λ 对应指定时间段的平均次数. 如果在相应的泊松到达模型中，半分钟内的请求数服从参数 $\lambda = 1$ 的泊松分布，那么半分钟内没有请求的概率为 e^{-1}，不能继续代入

一分钟所用的参数 *2*.

我们下面考虑连续随机变量的分布. 首先我们考虑最简单的分布——均匀分布. 它是几何概型在随机变量语境下的另一种表述.

例 2.2.15 (均匀分布) 连续随机变量 X 取值为 $[a,b]$, a,b 为有限的常数，X 的密度函数为

$$f(x)=\frac{1}{b-a},\quad x\in[a,b],$$

称该分布为均匀分布（*Uniform Distribution*），记为 $U[a,b]$.

例 2.2.16 (均匀分布中的区间长度) 假设某班车到站的剩余等待时间 X 在 $[0,10]$ 分钟内均匀分布，则 $f(x)=1/10$，$0\le x\le 10$. 等待时间介于 *2* 分钟和 *5* 分钟之间的概率为

$$P(2\le X\le 5)=\int_2^5\frac{1}{10}\mathrm{d}x=\frac{3}{10}.$$

若已知至少还要等 *4* 分钟，则新的可能范围是 $[4,10]$，此时

$$P(X\le 7\mid X\ge 4)=\frac{P(4\le X\le 7)}{P(X\ge 4)}=\frac{3/10}{6/10}=\frac{1}{2}.$$

计算条件概率时，作为分母的总长度已经由 *10* 变为 *6*.

在讨论离散随机变量时，我们给出了几何分布，它表示独立地执行同样的实验时，首次成功出现的时间. 我们想要将其推广到连续的情形. 我们知道等比数列在连续情形下的推广就是指数函数，因此一个指数函数有望成为一个分布，只要其满足完备性条件. 我们知道，$\int_0^{+\infty}e^{-\lambda x}\mathrm{d}x=\lambda^{-1}$, 因此只需配备一个归一化系数 λ, 我们就得到了指数分布

例 2.2.17 (指数分布) 连续随机变量 X 取值为 $[0,+\infty)$, $\lambda>0$ 为常数，X 的密度函数为

$$f(x)=\lambda e^{-\lambda x},\quad x\in[0,\infty),$$

称该分布为指数分布（*Exponential Distribution*）.

指数分布时常用来描述电器等耐用器件的寿命. 因为这些器件在单位时间内都有一定的概率会损坏，而作为几何分布在连续意义下的推广的指数分布，恰好描绘了首次损坏出现的时间，也正是器件的寿命.

例 2.2.18 (指数分布中的生存概率) 假设某器件的寿命 T 以小时为单位，服从参数 $\lambda=0.01$ 的指数分布. 它能工作超过 *100* 小时的概率为

$$P(T>100)=\int_{100}^{+\infty}0.01e^{-0.01t}\mathrm{d}t=e^{-1}\approx 0.3679.$$

若器件已经正常工作了 *100* 小时，它还能再工作超过 *50* 小时的条件概率为

$$P(T>150\mid T>100)=\frac{e^{-1.5}}{e^{-1}}=e^{-0.5}=P(T>50).$$

Yuan-qing Song

这就是指数分布的无记忆性，与几何分布的例子相对应. 该结论依赖指数寿命模型；若器件会明显老化，便不能直接作此推断.

我们上文中讨论的连续分布的取值范围均为 $\mathbb{R}$ 的一个真子集. 我们下面想要寻找一个定义在 $\mathbb{R}$ 上的随机变量. 因为完备性，即 $\int_{-\infty}^{+\infty} f(x)\mathrm{d}x = 1$, 我们就不能考虑像均匀分布那样的简易的情形. 我们希望这个分布有一个中心，在这里的概率密度最高，而向两边分散时，概率密度逐渐趋向于 0，整个密度函数类似于一个钟形曲线. 在所有的初等函数中，我们锁定了 e^{-ax^2} 这一较为简单的函数满足上述条件. 下面要做的是根据完备性条件，求得上述函数的归一化系数. 这一计算可以使用两个相同积分耦合以及极坐标变换完成，这里不展开推导. 相应的归一化系数是 $\sqrt{a/\pi}$. 在实际问题中，我们令 $a = 1/(2\sigma^2)$, σ 有特殊的含义；而进一步由于平移不影响积分的结果，我们可以使用 $(x-\mu)^2$ 代替 x^2, μ 同样有特殊的含义. 我们将其总结为如下分布：

例 2.2.19 (正态分布/高斯分布) 连续随机变量 X 取值为 $\mathbb{R}$, 给定 $\mu \in \mathbb{R}, \sigma > 0$ 为常数，X 的密度函数为

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad x \in \mathbb{R},$$

称该分布为正态分布（*Normal Distribution*），或高斯分布（*Gaussian Distribution*），记为 $N(\mu, \sigma^2)$.

例 2.2.20 (正态分布先标准化再计算) 假设某传感器的读数 X 服从 $N(100, 4)$，其中均值为 *100*，标准差为 $\sqrt{4} = 2$. 令 $Z = (X - 100)/2$，通过变量代换可得 Z 服从 $N(0, 1)$. 因此

$$P(98 \le X \le 102) = P(-1 \le Z \le 1).$$

记标准正态分布函数为 $\Phi(z) = P(Z \le z)$，通过数值积分可得 $\Phi(1) \approx 0.8413$，又由对称性有 $\Phi(-1) = 1 - \Phi(1)$，所以

$$P(98 \le X \le 102) = 2\Phi(1) - 1 \approx 0.6827.$$

注意 $N(100, 4)$ 中的第二个参数是方差 *4*，标准化时应除以标准差 *2*.

2.2.3 数学期望

对于一列数 $x_1, \ldots, x_n$, 我们有平均数的概念，即 $\bar{x} := \frac{1}{n}(x_1 + \cdots + x_n)$. 而如果我们想要给所有数字分配不等的权重，我们可以额外定义权重 $w_1, \ldots, w_n$ 满足 $\sum_{i=1}^n w_i = 1$, 以及加权平均数 $\bar{x}_w := \sum_{i=1}^n w_i x_i$. 我们可以将权重的概念推广到随机变量与概率的语境中，用概率来代表不同取值的权重，从而也得到一个某种意义上的关于某个随机变量

的平均的数值，我们称这个数值为随机变量的均值（Mean）或数学期望（Expectation），简称期望. 离散随机变量与连续随机变量的数学期望的定义分别如下：

定义 2.2.21 (离散随机变量的数学期望) 对于离散随机变量 X，设其取值范围为 $\mathcal{X} = \{x_1, \ldots, x_n, \ldots\}$, 分布列为 $f(x)$, 如果级数 $\sum_{i=1}^{\infty} |x_i| f(x_i)$ 收敛，则称级数

$$\sum_{i=1}^{\infty} x_i f(x_i)$$

为随机变量 X 的数学期望，记作 $\mathbb{E}X$.

小贴士

考虑级数 $\sum_{i=1}^{\infty} |x_i| f(x_i)$ 的目的是，有些随机变量可能满足 $\sum_{i=1}^{\infty} x_i f(x_i)$ 收敛，然而 $\sum_{i=1}^{\infty} |x_i| f(x_i)$ 可能发散. 通常来讲，这是由于随机变量的分布过于分散，此时考虑它的均值这一衡量总体性质的量意义不大，此时我们称它的期望不存在. 不过，如果离散随机变量的取值仅为有限个，那么它的期望必定存在.

定义 2.2.22 (连续随机变量的数学期望) 对于连续随机变量 X, 设其取值范围为 $[a, b] \subseteq \mathbb{R}$, 密度函数为 $f(x)$, 如果积分 $\int_a^b |x| f(x) \mathrm{d}x$ 收敛，则称积分

$$\int_a^b x f(x) \mathrm{d}x$$

为随机变量 X 的数学期望，记作 $\mathbb{E}X$.

例 2.2.23 (期望不一定是可能取到的值) 掷一次均匀骰子，令 X 表示点数，则

$$\mathbb{E}X = \sum_{x=1}^{6} x \cdot \frac{1}{6} = \frac{1+2+3+4+5+6}{6} = 3.5.$$

骰子不会掷出 *3.5* 点，但多次独立掷骰子所得点数的平均值会趋近这一数值. 期望描述按概率加权的平均水平，并不保证某次试验能取到它.

连续情形也一样. 例如前面密度为 $f(x) = 2x$、$0 \le x \le 1$ 的随机变量，其期望为

$$\mathbb{E}X = \int_0^1 x \cdot 2x \mathrm{d}x = \frac{2}{3}.$$

这比区间中点 $1/2$ 更大，因为较大的取值附近具有更大的概率密度.

我们下面试着求一部分常用分布的数学期望，其他分布的期望留作习题.

例 2.2.24 对于二项分布，我们有：

$$\begin{aligned}\mathbb{E}X &= \sum_{x=0}^{n} xC_n^x p^x(1-p)^{n-x} = \sum_{x=0}^{n} x\frac{n!}{x!(n-x)!}p^x(1-p)^{n-x}\\ &= \sum_{x=1}^{n} nC_{n-1}^{x-1}p\cdot p^{x-1}(1-p)^{n-x} = np\sum_{y=0}^{n-1} C_{n-1}^{y}p^y(1-p)^{n-1-y} = np,\end{aligned}$$

其中最后一个等式利用了一个新的二项分布的完备性. 因此，我们有二项分布的均值即为 np, 特别地，当 $n=1$ 时，相应的伯努利分布的均值为 p.

例 2.2.25 对于正态分布，我们有：

$$\begin{aligned}\mathbb{E}X &= \int_{-\infty}^{+\infty} x\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}}\mathrm{d}x\\ &= \int_{-\infty}^{+\infty}(x-\mu)\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}}\mathrm{d}x + \int_{-\infty}^{+\infty}\frac{\mu}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}}\mathrm{d}x\\ &\xlongequal{y=x-\mu} \int_{-\infty}^{+\infty}\frac{y}{\sqrt{2\pi}\sigma}e^{-\frac{y^2}{2\sigma^2}}\mathrm{d}y + \mu = \mu,\end{aligned}$$

其中最后一个等式利用了奇函数的中心对称性. 因此，我们有正态分布的均值即为 μ, 这也是正态分布中参数 μ 的实际意义.

我们下面来讨论一下数学期望的性质. 首先，数学期望具有线性性，即：

性质 2.2.26 (线性性) 对于任意两个期望存在的随机变量 X, Y, 与任意三个常数 $a, b, c \in \mathbb{R}$, 我们有

$$\mathbb{E}(aX+bY+c) = a\mathbb{E}X + b\mathbb{E}Y + c.$$

我们将数学期望展开为级数或是积分的形式，并利用级数或是积分的线性性，就可验证上述关于期望的线性性质的正确性. 线性性可以帮助我们更方便地求得更多分布的均值.

例 2.2.27 (线性性不要求相互独立) 从 *1* 至 *10* 号共 *10* 张签中不放回地抽取两张，其中 *1* 至 *3* 号为中奖签. 令 X_1, X_2 分别表示两次是否中奖，中奖取 *1*，否则取 *0*. 由抽签位置的对称性，两者的中奖概率均为 $3/10$，所以

$$\mathbb{E}(X_1+X_2) = \mathbb{E}X_1 + \mathbb{E}X_2 = \frac{3}{10}+\frac{3}{10} = \frac{3}{5}.$$

虽然第二次是否中奖受第一次结果影响，期望仍然可以相加. 若每次中奖获得 *10* 元，参与两次抽签共花费 *4* 元，则净收益为 $R = 10(X_1+X_2)-4$，有

$$\mathbb{E}R = 10\times\frac{3}{5} - 4 = 2(\text{元}).$$

这里求的是平均净收益，并不是说每次参与都能获得 *2* 元.

Yuan and Song

例 2.2.28 对于超几何分布 $H(n,M,m)$, 我们引入 n 个辅助变量 $X_1,\dots,X_n$, 分别表示第 $1,\dots,n$ 次摸到的球的指示量，当摸到白球时取 *1*，否则取 *0*. 此时这 n 个辅助变量均满足伯努利分布，而且由于抽签结果与抽签顺序无关的原理，它们的成功概率都是 m/M. 而超几何分布随机变量 X 就是这些辅助随机变量的和，因此根据数学期望的线性性，我们有：

$$\mathbb{E}X=\mathbb{E}(X_1+\cdots+X_n)=\mathbb{E}X_1+\cdots+\mathbb{E}X_n=n\frac{m}{M},$$

此即为超几何分布的数学期望.

数学期望的另一个性质考虑的是将一个函数 $g(x)$ 作用在随机变量上，得到另一个随机变量 $g(X)$, 并研究 $g(X)$ 的期望. 我们自然可以先求出 $g(X)$ 的分布然后再求它的期望，然而我们也有更加直接的办法，即如下的性质：

性质 2.2.29 (佚名统计学家公式) 以下假设 $\mathbb{E}|g(X)|<\infty$.

1. 已知离散随机变量 X 取值列为 $x_1,x_2,\dots$, 相应的分布列为 $f(x)$. 对于一个给定的博雷尔函数 $g(x)$, 我们有：

$$\mathbb{E}\big(g(X)\big)=\sum_{i=1}^{\infty}g(x_i)f(x_i).$$

2. 已知连续随机变量 X 取值范围为 $[a,b]$, 相应的密度函数为 $f(x)$. 对于一个给定的博雷尔函数 $g(x)$, 我们有：

$$\mathbb{E}\big(g(X)\big)=\int_a^b g(x)f(x)\mathrm{d}x.$$

小贴士

博雷尔函数（Borel Functions）的严格要求是，每个博雷尔集的原像仍是博雷尔集. 我们常用的连续函数、分段连续函数等都满足这一要求.

佚名统计学家公式在离散情形下，可以通过把映射到同一 $g(x)$ 值的概率合并，再重新求和来理解；它不要求 g 是一一映射. 对于连续情形，求 $g(X)$ 的密度函数有时候并不容易，而这一公式告诉我们，如果只是想求 $g(X)$ 的期望，仍可直接按 X 原有的分布加权，只需把期望公式中的被积因子 x 替换为 $g(x)$ 即可. 这为计算带来了方便. 连续情形的严格证明需要用到测度论知识，我们在此略去.

例 2.2.30 (直接求函数的期望) 设 X 以相同概率取 $-1,0,1$，令 $Y=X^2$. 此时 -1 与 1 都映射到 *1*，所以 Y 的分布为

$$P(Y=0)=\frac{1}{3},\qquad P(Y=1)=\frac{2}{3},$$

从而 $\mathbb{E}Y = 2/3$. 用佚名统计学家公式直接计算，也得到

$$\mathbb{E}(X^2) = (-1)^2 \cdot \frac{1}{3} + 0^2 \cdot \frac{1}{3} + 1^2 \cdot \frac{1}{3} = \frac{2}{3}.$$

但 $\mathbb{E}X = 0$，故 $\mathbb{E}(X^2) \neq (\mathbb{E}X)^2$；一般不能把非线性函数移到期望符号外.

若改为 X 在 $[-1, 1]$ 上均匀分布，则无需求 X^2 的密度，便有

$$\mathbb{E}(X^2) = \int_{-1}^{1} x^2 \cdot \frac{1}{2} \mathrm{d}x = \frac{1}{3}.$$

2.3 多元随机变量与方差

在上一节中，我们研究了单个随机变量的性质及其均值，而在本节中我们要讨论多个随机变量组合起来的联合随机变量的性质. 同时我们也进一步讨论度量随机变量偏离中心程度的指标——方差，并引入它在多元随机变量情形下的变体.

2.3.1 多元随机变量

有些随机对象可能难以用一个数字来描述，如同时掷多轮骰子. 那么这时我们就需要使用一系列的数 $X_1, \ldots, X_n$ 来共同描述一个随机对象. 上述的 n 个数便构成了一组 n 元随机变量，或称随机向量（Random vectors）. 此时它们的样本空间同样需要对每个样本空间做笛卡尔积，即 $\Omega_1 \times \Omega_2 \times \cdots \times \Omega_n$. 每个随机变量既可以都是离散型的，也可以都是连续型的，还可以是有些离散、有些连续的. 然而离散与连续混杂的形式讨论起来较为复杂，我们在本节中只讨论全部离散或是全部连续的情形.

了解一组 n 元随机变量的性质，首先要定义它们的分布，离散与连续的 n 元随机变量的分布分别定义如下：

定义 2.3.1 (n 元离散随机变量的分布) 给定 n 元离散随机变量 $X_1, \ldots, X_n$, 设其所有取值构成的集合为 $\mathcal{X} := \mathcal{X}_1 \times \cdots \times \mathcal{X}_n$, 其中每一个取值为一个 n 元向量，定义以 $\mathcal{X}$ 为定义域的函数

$$f(x_1, \ldots, x_n) := P(X_1 = x_1, \ldots, X_n = x_n), \quad (x_1, \ldots, x_n) \in \mathcal{X},$$

为 n 元随机变量 $X_1, \ldots, X_n$ 的联合概率质量函数，也称联合分布列.

小贴士

概率记号 $P(\cdot, \cdot)$ 中的逗号代表交事件.

Yuan and Song

例 2.3.2 (用联合分布表记录两个量) 独立地掷两枚均匀硬币，令 X 表示第一枚是否为正面，正面取 *1*，反面取 *0*；令 Y 表示两枚硬币中正面的总数. 四个等可能的结果分别给出

$$(X,Y)=(0,0),(0,1),(1,1),(1,2).$$

因此联合分布列可以写成表格：

$X\backslash Y$	0	1	2
0	1/4	1/4	0
1	0	1/4	1/4

表中每个数表示“行条件和列条件同时满足”的概率. 例如 $P(X=1,Y=2)=1/4$，而 $P(X=0,Y=2)=0$，因为第一枚为反面时不可能共出现两个正面. 表中所有概率之和为 *1*，但不是每个数对都可能出现.

定义 2.3.3 (n 元连续随机变量的分布) 给定 n 元连续随机变量 $X_1,\ldots,X_n$，设其取值范围为 $\mathcal{X}:=\mathcal{X}_1\times\cdots\times\mathcal{X}_n\subseteq\mathbb{R}^n$，定义以 $\mathcal{X}$ 为定义域的函数

$$F(x_1,\ldots,x_n):=P(X_1\le x_1,\ldots,X_n\le x_n),\quad (x_1,\ldots,x_n)\in\mathcal{X},$$

为 n 元随机变量 $X_1,\ldots,X_n$ 的联合累积分布函数，简称联合分布函数.

同样，我们也可以将 n 元连续随机变量的联合分布函数延拓至整个 $\mathbb{R}^n$ 空间，那些支撑以外的位置联合分布函数值可能是 0, 可能是 1, 也可能是中间的某个数值，我们只需代入定义计算即可. 随后我们可以引入 n 元连续随机变量的联合概率密度函数：

定义 2.3.4 (n 元连续随机变量的联合概率密度函数) 给定 n 元连续随机变量 $X_1,\ldots,X_n$，不妨设其取值范围为 $\mathbb{R}^n$，已知其联合累积分布函数为 $F(x_1,\ldots,x_n)$，若存在另一函数 $f(x_1,\ldots,x_n)$ 满足

$$F(x_1,\ldots,x_n)=\int_{-\infty}^{x_1}\cdots\int_{-\infty}^{x_n}f(t_1,\cdots,t_n)\mathrm{d}t_1\cdots\mathrm{d}t_n,$$

则称 $f(x_1,\ldots,x_n)$ 为 $X_1,\ldots,X_n$ 的联合概率密度函数，简称联合密度函数.

如果联合分布函数可微，那么联合密度函数应当是其关于每个分量求一次导的交叉导数，即 $f(x_1,\ldots,x_n)=\dfrac{\partial^n}{\partial x_1\cdots\partial x_n}F(x_1,\ldots,x_n)$. 在支撑以外的部分，联合密度函数恒为 0.

例 2.3.5 (联合密度要在整个支撑区域上归一化) 在三角形 $D=\{(x,y):x\ge0,y\ge0,x+y\le1\}$ 上均匀取一点 (X,Y)，设其联合密度在 D 上为常数 c，在 D 外为 *0*. 因为

D 的面积为 $1/2$，故 $c=2$；用二重积分验证也是

$$\int_0^1 \int_0^{1-x} c\mathrm{d}y\mathrm{d}x = \frac{c}{2} = 1.$$

事件 $X+Y \le 1/2$ 对应一个直角边长为 $1/2$ 的小三角形，所以

$$P(X+Y \le 1/2) = \int_0^{1/2} \int_0^{1/2-x} 2\mathrm{d}y\mathrm{d}x = \frac{1}{4}.$$

虽然 X,Y 各自的可能取值都在 $[0,1]$ 中，但它们的联合支撑是三角形，积分上限应随另一个变量变化，不能直接在整个单位正方形上积分.

我们下面给出一些具体的多元随机变量的例子：

例 2.3.6 (多元独立伯努利分布) 设 n 个相互独立的随机变量 $X_1,\dots,X_n$ 均服从成功概率为 p 的伯努利分布，则它们可以构成一个多元独立伯努利分布，且它们的联合分布列即为每个分量的分布列的乘积：

$$f(x_1,\dots,x_n) = \prod_{i=1}^n p^{x_i}(1-p)^{1-x_i}, \quad x_i \in \{0,1\}.$$

我们不难得出，$X_1+\cdots+X_n$ 服从二项分布. 这里随机变量相互独立的含义是，对任意取值范围 $B_1,\dots,B_n$，事件 $\{X_i \in B_i\}$ 相互独立. 在离散情形下，这等价于联合分布列在所有取值组合上等于各分量分布列的乘积；在有联合密度的连续情形下，则等价于联合密度几乎处处等于各分量密度的乘积. 独立性还保证：若有关期望存在，则 $\mathbb{E}(XY) = \mathbb{E}X\,\mathbb{E}Y$，这可以通过将联合分布的乘积代入求和或积分公式得到.

例 2.3.7 (多维均匀分布) 设 $\mathcal{X} \in \mathbb{R}^n$ 为一个体积有限的区域，记其体积为 V, 则定义多维均匀分布的密度函数为

$$f(x_1,\dots,x_n) = \frac{1}{V}, \quad (x_1,\dots,x_n) \in \mathcal{X}.$$

多维均匀分布就是几何概型在高维度下的随机变量表达.

我们下面介绍多元随机变量中最重要的实例——多元正态分布，先考虑二元的情形. 我们先来思考一下二元正态分布的联合密度函数可能是什么形式. 首先我们自然可以考虑两个正态分布随机变量相互独立的情况. 将两个随机变量的密度函数直接相乘，得到：

$$f(x,y) = \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}} \cdot \frac{1}{\sqrt{2\pi}\sigma_2} e^{-\frac{(y-\mu_2)^2}{2\sigma_2^2}} = \frac{1}{2\pi\sigma_1\sigma_2} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2} - \frac{(y-\mu_2)^2}{2\sigma_2^2}}.$$

不过更一般的情形下，X,Y 并不独立. 我们的做法是引入一个表示二者之间关系的因子 $\rho \in (-1,1)$. 当 $\rho = \pm 1$ 时分布退化，不再具有下面这种二维密度. 引入 ρ 后的二元正态分布的联合密度函数如下：

Yuan and Song

例 2.3.8 (二元正态分布) 定义服从二元正态分布的随机变量 X, Y 的密度函数为

$$f(x,y)=\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left\{-\frac{(x-\mu_1)^2}{2(1-\rho^2)\sigma_1^2}+\frac{\rho(x-\mu_1)(y-\mu_2)}{(1-\rho^2)\sigma_1\sigma_2}-\frac{(y-\mu_2)^2}{2(1-\rho^2)\sigma_2^2}\right\}.$$

可以看出，当 $\rho=0$ 时，就是我们上面给出的独立的情形. 而 $\rho\neq 0$ 时，归一化因子中出现了 $\sqrt{1-\rho^2}$, 同时指数中出现了交叉项，而交叉项的系数之所以如此设定，我们留待后续讨论边缘密度与条件密度时加以解决.

2.3.2 方差

我们知道，数学期望可以描述一个随机变量的整体平均特征，然而在有些场合，我们想要研究一个随机变量究竟偏离中心的程度如何，我们就需要引入一个全新的统计量.

一个直觉是，我们可以引入每个取值偏离期望的绝对值，并按概率加权，即

$$\sum_{i=1}^{\infty}p_i\big|x_i-\mathbb{E}X\big|,$$

但这样做引入了分段绝对值函数，这个函数具有许多不可导点，研究起来并不容易，因此我们转而研究另一个更加平滑的形式：

$$\sum_{i=1}^{\infty}p_i\big(x_i-\mathbb{E}X\big)^2.$$

从而我们引入了方差的定义，它可以同时适用于离散情形与连续情形.

定义 2.3.9 (方差) 对于一个随机变量 X 及其期望 $\mathbb{E}X$, 若

$$\mathbb{E}(X-\mathbb{E}X)^2$$

存在，则称其为随机变量 X 的方差（*variance*），记为 $\mathbb{D}X$ 或 $\mathrm{Var}(X)$. 同时称 $\sqrt{\mathbb{D}X}$ 为 X 的标准差（*standard deviation*）.

例 2.3.10 (均值相同，波动却不同) 两个随机变量 X, Y 各自以相同概率取两个值：X 取 *4* 和 *6*，Y 取 *0* 和 *10*. 它们的期望都是 *5*，但方差分别为

$$\mathbb{D}X=\frac{1}{2}(4-5)^2+\frac{1}{2}(6-5)^2=1,$$

$$\mathbb{D}Y=\frac{1}{2}(0-5)^2+\frac{1}{2}(10-5)^2=25.$$

对应标准差分别为 *1* 和 *5*. 因此，平均水平相同并不表示稳定程度相同；Y 的取值离均值更远，所以方差更大.

Xuan and Song

利用数学期望的线性性质，我们可以有如下推导：

$$\begin{aligned}\mathbb{D}X &= \mathbb{E}(X-\mathbb{E}X)^2 = \mathbb{E}\big(X^2 - 2X\mathbb{E}X + (\mathbb{E}X)^2\big)\\ &= \mathbb{E}(X^2) - 2\mathbb{E}X\cdot\mathbb{E}X + (\mathbb{E}X)^2 = \mathbb{E}(X^2) - (\mathbb{E}X)^2,\end{aligned}$$

这也是另一种计算方差的常用方式. 注意到 $\mathbb{E}(X^2)$ 实际上是随机变量 X 在函数 $y=x^2$ 作用下的新的随机变量的期望，而我们使用佚名统计学家公式就可以无需求新的随机变量的分布便可直接求得 $\mathbb{E}(X^2)$.

由于方差实际上也是一种期望，我们可以根据期望的性质直接得到方差的若干性质：

性质 2.3.11 *给定随机变量 X 及确定常数 c, 则我们有*

1. $\mathbb{D}c = \mathbb{E}(c-c)^2 = 0.$
2. $\mathbb{D}(X+c) = \mathbb{E}(X+c-\mathbb{E}X-c)^2 = \mathbb{E}(X-\mathbb{E}X)^2 = \mathbb{D}X.$
3. $\mathbb{D}(cX) = \mathbb{E}(cX-\mathbb{E}(cX))^2 = c^2\mathbb{E}(X-\mathbb{E}X)^2 = c^2\mathbb{D}X.$

例 2.3.12 (平移与缩放对方差的影响) *某随机误差 X 满足 $\mathbb{E}X=0$、$\mathbb{D}X=4$. 若仪器输出 $Y=3X+10$，则*

$$\mathbb{E}Y = 10, \qquad \mathbb{D}Y = 3^2\times 4 = 36, \qquad \sqrt{\mathbb{D}Y} = 6.$$

常数 10 只平移了读数，不改变波动大小；放大 3 倍使标准差放大 3 倍、方差放大 9 倍. 因此“方差也按 3 倍增长”是不正确的.

我们下面依然试着求一些随机变量的方差.

例 2.3.13 *考虑成功概率为 p 的伯努利分布 X, 其方差为*

$$\mathbb{D}X = p(1-p)^2 + (1-p)(0-p)^2 = p(1-p)$$

我们可以看出，p 越接近于 $0,1$ 中的某一个值，伯努利分布的方差越小，表示此时该随机变量更偏向一个确定性的结果，反之当 $p=1/2$ 时，方差达到最大，此时我们最难对结果做出预测.

Yuan and Song

例 2.3.14 考虑 $[a,b]$ 上的均匀分布 X, 首先易得其均值为 $(a+b)/2$, 随后方差计算为

$$\begin{aligned}\mathbb{D}X &= \int_a^b \left(x-\frac{a+b}{2}\right)^2 \cdot \frac{1}{b-a}\mathrm{d}x \\ &= \frac{1}{b-a}\left(\frac{x^3}{3}-\frac{a+b}{2}x^2+\frac{(a+b)^2}{4}x\Big|_a^b\right) \\ &= \frac{1}{b-a}\left(\frac{1}{12}b^3-\frac{1}{4}ab^2+\frac{1}{4}a^2b-\frac{1}{12}a^3\right) \\ &= \frac{(b-a)^2}{12}\end{aligned}$$

我们最后再考虑正态分布，并指出其密度函数中的另一个参数 σ^2 正是它的方差.

例 2.3.15 考虑正态分布的方差，直接使用定义计算：

$$\begin{aligned}\mathbb{D}X &= \int_{-\infty}^{+\infty}(x-\mu)^2\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}}\mathrm{d}x \\ &\xlongequal{y=x-\mu} \int_{-\infty}^{+\infty} y^2\frac{1}{\sqrt{2\pi}\sigma}e^{-y^2/(2\sigma^2)}\mathrm{d}y \\ &= -\int_{-\infty}^{+\infty} y\frac{\sigma}{\sqrt{2\pi}}\mathrm{d}e^{-\frac{y^2}{2\sigma^2}} \\ &= -\frac{\sigma y}{\sqrt{2\pi}}e^{-\frac{y^2}{2\sigma^2}}\Big|_{-\infty}^{+\infty}+\int_{-\infty}^{+\infty}\frac{\sigma}{\sqrt{2\pi}}e^{-\frac{y^2}{2\sigma^2}}\mathrm{d}y \\ &= 0+\sigma^2=\sigma^2\end{aligned}$$

自此，正态分布 $N(\mu,\sigma^2)$ 中的两个参数的实际含义均已明晰，它们分别是正态分布的均值与方差.

2.3.3 边缘分布与条件分布

在本小节中，为了简便起见，我们均只考虑二元随机变量的情形，因为二元情形足以展示多元随机变量之间的相互关系，更多元的情形可以类推得到.

我们下面考虑二元随机变量的期望，它的期望自然也是一个二维向量. 而无论是级数还是积分，我们计算期望的公式得到的都只是一个标量，因此，考虑二元随机变量的期望需要每个分量单独进行考虑. 一个合理的思路是，考虑一个函数：$g(X,Y)=X$, 并使用佚名统计学家公式. 对于连续随机变量的情形，我们可以定义二元期望的第一个分量为

$$\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty} xf(x,y)\mathrm{d}x\mathrm{d}y.$$

然而，我们从另一角度来想，二元随机变量中的第一个分量 X, 本身也是一个随机变量，它也有自己的分布与期望. 我们希望上述二元期望的第一个分量就恰好是 X 自身的期

Kuan and Song

望，这样就为我们研究二元多元随机变量带来了极大的方便. 而我们进一步观察上述式子即可得到：

$$\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty} xf(x,y)\mathrm{d}x\mathrm{d}y = \int_{-\infty}^{+\infty} x\left(\int_{-\infty}^{+\infty} f(x,y)\mathrm{d}y\right)\mathrm{d}x,$$

式子中出现的 $\int_{-\infty}^{+\infty} f(x,y)\mathrm{d}y$ 是一个关于 x 的函数，它实际上正是 X 单独作为随机变量时的密度函数. 这样一来，二元期望的第一个分量就与 X 自己的期望是等价的了，而相应的 X 自身的密度函数我们称其为边缘密度，以便和联合密度区分开来.

离散情形的边缘分布与连续情形的推导基本类似，我们分别给出二者的边缘分布的定义：

定义 2.3.16 (二元离散随机变量的边缘分布) *给定二元离散随机变量 X,Y, 设其所有取值构成的集合为 $\mathcal{X}\times\mathcal{Y}$, 定义关于 x 的函数*

$$f_X(x) := \sum_{y\in\mathcal{Y}} P(X=x, Y=y), \quad x\in\mathcal{X},$$

为 X 的边缘分布. 同理可得 Y 的边缘分布.

我们从事件的分解角度也可以对上述定义给出合理的解释，Y 的不同取值可以作为一个完备事件组 $B_1, B_2, \ldots$, 而 $X=x$ 为事件 A, 则我们有

$$A = A\cap\Omega = A\cap(B_1+B_2+\cdots) = AB_1+AB_2+\cdots,$$

从而有

$$P(A) = P(AB_1)+P(AB_2)+\cdots.$$

因此，X 的边缘分布其实就是 $P(X=x)$.

定义 2.3.17 (二元连续随机变量的边缘密度与边缘分布) *给定二元连续随机变量 X,Y, 不妨设其取值范围为 $\mathbb{R}^2$, 已知其联合密度函数为 $f(x,y)$, 定义关于 x 的函数*

$$f_X(x) := \int_{-\infty}^{+\infty} f(x,y)\mathrm{d}y,$$

为 X 的边缘密度，同时定义 $F_X(x) := \int_{-\infty}^{x} f_X(t)\mathrm{d}t$ 为 X 的边缘分布. 同理可得 Y 的边缘密度与边缘分布.

在事件与概率的语境中，我们有条件概率 $P(B|A) = P(AB)/P(A)$, 我们想把它推广到两个随机变量的情形. 对于离散的随机变量，这一推广是比较自然的，我们可以定义 Y 关于 X 的条件分布为

$$f_{Y|X} = \frac{P(X=x,Y=y)}{P(X=x)} = \frac{f(x,y)}{f_X(x)}.$$

Yuan and Song

对于连续随机变量的情形，因为变量取一个特定的值的概率大部分情形下是 0，因此上述式子是可能需要从极限的角度去定义. 然而，我们可以直接形式地将联合密度与边缘密度相除得到条件密度，这实际上就是使用极限方式定义后推导得到的结果. 总之，无论离散情形还是连续情形，我们都可以使用二者的商来定义一个条件概率.

定义 2.3.18 (二元离散随机变量的条件分布) 给定二元离散随机变量 X,Y, 设其所有取值构成的集合为 $\mathcal{X}\times\mathcal{Y}$, 已知其联合分布列 $f(x,y)$ 与 X 的边缘分布列 $f_X(x)$, 对 $f_X(x)>0$ 的取值 x，定义

$$f_{Y|X}(y|x):=\frac{f(x,y)}{f_X(x)}=\frac{P(X=x,Y=y)}{P(X=x)}$$

为 Y 关于 X 的条件分布函数. 同理可得 X 关于 Y 的条件分布函数.

例 2.3.19 (对联合分布表求和，再按条件归一化) 仍考虑例2.3.2中的联合分布表. 按行求和，得到 X 的边缘分布；按列求和，得到 Y 的边缘分布：

$$P(X=0)=P(X=1)=\frac{1}{2},$$

$$P(Y=0)=\frac{1}{4},\qquad P(Y=1)=\frac{1}{2},\qquad P(Y=2)=\frac{1}{4}.$$

若已知 $X=1$，就在该行内重新归一化，得到

$$P(Y=0|X=1)=0,\quad P(Y=1|X=1)=\frac{1/4}{1/2}=\frac{1}{2},\quad P(Y=2|X=1)=\frac{1}{2}.$$

条件分布的三个概率之和仍为 *1*. 因为 $P(Y=2|X=1)=1/2\neq 1/4=P(Y=2)$，所以 X,Y 并不独立. 也可用 $P(X=0,Y=2)=0\neq(1/2)(1/4)$ 检验这一点.

定义 2.3.20 (二元连续随机变量的条件密度与条件分布) 给定二元连续随机变量 X,Y, 不妨设其取值范围为 $\mathbb{R}^2$, 已知其联合密度函数 $f(x,y)$ 与 X 的边缘密度函数 $f_X(x)$, 对 $f_X(x)>0$ 的取值 x，定义

$$f_{Y|X}(y|x):=\frac{f(x,y)}{f_X(x)}$$

为 Y 关于 X 的条件密度函数，同时定义 $F_{Y|X}=\int_{-\infty}^{y}f_{Y|X}(t|x)\mathrm{d}t$ 为 Y 关于 X 的条件分布函数. 同理可得 X 关于 Y 的条件密度函数与条件分布函数.

例 2.3.21 (三角形支撑上的边缘密度与条件密度) 仍考虑例2.3.5，联合密度在 D 上为 *2*. 对于 $0\le x\le 1$，固定 x 后，y 只能在 $[0,1-x]$ 内取值，所以

$$f_X(x)=\int_0^{1-x}2\mathrm{d}y=2(1-x).$$

同理，$f_Y(y)=2(1-y)$，$0\le y\le 1$；相应区间外的边缘密度均为 *0*. 因此在三角形内均匀取点，并不意味着每个坐标都在 $[0,1]$ 上均匀分布.

Yuan and Song

对于 $0 \le x < 1$，条件密度为

$$f_{Y|X}(y|x) = \frac{2}{2(1-x)} = \frac{1}{1-x}, \quad 0 \le y \le 1-x,$$

区间外为 0. 也就是说，给定 $X = x$ 后，Y 在 $[0, 1-x]$ 上均匀分布. 例如

$$P(Y > 1/4 \mid X = 1/2) = \int_{1/4}^{1/2} 2\mathrm{d}y = \frac{1}{2}.$$

这里使用的是条件密度，不能把它写成两个单点事件概率的比值，因为 $P(X = 1/2) = 0$.

在例2.3.8讨论二元正态分布时，我们留有一个悬念，即指数中交叉项的系数为什么如此设定. 我们下面来计算一下二元正态分布的边缘密度与条件密度，并指出上述系数的设定可以保证二者依然还是正态分布.

例 2.3.22 考虑 X 的边缘密度，即将联合密度函数中的 y 积分掉. 直接积分毫无疑问会非常复杂，我们需要进行巧妙的观察. 我们将指数中的所有项在此列出：

$$-\frac{(x-\mu_1)^2}{2(1-\rho^2)\sigma_1^2} + \frac{\rho(x-\mu_1)(y-\mu_2)}{(1-\rho^2)\sigma_1\sigma_2} - \frac{(y-\mu_2)^2}{2(1-\rho^2)\sigma_2^2}.$$

我们看到，如果只关注 y, 那么指数中是一个关于 y 的二次函数，我们需要对其进行配方，就可以得到一个一元正态分布的形式. 具体来讲，y 的二次项系数是

$$-\frac{1}{2(1-\rho^2)\sigma_2^2},$$

一次项系数是

$$\frac{\mu_2}{(1-\rho^2)\sigma_2^2} + \frac{\rho(x-\mu_1)}{(1-\rho^2)\sigma_1\sigma_2} = \frac{1}{(1-\rho^2)\sigma_2}\left(\frac{\mu_2}{\sigma_2} + \frac{\rho(x-\mu_1)}{\sigma_1}\right),$$

因此 y 的对称轴为

$$\mu_2 + \frac{\rho\sigma_2(x-\mu_1)}{\sigma_1}$$

同时需要配出的常数项是

$$-\frac{1}{2(1-\rho^2)}\left(\frac{\mu_2}{\sigma_2} + \frac{\rho(x-\mu_1)}{\sigma_1}\right)^2.$$

将剩余与 y 无关的部分，连同配出的常数项结合，有：

$$\begin{aligned}
&-\frac{(x-\mu_1)^2}{2(1-\rho^2)\sigma_1^2} - \frac{\rho\mu_2(x-\mu_1)}{(1-\rho^2)\sigma_1\sigma_2} - \frac{\mu_2^2}{2(1-\rho^2)\sigma_2^2} + \frac{1}{2(1-\rho^2)}\left(\frac{\mu_2}{\sigma_2} + \frac{\rho(x-\mu_1)}{\sigma_1}\right)^2 \\
&= (\rho^2-1)\frac{(x-\mu_1)^2}{2(1-\rho^2)\sigma_1^2} = -\frac{(x-\mu_1)^2}{2\sigma_1^2},
\end{aligned}$$

余下的这正是 X 单独作为一元正态分布时指数中的项. 因此联合密度的指数可以做如下分解：

$$-\frac{(x-\mu_1)^2}{2\sigma_1^2} - \frac{1}{2(1-\rho^2)\sigma_2^2}\left(y - \mu_2 - \frac{\rho\sigma_2(x-\mu_1)}{\sigma_1}\right)^2.$$

从而我们就可以很方便地求出关于 X 的边缘密度，因为可以利用正态分布的密度函数

Yuan and Song

将积分化为 *1*，即：

$$\begin{aligned} f_X(x) &= \int_{-\infty}^{+\infty} f(x,y)\mathrm{d}y \\ &= \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}} \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)\sigma_2^2}\left(y-\mu_2-\frac{\rho\sigma_2(x-\mu_1)}{\sigma_1}\right)^2} \mathrm{d}y \\ &= \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}}, \end{aligned}$$

这恰好就是 X 自己作为正态分布时的密度函数. 进一步，我们也可以求得 Y 关于 X 的条件分布，事实上正是上述式子的后半部分，即：

$$f_{Y|X}(y|x) = \frac{f(x,y)}{f_X(x)} = \frac{1}{\sqrt{2\pi}\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)\sigma_2^2}\left(y-\mu_2-\frac{\rho\sigma_2(x-\mu_1)}{\sigma_1}\right)^2},$$

这同样也是一个正态分布，是一个均值为 $\mu_2+\frac{\rho\sigma_2(x-\mu_1)}{\sigma_1}$（与 x 有关），方差为 $(1-\rho^2)\sigma_2^2$ 的正态分布. 从而我们有结论：二元正态分布的边缘分布与条件分布都仍然是正态分布.

例 2.3.23 (给二元正态分布代入具体参数) 设 (X,Y) 服从二元正态分布，其中 $\mu_1=10$、$\mu_2=20$、$\sigma_1=2$、$\sigma_2=3$、$\rho=1/2$. 根据上例，X 的边缘分布为 $N(10,4)$，而给定 $X=12$ 后，Y 的条件均值与条件方差分别为

$$20+\frac{(1/2)\times 3}{2}(12-10)=21.5, \qquad (1-(1/2)^2)\times 3^2 = 6.75.$$

因此 Y 的条件分布为 $N(21.5, 6.75)$. 相较于 Y 自身的边缘分布 $N(20,9)$，观测到高于均值的 X 后，对 Y 的预测均值上升，预测的方差减小.

在结束本小节之前，我们最后再来探讨另一个概念——条件期望（conditional expectation）. Y 关于 X 的条件期望就是将对应的条件分布作为新的概率去计算 Y 的期望，计算出的结果是一个与 X 取值有关的函数. 我们只给出连续情形的条件期望定义，离散情形的可以类似得出.

定义 2.3.24 (条件期望) 给定二元连续随机变量 X,Y，不妨设其取值范围为 $\mathbb{R}^2$，已知 Y 关于 X 的条件密度函数为 $f_{Y|X}(y|x)$，定义关于 x 的函数

$$\mathbb{E}(Y|X=x) = \int_{-\infty}^{+\infty} y f_{Y|X}(y|x)\mathrm{d}y$$

为 Y 关于 X 的条件期望，同理可得 X 关于 Y 的条件期望.

条件期望的一个重要性质是，将 Y 关于 X 的条件期望作为一个新的随机变量，对它求期望就等于 Y 自身的期望. 其严格叙述如下：

性质 2.3.25 (重期望公式) 设 Y 关于 X 的条件期望为 $\mathbb{E}(Y|X=x)$，Y 自身的期望是 $\mathbb{E}Y$，

则有：

$$\mathbb{E}\big(\mathbb{E}(Y|X)\big) = \mathbb{E}Y.$$

证明. 我们注意到，$\mathbb{E}(Y|X=x)$ 是一个关于 x 的函数，那么 $\mathbb{E}(Y|X)$ 就是随机变量 X 在该函数作用下的一个新的随机变量，因此求它的期望依然使用的是佚名统计学家公式：

$$\begin{aligned}\mathbb{E}\big(\mathbb{E}(Y|X)\big) &= \int_{-\infty}^{+\infty}\left(\int_{-\infty}^{+\infty} y f_{Y|X}(y|x)\mathrm{d}y\right) f_X(x)\mathrm{d}x \\ &= \int_{-\infty}^{+\infty} y\left(\int_{-\infty}^{+\infty} f(x,y)\mathrm{d}x\right)\mathrm{d}y \\ &= \int_{-\infty}^{+\infty} y f_Y(y)\mathrm{d}y = \mathbb{E}Y.\end{aligned}$$

■

例 2.3.26 (先按条件求平均，再对条件求平均) 在例2.3.5的三角形均匀分布中，我们已经知道给定 $X=x$ 后，Y 在 $[0,1-x]$ 上均匀分布，故

$$\mathbb{E}(Y|X=x) = \frac{1-x}{2}, \qquad \mathbb{E}(Y|X) = \frac{1-X}{2}.$$

前者在给定 x 时是一个数，后者随随机变量 X 变化，仍是一个随机变量. 利用重期望公式与 $f_X(x) = 2(1-x)$，有

$$\mathbb{E}Y = \int_0^1 \frac{1-x}{2}\,2(1-x)\mathrm{d}x = \int_0^1 (1-x)^2\mathrm{d}x = \frac{1}{3}.$$

用 Y 的边缘密度直接计算，也得到

$$\mathbb{E}Y = \int_0^1 y\,2(1-y)\mathrm{d}y = \frac{1}{3}.$$

两种方法给出相同结果，展示了“先在每个条件下平均，再按条件出现的概率平均”的过程.

我们下面使用二元正态分布来验证重期望公式的正确性. 我们已经求得 Y 关于 X 的条件分布为均值 $\mu_2 + \frac{\rho\sigma_2(x-\mu_1)}{\sigma_1}$ 的正态分布，因此

$$\mathbb{E}(Y|X) = \mu_2 + \frac{\rho\sigma_2(X-\mu_1)}{\sigma_1},$$

我们根据期望的线性性质很容易得到

$$\mathbb{E}\big(\mathbb{E}(Y|X)\big) = \mathbb{E}\left(\mu_2 + \frac{\rho\sigma_2(X-\mu_1)}{\sigma_1}\right) = \mu_2 + \frac{\rho\sigma_2(\mu_1-\mu_1)}{\sigma_1} = \mu_2,$$

恰好为 Y 自己的均值 $\mathbb{E}Y$. 因此重期望公式得以验证.

在我们后续有关随机梯度下降算法的讨论中，重期望公式是一个很有利的工具，其帮助我们分步求取随机变量的均值.

YuanandSong

2.3.4 协方差与相关系数

我们知道数学期望具有线性性，即 $\mathbb{E}(X+Y)=\mathbb{E}X+\mathbb{E}Y$, 然而方差是否也具有线性性呢？我们尝试将其展开：

$$\begin{aligned}\mathbb{D}(X+Y)&=\mathbb{E}\big(X+Y-\mathbb{E}(X+Y)\big)^2=\mathbb{E}\big(X-\mathbb{E}X+Y-\mathbb{E}Y\big)^2\\&=\mathbb{E}(X-\mathbb{E}X)^2+\mathbb{E}(Y-\mathbb{E}Y)^2+2\mathbb{E}\big((X-\mathbb{E}X)(Y-\mathbb{E}Y)\big)\\&=\mathbb{D}X+\mathbb{D}Y+2\mathbb{E}\big((X-\mathbb{E}X)(Y-\mathbb{E}Y)\big).\end{aligned}$$

可以看到，两个随机变量之和的方差拆成两个方差之和之后还多出来了一个交叉项，我们自然地将这一项定义为两个随机变量之间的协方差（covariance）.

定义 2.3.27 (协方差) *对于两个随机变量 X,Y 及各自的期望 $\mathbb{E}X,\mathbb{E}Y$, 记*

$$\operatorname{cov}(X,Y):=\mathbb{E}\big((X-\mathbb{E}X)(Y-\mathbb{E}Y)\big)$$

为二者的协方差.

协方差实际上是一个二元函数作用在 X,Y 二元随机变量上得到的新的随机变量的期望，计算方法依然是使用佚名统计学家公式. 我们下面以二元正态分布为例，计算两个变量之间的协方差. 首先，两个随机变量的各自的期望分别是 μ_1,μ_2, 随后我们使用上一小节使用过的分解式，得到：

$$\begin{aligned}&\operatorname{cov}(X,Y)=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}(x-\mu_1)(y-\mu_2)f(x,y)\mathrm{d}x\mathrm{d}y\\&=\int_{-\infty}^{+\infty}\frac{(x-\mu_1)^2}{\sqrt{2\pi}\sigma_1}e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}}\left(\int_{-\infty}^{+\infty}\frac{y-\mu_2}{\sqrt{2\pi}\sigma_2\sqrt{1-\rho^2}}e^{-\frac{1}{2(1-\rho^2)\sigma_2^2}\left(y-\mu_2-\frac{\rho\sigma_2(x-\mu_1)}{\sigma_1}\right)^2}\mathrm{d}y\right)\mathrm{d}x\\&=\int_{-\infty}^{+\infty}\frac{(x-\mu_1)^2}{\sqrt{2\pi}\sigma_1}e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}}\cdot\frac{\rho\sigma_2(x-\mu_1)}{\sigma_1}\mathrm{d}x\\&=\frac{\rho\sigma_2}{\sigma_1}\mathbb{E}(X-\mu_1)^2=\frac{\rho\sigma_2}{\sigma_1}\mathbb{D}X\\&=\frac{\rho\sigma_2}{\sigma_1}\sigma_1^2=\rho\sigma_1\sigma_2,\end{aligned}$$

因此二元正态分布中 X,Y 之间的协方差为 $\rho\sigma_1\sigma_2$.

回过头来，方差可以视为协方差的一种特例，即自己与自己的协方差. 进一步，我们在上一章中介绍的柯西-施瓦茨不等式可以从向量形式推广到离散随机变量分布列，乃至连续随机变量的场景，我们可以得出如下结论：

$$\big|\mathbb{E}(XY)\big|\leq\sqrt{\mathbb{E}(X^2)}\sqrt{\mathbb{E}(Y^2)},$$

Yuanzhi Song

稍加转换即可得到

$$\big|\operatorname{cov}(X,Y)\big| \le \sqrt{\mathbb{D}X}\sqrt{\mathbb{D}Y},$$

从而我们可以定义如下的相关系数（correlation coefficient）：

定义 2.3.28 (相关系数) *对于两个随机变量 X,Y, 已知各自的方差 $\mathbb{D}X,\mathbb{D}Y$, 及协方差 $\operatorname{cov}(X,Y)$, 定义相关系数为*

$$\rho = \frac{\operatorname{cov}(X,Y)}{\sqrt{\mathbb{D}X}\sqrt{\mathbb{D}Y}},$$

当 $\mathbb{D}X,\mathbb{D}Y$ 其中一个为 0 时，即其中一个随机变量为确定的常数，我们规定此时相关系数为 0.

因此，我们可以看到，二元正态分布中参数 ρ 的实际意义其实就是相关系数.

例 2.3.29 (从联合分布计算协方差与相关系数) *再考虑例2.3.2中的 X,Y. 由边缘分布可得*

$$\mathbb{E}X = \frac{1}{2},\quad \mathbb{E}Y = 1,\quad \mathbb{D}X = \frac{1}{4},\quad \mathbb{D}Y = \frac{1}{2}.$$

将联合分布表中的 xy 按概率加权，得到 $\mathbb{E}(XY) = 1\cdot 1\cdot(1/4) + 1\cdot 2\cdot(1/4) = 3/4$. 展开协方差的定义可得 $\operatorname{cov}(X,Y) = \mathbb{E}(XY) - \mathbb{E}X\,\mathbb{E}Y$，所以

$$\operatorname{cov}(X,Y) = \frac{3}{4} - \frac{1}{2}\times 1 = \frac{1}{4},\qquad \rho = \frac{1/4}{\sqrt{1/4}\sqrt{1/2}} = \frac{1}{\sqrt{2}}.$$

第一枚出现正面时，总正面数往往也更大，所以协方差为正. 若将 Y 替换为 $-Y$，协方差与相关系数都会变号. 若令 $Z = 2X+3$，则 $\operatorname{cov}(X,Z) = 2\mathbb{D}X = 1/2$、$\mathbb{D}Z = 1$，相关系数为 1，体现了完全的正线性关系.

例 2.3.30 (为什么独立测量取平均能减小方差) *设 $X_1,\dots,X_n$ 相互独立，每个变量的期望为 μ、方差为 σ^2. 独立性保证不同变量的协方差为 0. 将前面的方差展开式推广到 n 项，并令 $\bar{X} = (X_1+\cdots+X_n)/n$，得到*

$$\mathbb{E}\bar{X} = \mu,\qquad \mathbb{D}\bar{X} = \frac{1}{n^2}\sum_{i=1}^{n}\mathbb{D}X_i = \frac{\sigma^2}{n}.$$

例如单次测量的标准差为 2，4 次独立测量的平均值的标准差就是 $\sqrt{4/4} = 1$.

若只是把同一次测量 X 重复记录 4 遍，则平均值仍为 X，方差仍为 4. 减小方差需要利用测量之间的关系，不能只看记录条数. 我们后续研究小批量随机梯度时，也会用到这一思路.

Yuan and Song

例 2.3.31 (不相关不一定独立) 设 X 以相同概率取 $-1,0,1$，令 $Y=X^2$. 前一节已经算得 $\mathbb{E}X=0$、$\mathbb{E}Y=2/3$. 又因为

$$\mathbb{E}(XY)=\mathbb{E}(X^3)=\frac{-1+0+1}{3}=0,$$

所以 $\operatorname{cov}(X,Y)=0$，且 $\mathbb{D}X=2/3$、$\mathbb{D}Y=2/9$ 均为正，因此相关系数为 *0*. 但

$$P(Y=0|X=0)=1\neq\frac{1}{3}=P(Y=0),$$

故二者并不独立. 相关系数为 *0* 只排除了线性相关，不能排除 $Y=X^2$ 这样的非线性关系.

对于具有前述密度的二元正态分布，情形有所不同：当 $\rho=0$ 时，联合密度恰好分解为两个边缘密度的乘积，因此 X,Y 独立. 这个结论要求 (X,Y) 联合服从二元正态分布，不能推广到任意两个随机变量.

Yuan and Song